

DATA SCIENCE

Algoritmos de clasificación y Regresión

Temario

Algoritmos de clasificación

- ✓ KNN
- ✓ Random Forest
- ✓ Regresión Logística

Algoritmos de clasificación y Regresión

- ✓ [SVM](#)
- ✓ [Ejemplos clasificación errónea](#)
- ✓ [Regresión Lineal y Múltiple](#)
- ✓ [Optimización de hiperparámetros](#)


Algoritmos de Agrupación I

- ✓ K means
- ✓ DBSCAN

Objetivos de la clase

- **Profundizar** en el Aprendizaje Supervisado
- **Aplicar** el algoritmo de SVM
- **Aplicar** los modelos de Regresión

MAPA DE CONCEPTOS





Repaso

Les proponemos tomarse unos minutos para realizar un repaso de los conceptos aprendidos en Kahoot, ¿están listos?


**Profe, puedes compartir el PIN
o link de acceso al juego**

Support Vector Machine: **SVM**


Máquinas de soporte vectorial




SVM por sus siglas en inglés (**Support Vector Machines**), es un algoritmo que se puede usar tanto para regresión como para problemas de clasificación. Es un algoritmo que se fundamenta en la construcción de hiperplanos de segmentación.



Ejemplo aplicado




1) Imaginemos que tenemos dos grupos (Verde y Rojo). La línea naranja en este caso funciona como punto límite para decisión




2) Pero qué pasa si tenemos un punto muy cerca del límite de decisión



Ejemplo aplicado




3) En este caso lo podríamos clasificar como verde pero no tiene mucho sentido en este caso



Podemos enfocarnos en las observaciones cerca a los límites de los dos grupos

Podemos hacer esta clasificación de una mejor forma?




Para ello podemos usar el valor del punto medio entre esos dos puntos

Máquinas de soporte vectorial




TERMINOLOGÍA




La distancia más corta entre las observaciones y el threshold se conoce como **margen** esto se conoce como **Maximal Margin Classifier**

Para recordar el **margen** en teoría debe ser igual en ambos lados del threshold para que se tenga una buena clasificación




Pero no siempre funciona bien! **OUTLIERS**
PORQUE EN ESTE CASO NO FUNCIONA?


Máquinas de soporte vectorial



En este caso esa metodología no funciona tan bien y es porque los **Maximal Margin Classifiers** son muy sensibles a OUTLIERS





Elegir una zona límite que no sea sensible a outliers se conoce como **Bias/Variance Tradeoff** y el límite se conoce como **Soft margin**




Support Vector Classifier viene del hecho que se usó un **soft margin** por medio de **support vectors**

Máquinas de soporte vectorial





Máquinas de soporte vectorial





Las observaciones que quedan dentro del **soft margin** quedan mal clasificadas.

Máquinas de soporte vectorial




Máquinas de soporte vectorial



Cuando hay 4 o más dimensiones la máquina de soporte vectorial es un **hiperplano** así como en el caso 1D, 2D o 3D

Máquinas de soporte vectorial



Las máquinas de soporte vectorial pueden manejar **outliers** y problemas de **malas clasificaciones**


Ejemplo: Qué pasaría si tuviéramos este caso en el cual los puntos verdes representan pacientes recuperados y los rojo no recuperados (El medicamento solo funciona en las dosis apropiadas)



Máquinas de soporte vectorial



En estos casos **Maximal Margin Classifiers** no funciona tan bien y hablamos de **SVM (Support Vector Machines)**



- 1) Empezar con data en una dimensión baja (1D)
- 2) Mover los datos a una dimensión mayor (e.g 2D)
- 3) Encontrar el SVC que separe los datos


Ejemplos de clasificación errónea

Clasificaciones erróneas



Vamos a suponer que los puntos azules corresponden a la clase «azul» y los puntos rojos a la clase «rojo».

Ahora vamos a intentar dibujar una línea que separe los puntos azules de los rojos.




De esta forma, **cuando haya un punto nuevo, intentaremos poder determinar qué color va a tener, dependiendo del lado de la línea** en el que se encuentre.

Clasificaciones erróneas



En la siguiente figura, podemos decir que lo que esté a la izquierda de la línea, es azul y lo que esté a la derecha, es rojo.

Sin embargo, **el punto nuevo abajo a la izquierda es clasificado como azul aunque en realidad debería clasificarse como rojo.**




Clasificaciones erróneas



Podemos decir que cualquier punto que esté por arriba de la línea establecida será azul y cualquier otro punto que esté por debajo de la línea será rojo.


Sin embargo, **el nuevo punto a la derecha, ha sido incorrectamente clasificado como azul, cuando debería ser rojo.**



Clasificaciones erróneas

La línea que mejor distingue las zonas de los puntos azules de la zona de los puntos rojos es la que maximiza el margen entre ambos.

SVM es una técnica de machine learning que encuentra la mejor separación posible entre clases.





Para recordar...

Resulta importante mencionar, que **normalmente los problemas de aprendizaje automático tienen muchas dimensiones**, por lo tanto en vez de encontrar la línea óptima, **el SVM encuentra el hiperplano que maximiza el margen de separación entre clases**

Regresión Lineal Simple y Múltiple




Break

¡10 minutos y volvemos!

Regresión Lineal Simple

Regresión Lineal simple

A diferencia de los modelos anteriores, es un **modelo estadístico** que trata de explicar la relación que existe entre una **variable dependiente (variable respuesta)** y una **variable independiente (explicativa)**



Regresión Lineal simple


El modelo de regresión lineal está dado por la siguiente expresión:

$$y = \alpha + \beta X + \epsilon$$


α = intercepto (valor que toma Y cuando X vale 0)

β = es la pendiente (indica cómo cambia Y al incrementar X en una unidad)

ϵ = representa el error aleatorio con una distribución normal $(0, \sigma)$




Regresión Lineal simple




La estimación de α y β se hace por medio del metodo de **minimos cuadrados**, donde se busca minimizar la suma de cuadrados de los errores dada por:

$$SSE = \sum_{\substack{i=1 \\ \text{test set}}}^n \underbrace{(y_i - \hat{y}_i)}_{\text{predicted vaue actual value}}^2$$




Regresión Lineal simple




Interpretación del coeficiente β

Tenemos tres casos posibles:

1. $\beta = 0$ para cualquier valor de X la variable Y es constante (no cambia)
2. $\beta > 0$ indica que al aumentar el valor de X , también aumenta el valor de Y
3. $\beta < 0$ indica que al aumentar el valor de X , el valor de Y disminuye




Regresión Lineal simple



Coefficiente de correlación R: Es una medida que trata de medir la **dependencia lineal** que existe entre dos variables. Y su cuadrado se determina **coeficiente de determinación R^2**


El coeficiente de determinación cuantifica el porcentaje de variabilidad que puede explicar X de Y, por ejemplo si $R^2 = 0.45$, indica que 45% de la variabilidad de Y es explicada por X




Regresión Lineal simple

Propiedades del coeficiente de correlación

1. No tiene dimensión y siempre está entre $[-1,1]$
2. Si las variables son independientes entonces $R=0$, pero lo inverso no siempre es cierto
3. Si existe relación lineal perfecta $R=1$ o -1 (relación inversa perfecta)
4. Si $R>0$ indica una relación directa lineal de X en Y
5. Si $R<0$ indica una relación inversa de X en Y




Regresión Lineal simple



Supuestos


1. **Independencia:** los residuales deben ser independientes entre sí
2. **Homocedasticidad:** significa varianzas iguales, para cada valor de X la varianza de los residuales debe ser la misma
3. **Normalidad:** para cada valor de X , los residuales tienen distribución normal con media cero



Regresión Lineal Múltiple

Regresión Lineal Multiple

Similar al **modelo estadístico de Regresión lineal simple** donde trata de explicar la relación que existe entre una **variable dependiente (variable respuesta)** y unas **variables independientes (explicativas)**



Regresión Lineal Multiple




El modelo de regresión lineal múltiple está dado por la siguiente expresión:

$$y = \alpha + \beta_1 X_1 + \dots + \beta_n X_n + \epsilon$$

α = intercepto (valor que toma Y cuando X vale 0)

β_i = es la pendiente de cada variable independiente ($i = 1, 2, \dots, n$)

ϵ = representa el error aleatorio con una distribución normal $(0, \sigma)$




Regresión Lineal Multiple



Este modelo al igual que el de regresión lineal simple tiene los mismos supuestos y se puede cuantificar su desempeño de la misma forma (utilizando el coeficiente de determinación (R^2))

De igual forma el **la pendiente** de cada **variable independiente** puede ser o no significativa y se necesita verificar individualmente.



Optimización de hiperparametros

Hiperparametros

Los **hiperparametros** son variables que rigen el proceso de entrenamiento (e.g en una red neuronal las capas ocultas serían un ejemplo). Estas variables **no están directamente relacionadas** con los datos de entrenamiento, sino que son de **configuración** y por ende son **constantes** durante cualquier entrenamiento



Hiperparametros

Además de los hiperparametros tenemos dos otros conceptos importantes que controlan el entrenamiento de cualquier modelo:

1. Datos de entrada: colección de instancias con las características relevantes para el problema de interés. Se usan en el entrenamiento para configurar el modelo con el fin de que pueda realizar predicciones sobre nuevas instancias



Hiperparametros

Además de los hiperparametros tenemos dos otros conceptos importantes que controlan el entrenamiento de cualquier modelo:

2. Parámetros: son las variables que usan los modelos para ajustarse a los datos (e.g los nodos en una red neuronal y sus pesos). Los parámetros son formalmente el modelo ya que son los que dan las características



Hypertuning de parámetros

Hypertuning de Parámetros



Dentro de este contexto, resulta importante entender que **la optimización de hiper-parámetros**, se realiza normalmente mediante la utilización de un proceso de búsqueda cuyo objetivo consiste en encontrar la mejor selección de valores para un conjunto finito de hiper-parámetros con el objetivo de generar el mejor modelo posible.





Ejemplo en vivo

Miraremos ejemplos de aplicación dentro de la carpeta de clase para los algoritmos: SVM, Regresión Lineal + múltiple. Además exploraremos cómo podemos hacer el hypertuning de parámetros para un modelo de Regresión.



MATERIAL AMPLIADO

Recursos multimedia

Algoritmos de regresión



Algoritmos de regresión | **Scikit-Learn** | [Enlace](#)

Disponible en nuestro repositorio.

¿Preguntas?

Glosario

SVM: algoritmo de aprendizaje supervisado que permite resolver problemas de clasificación o regresión haciendo uso de hiperplanos generando regiones de separación con un amplio margen

Regresión lineal: técnica estadística que permite encontrar la asociación lineal entre una variable dependiente (Y) y una/varias variable(s) independiente(s) llamadas X's, puede ser simple (1 variable independiente) o múltiple (más de 1 variable independiente)

Parámetros: son las variables que usan los modelos para ajustarse a los datos. Se definen como la estructura interna del modelos ya que son las características del mismo

Hiperparametros: variables que rigen el proceso de entrenamiento, no están directamente relacionadas con los datos de entrenamiento sino que son de configuración y por ende son constantes durante cualquier entrenamiento

Muchas gracias.

Resumen de la clase hoy

- ✓ Clasificación con SVM
- ✓ Ejemplos de clasificación errónea
- ✓ Regresión Lineal simple y Múltiple
- ✓ Optimización de hiper parámetros

Opina y valora
esta clase

#DemocratizandoLaEducación