

Esta clase va a ser

- grabada

Semana 11. DATA SCIENCE

Introducción a ML y mejora de Modelos

Temario

En foco...

- ✓ Data Acquisition
- ✓ Data Wrangling
- ✓ EDA
- ✓ Análisis estadístico

Introducción a ML y Mejora de Mod

- ✓ [Marco CRISP-DM y la fase de Machine Learning y modelado](#)
- ✓ [Scikit Learn](#)
- ✓ [Técnicas de Encoding](#)
- ✓ [Feature Engineering](#)
- ✓ [Flujo de trabajo](#)

Algoritmos de clasificación

- ✓ KNN
- ✓ Random Forest
- ✓ Regresión Logística

Objetivos de la clase




Introducir el concepto de Machine Learning



Enfatizar la importancia del encoding de variables y la ingeniería de atributos



MAPA DE CONCEPTOS





Repaso

Les proponemos tomarse unos minutos para realizar un repaso de los conceptos aprendidos en Kahoot, ¿están listos?

**Profe, puedes compartir el PIN
o link de acceso al juego**



Actividad colaborativa

Recolectando datos

Simularemos pertenecer al equipo de marketing de una empresa de cosméticos e intentaremos encontrar patrones demográficos que indican a qué persona se le podría vender delineador de ojos

Recolectamos datos a través de una encuesta de zoom para su posterior análisis.

Duración: **5 minutos**

Marco CRISP-DM y la fase de Machine Learning y modelo


Definición

CRISP-DM, que son las siglas de Cross-Industry Standard Process for Data Mining, es un método probado para orientar sus trabajos de minería de datos.



- Como **metodología**, incluye descripciones de las fases normales de un proyecto, las tareas necesarias en cada fase y una explicación de las relaciones entre las tareas.
- Como **modelo de proceso**, CRISP-DM ofrece un resumen del ciclo vital de minería de datos.

Contiene 6 fases importantes que se encuentran relacionadas.

A continuación explicaremos cada una de ellas



Fases CRISP-DM




Comprensión del negocio


Es recomendable dedicar tiempo a explorar las expectativas de la organización con respecto al análisis de datos. Siempre es bueno involucrar a **equipos interdisciplinarios** para entablar discusiones sobre cual es el mejor camino a elegir.

Conocer el **contexto y las razones** por las cuales se realizan diferentes procesos hace que se pueda optimizar el tiempo y recursos valiosos en la compañía.

Es bueno **recopilar información** acerca de la situación comercial actual y qué **objetivos** tiene la compañía a corto, mediano y largo plazo



Comprensión de datos



Esta fase involucra estudiar más de cerca los datos disponibles, esto es vital para evitar problemas durante la siguiente fase: Preparación de datos

Es importante en esta fase acceder a los datos y explorarlos con ayuda de tablas y gráficos. Consiste de 4 procesos fundamentales:


1. Recopilación
2. Descripción
3. Exploración
4. Verificación de calidad



Preparación de datos

Es un aspecto fundamental que requiere de bastante tiempo (entre 50-70% del tiempo total invertido). Algunas de las tareas involucradas en esta fase son:

1. Fusión de conjuntos y registros de datos
2. Selección de muestras de subconjuntos de datos
3. Agregación de registros
4. Derivación de nuevos atributos
5. Clasificación de los datos para modelado
6. Eliminación o sustitución de valores en blanco o perdidos
7. División en entrenamiento y prueba





Modelado


En esta fase se incorporan herramientas analíticas para lograr resolver las preguntas de interés

El modelado se hace en varias iteraciones, los analistas de datos usualmente ejecutan varios modelos utilizando los parámetros predeterminados y ajustan los parámetros o vuelven a la fase de preparación de datos para las manipulaciones necesarias

Existen muchas formas de resolver un problema e incluso de pueden utilizar diversos modelos para resolver el mismo problema



Evaluación



Luego de implementar modelos se debe evaluar los resultados a través de criterios de rendimiento comercial que se deben establecer al inicio del proyecto.

Esta fase es clave para asegurar que su organización puede usar los resultados que ha obtenido

Las conclusiones o inferencias obtenidas de los modelos y del proceso se entienden como **descubrimientos**





Despliegue

Es el proceso que consiste en utilizar sus nuevos conocimientos para implementar las mejoras en su organización.

En general la fase de despliegue CRISP-DM incluye dos tipos de actividades:

1. Planificación y control del despliegue de los resultados
2. Finalización de tareas de presentación como la producción de un informe final y la revisión de un proyecto (La presentación final se puede llevar a cabo a través de un dashboard)





Implementando metodología CRISP-DM

Evaluaremos un caso donde podremos implementar la metodología CRISP-DM con el fin de resolver un problema

Duración: 15-20 min



ACTIVIDAD EN CLASE


Implementando metodología CRISP-DM

Descripción de la actividad.

Tenemos el siguiente escenario: El dueño de un concesionario de autos recientemente ha escuchado que los negocios que no implementen técnicas de análisis de datos no podrán hacer parte de ciertos beneficios que proporciona el gobierno. Por esto contrata a un grupo de personas dedicadas a la ciencia de datos para que le ayuden a implementar una metodología CRISP-DM en su compañía con el fin de maximizar las ventas

Importante: El concesionario lleva todos sus registros de manera manual desde su creación en 1975

Tiempo estimado 15-20 min





ACTIVIDAD EN CLASE


Implementando metodología CRISP-DM

Descripción de la actividad.

Rellenar la siguiente tabla con propuestas para el dueño del concesionario

Fase	Sugerencias de implementación
Comprensión del negocio	
Comprensión de datos	
Preparación de datos	
Modelamiento	
Evaluación y despliegue	

Tiempo estimado 15-20min




Scikit-learn

Scikit-learn



Scikit-learn es probablemente la librería más útil para Machine Learning en Python, es de código abierto y es reutilizable en varios contextos. **Proporciona además una gama de algoritmos de aprendizaje supervisados y no supervisados en Python.**

Fue diseñado por David Cournapeau como un código de un proyecto en 2007, luego este trabajo fue complementado por Matthieu Brucher en 2010 con su primera versión beta 1.0




Librerías involucradas

Scikit-learn



Esta librería está construida sobre **SciPy (Scientific Python)** e incluye las siguientes librerías o paquetes:



Scikit-learn



IPython:

consola interactiva mejorada



NumPy:

librería de matriz n-dimensional base



SciPy:

librería fundamental para la informática científica



Matplotlib:

trazado completo 2D



SymPy:

matemática simbólica



Pandas:


estructura de datos y análisis

¿Por qué elegir
Scikit-Learn?

¿Por qué elegir Scikit-Learn?


scikit
learn

- **Clustering.**
- **Ensemble methods**, es decir, algoritmos de aprendizaje supervisados y no supervisados.
- **Validación cruzada**, es decir, dispone de varios métodos para verificar la precisión de los modelos supervisados.
- Varios conjuntos de **datos para prueba**
- **Reducción de dimensionalidad**
- **Feature selection**
- Ajuste de **hiperparámetros**



Ventajas

1. **Interfaz consistente** sin importar el entorno
2. **Variedad de módulos y algoritmos** de ML y DL
3. **Posibilidad de extraer datos de varios repositorios** (Github, Gitlab entre otro)
4. **Parametros de configuracion** (parametros e hiperparametros)
5. **Documentación** bien estructurada y fácil de seguir
6. **Gran comunidad** que brinda soporte y ayuda en diferentes foros y repositorios en la web





Break

¡10 minutos y volvemos!

Encoding: One Hot, Label Encoder, Getdummies

One Hot Encoding



Toman variables numéricas para medir la distancia. Sin embargo, existe la manera de trabajar con variables categóricas haciéndolas variables dummy, a través del uso de la técnica de transformación de datos **One Hot Encoding (OHE)**. No permite convertir strings directamente.

COLOUR	ENCODING		
GREEN	RED	GREEN	BLUE
RED	0	1	0
BLUE	1	0	0
	0	0	1

Label Encoder



Sin embargo One Hot Encoding es la única técnica para transformar variables categóricas, existe una alternativa para reducir el problema de multidimensionalidad cuando tenemos muchas categorías en una variable a través del uso de la técnica de transformación de datos **Label Encoder (LE)**.

State (Nominal Scale)	State (Label Encoding)
Maharashtra	3
Tamil Nadu	4
Delhi	0
Karnataka	2
Gujarat	1
Uttar Pradesh	5

Getdummies()



Es un método similar a One Hot Encoding el cual transforma variables categóricas en dummies.

La diferencia es que One Hot Encoding almacena la transformación en un objeto. Una vez que se tiene la instancia `OneHotEncoder()`, se puede guardar para ser usada más tarde en las siguientes fases de manipulación de datos

Pandas Get Dummies

Turn your Categorical Column (Ex: "Name")...

Index	Name	8/6/2020
0	Liho Liho	\$234.54
1	Chambers	\$45.74
2	The Square	\$56.22
3	Liho Liho	\$32.31

...Into Dummy Indicator Columns

Index	Liho Liho	Chambers	The Square	8/6/2020
0	1	0	0	\$234.54
1	0	1	0	\$45.74
2	0	0	1	\$56.22
3	1	0	0	\$32.31


Ingeniería de atributos

Ingeniería de factores



También se le conoce como **Feature Engineering**

- Proceso previo a la creación del modelo en el que se hace **análisis, limpieza y estructuración de los datos**.
- El objetivo es eliminar los campos que no sirven para hacer la predicción y organizarlos adecuadamente **para que el modelo no reciba información que no le es útil y que podría provocar predicciones de poca calidad o confianza**.




Procesos involucrados



La ingeniería de factores consiste en diferentes procesos:

- Feature Creation
- Transformaciones
- Feature Extraction
- Exploratory Data Analysis
- Benchmark

A continuación explicaremos un poco cada uno de estos procesos



Feature Creation

Es el proceso de crear nuevas variables con el fin de desarrollar modelos más eficientes.

Esto se puede hacer añadiendo o removiendo algunas variables, incluso condensando diferentes variables en una sola por medio de un indicador

Es recomendable no añadir muchas más variables de las que se tienen en cualquier dataset.




Transformaciones

Es el proceso de convertir variables por medio de algún proceso de escalamiento o encoding

El objetivo de esta tarea es poder utilizar algunas visualizaciones para identificar si es necesario incluir o remover ciertas variables del dataset original.

Se pueden utilizar diversas metodologías con el fin de optimizar tiempos de ejecución en algoritmos como One Hot Encoding o LabelEncoder




Feature Extraction

Es el proceso de extraer variables o features de los datasets con el fin de identificar qué información es útil.

Sin distorsionar las relaciones originales o significativas, este proceso comprime la cantidad de información en cantidades manejables para que los algoritmos los procesen de manera eficiente.

Se asocia a lo que se conoce como reducción de dimensionalidad como el PCA por ejemplo.



Exploratory Data Analysis



Es el proceso de obtener gráficos y resúmenes descriptivos de los datos con el fin de mejorar el entendimiento de la data explorando sus propiedades

Esta técnica se aplica a menudo con el fin de poder testear hipótesis y encontrar patrones en los datos

Cobra mayor relevancia en datos de tipo cuantitativo o cualitativos que no han sido analizados previamente.



Benchmark

Es el proceso de crear un modelo de aprendizaje automático fácil de utilizar, confiable, transparente e interpretable.

Usualmente se pueden utilizar diferentes tipos de algoritmos para ver el desempeño individual de cada uno en los datos analizados (eg redes neuronales, máquinas de soporte vectorial, clasificadores lineales y no lineales, bagging/boosting entre otros)



Técnicas más utilizadas

Imputación

Esta técnica busca manejar los datos nulos, existen dos tipos de imputación:

1. **Numérica:** para este caso se puede utilizar interpolación o alguna técnica de regresión, incluso se puede reemplazar por valores por defecto
2. **Categorica:** una alternativa puede ser utilizar la moda para reemplazar, también es posible crear una nueva categoría llamada "Desconocido"



Manejo de outliers

Esta técnica busca remover valores atípicos de los datos.

Existen diversas formas de poder hacerlo:


1. **Remover:** es algo no muy recomendable aunque depende del contexto ya que puede dejar muy pocos datos para ser analizados
2. **Reemplazar:** se pueden reemplazar por la media o mediana entre otras opciones
3. **Capping:** utilizar valores arbitrarios de una distribución
4. **Discretización:** convertir variables numéricas a categóricas con el fin de evitar la influencia de outliers



Transformaciones numéricas

Existen muchas técnicas para realizar el procesos de escalamiento de los datos, a continuación mencionaremos las más utilizadas:

1. Logarítmica
2. StandardScaler
3. Min Max Scaler
4. Quantile Transformer
5. Robust Scaling
6. Absolute Maximum Scaling



Transformaciones categóricas




Para este proceso tenemos tres alternativas:

1. One Hot Encoding
2. Label Encoder
3. Conversión a variables dummies

Es recomendable que cuando se tienen pocas categorías (≤ 4) utilizar **One Hot Encoding** o el método **getdummies**.

Por otro lado, cuando se tienen muchas categorías (> 4) se recomienda reducirlas y aplicar **LabelEncoder**



Importancia

Importancia

El Feature Engineering es un proceso muy importante para Machine y Deep Learning, donde es posible extraer, limpiar, filtrar y crear variables artificiales que permiten mejorar el performance de modelos con el fin de obtener mejores resultados

Los Data Scientists pasan mucho tiempo limpiando y organizando datos (~60% del tiempo), por ende es importante que sean capaces de crear modelos reproducibles y con altos niveles de precisión



Importancia



Cuando las tareas asociadas a Feature Engineering se realizan de forma correcta, el dataset resultante es óptimo y contiene todos los factores importantes que afectan el problema de negocio

Como resultado estos datasets se convierten en el insumo para lograr obtener modelos con mayor precisión de los cuales se pueden obtener más insights



Flujo de trabajo


Flujo de trabajo





Ejemplo en vivo

Analizaremos el notebook llamado **Clase_1.ipynb** donde procesaremos la encuesta y entrenaremos un árbol de decisión que generará las reglas para determinar si alguien comprará o no delineador de ojos. Además evaluaremos qué tan bien funciona dicho árbol de decisión



¿Quieres saber más?
**Te dejamos material
ampliado de la clase**



MATERIAL AMPLIADO

Recursos multimedia

Scikit-Learn



Machine Learning in Python | **Scikit-Learn** | [Enlace](#)

Disponible en nuestro repositorio.

¿Preguntas?

Glosario

CRISP-DM: Cross-Industry Standard Process for Data Mining, es un método probado para orientar trabajos de minería de datos

Scikit-Learn: librería más útil para Machine Learning en Python, es de código abierto y es reutilizable en varios contextos

One Hot Encoding: proceso mediante el cual se realiza el encoding de variables categóricas en números utilizando variables dummies

Label Encoder: proceso mediante el cual se realiza el encoding de variables categóricas de manera secuencial ideal para variables ordinales

Feature Creation: proceso en el cual se crean nuevas variables con el fin de desarrollar modelos más eficientes.

Feature Extraction: proceso de extraer variables o features de los datasets con el fin de identificar qué información es útil.

Opina y valora
esta clase

Resumen de la clase hoy

- ✓ Marco CRISP-DM y la fase de Machine Learning
- ✓ Scikit Learn
- ✓ Encoding: OneHot encoder, Labelencoder, .getdummies()
- ✓ Ingeniería de atributos: concepto, ventajas y relevancia
- ✓ Flujo de trabajo

Muchas gracias.

#DemocratizandoLaEducación