DATA SCIENCE

Algoritmos de Agrupación I

CODERHOUSE

Temario

Algoritmos de clasificación y Regresión

- ✓ SVM
- ✓ Ejemplos clasificación errónea
- ✓ Regresión Lineal y Múltiple
- ✓ Optimización Hiper parámetros

Algoritmos de Agrupación I

- ✓ K means
- ✓ DBSCAN

Algoritmos de Agrupación II

- ✓ PCA
- ✓ Reducción de dimensionalidad
- ✓ Detección de Outliers

CODERHOUSE

Objetivos de la clase

- **Profundizar** en el Aprendizaje No Supervisado
- **Identificar** conceptos de aplicación de los modelos de Clustering

CODERHOUSE

MAPA DE CONCEPTOS



CODERHOUSE

K means

CODERHOUSE



Para pensar

Recuerdan ¿Cuál era la utilidad del algoritmo K means?. ¿En qué contextos se podía aplicar y con qué fin? ¿Hacía parte del aprendizaje Supervisado o No supervisado?

Contesta en el chat de Zoom

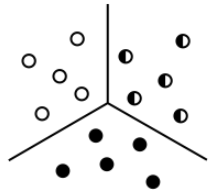
CODERHOUSE

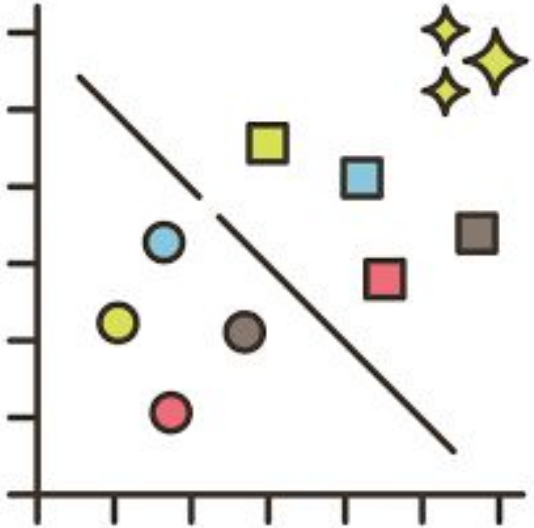
Definición

CODERHOUSE

K means

K-means es un algoritmo de aprendizaje no supervisado que se utiliza para resolver problemas de agrupamiento. Sigue un procedimiento simple de clasificar un conjunto de datos dado en una serie de grupos, definidos por la letra "k", que se fija de antemano por medio de un proceso iterativo



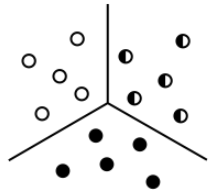


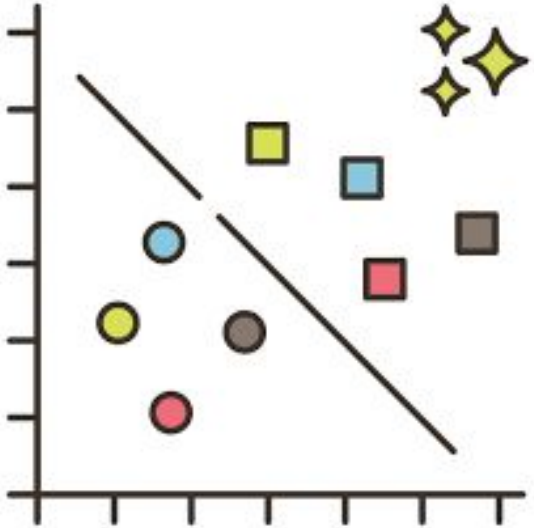
CODERHOUSE

¿Para qué sirve?

El objetivo de este algoritmo es **encontrar grupos en los datos, con el número de grupos representados por la variable K.**

El algoritmo funciona de manera iterativa para asignar cada punto de datos a uno de los grupos K en función de las características que se proporcionan.



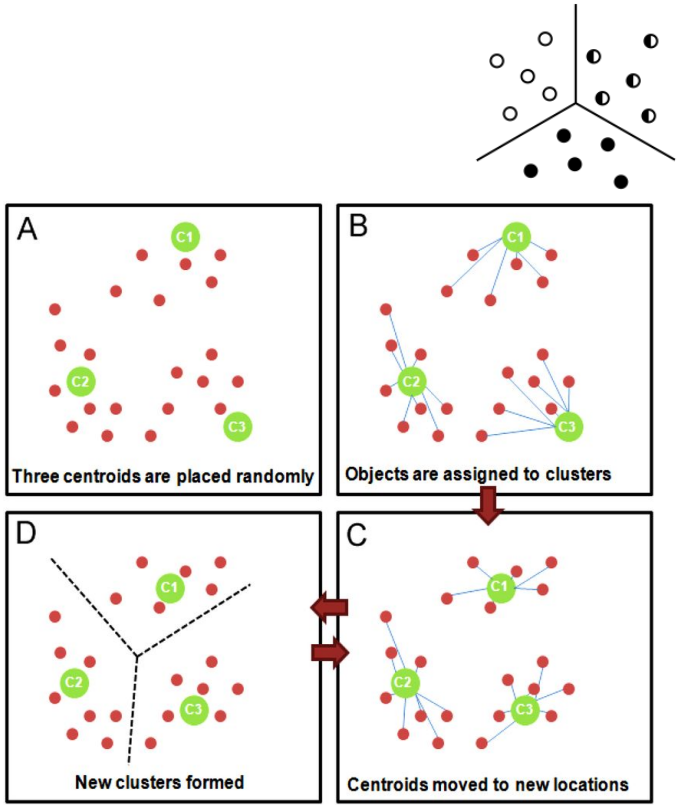


CODERHOUSE

¿Cómo se agrupa?

Los puntos de datos **se agrupan en función de la similitud de las características**. Los resultados de K Means son:

- Los centroides de los clústeres K, que pueden ser usados para etiquetar nuevos datos.
- Etiquetas para los datos de formación, cada punto de datos se asigna a un único clúster.



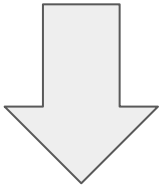
CODERHOUSE

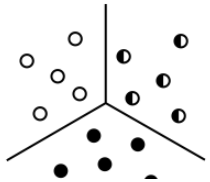
Ejemplo aplicado

CODERHOUSE

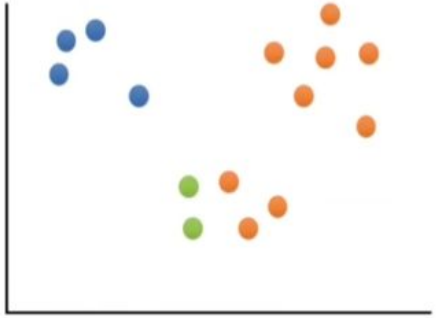
K means

Los datos reales pueden venir en diferentes formatos y formas y muchas veces interesa generar grupos automáticamente







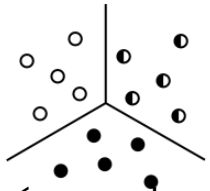


	Samples: #1	#2
Gene 1	12	6
Gene 2	-7	-13
Gene 3	8	6
Gene 4	7	-8



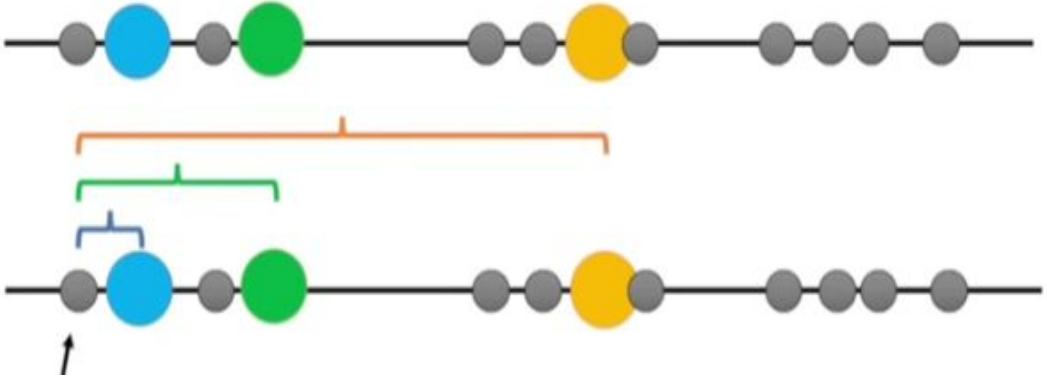
CODERHOUSE

K means





Paso 1: Seleccionar el número de clusters que se quieren obtener (k=3)

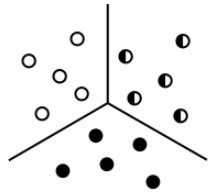


Paso 2: Seleccionar aleatoriamente 3 diferentes puntos

Paso 3: Medir la distancia entre el primer punto y los 3 centroides

CODERHOUSE

K means

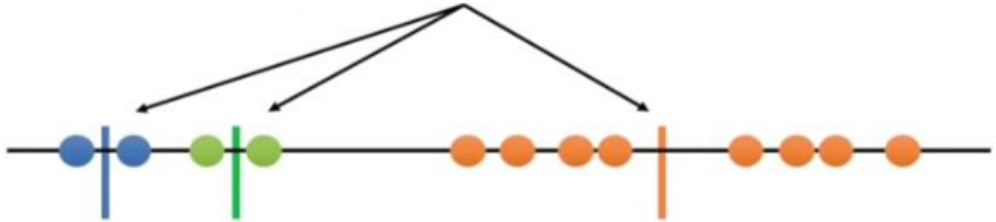




Paso 4: Asignar el cluster al grupo más cercano



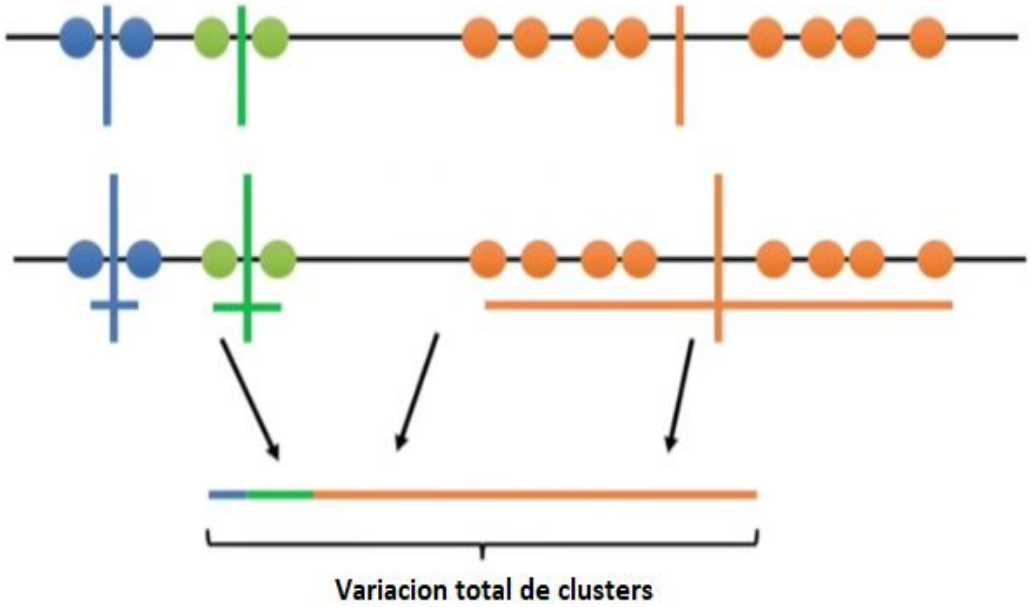
Paso 5: Repetimos el mismo proceso para los demás valores

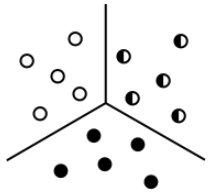


Paso 6: Calcular la media de cada cluster

CODERHOUSE

K means





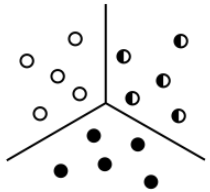
Paso 7: Repetir el mismo proceso de cálculo de distancias y asignación

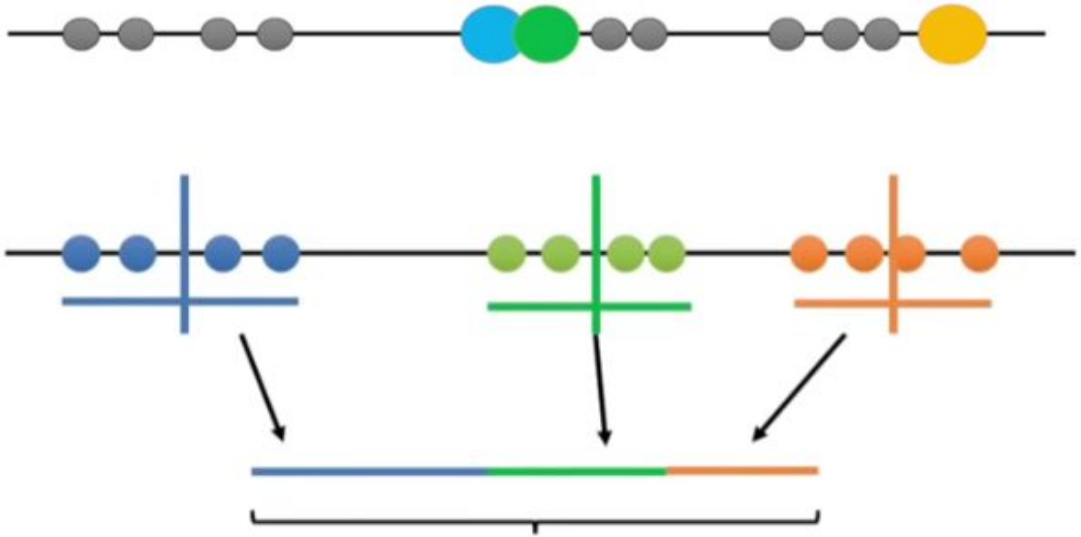
Paso 8: Se puede revisar que tan bien quedo el algoritmo con lo que se conoce como la Variación total de clusters

De lo anterior se puede deducir que la elección inicial de los centroides es importante

CODERHOUSE

K means



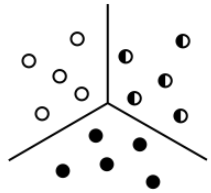


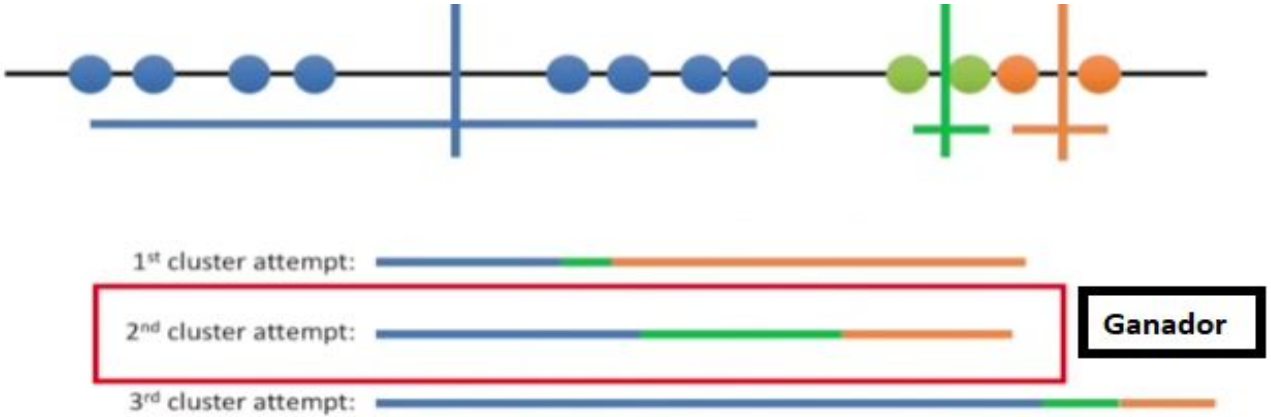
Paso 9: La selección de puntos se puede cambiar

Paso 10: El proceso se repite iterativamente varias veces hasta lograr convergencia

CODERHOUSE

K means

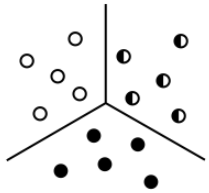


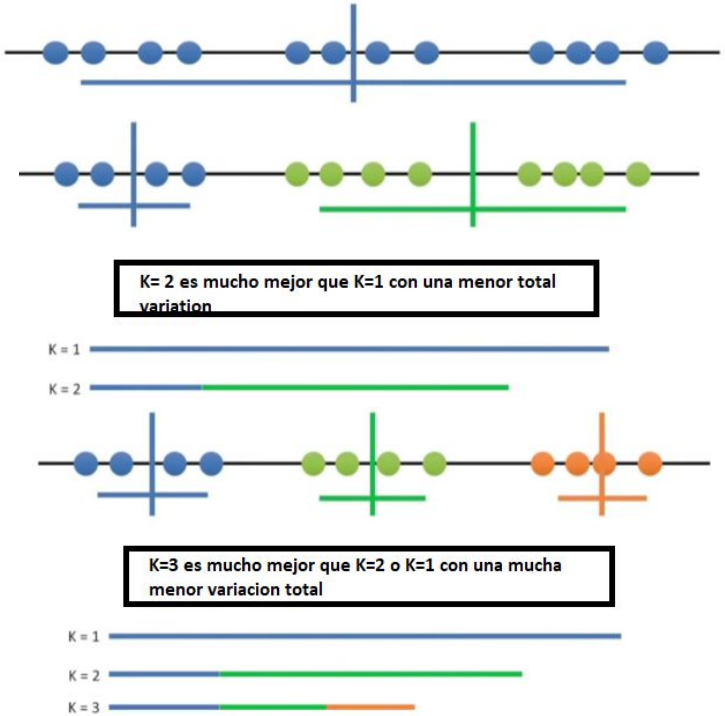


Si repetimos el proceso podemos identificar cuál metodología funciona mejor **(Esto puede ser mucho mayor que 3 veces)**

CODERHOUSE

K means – Selección valor óptimo K





k=1

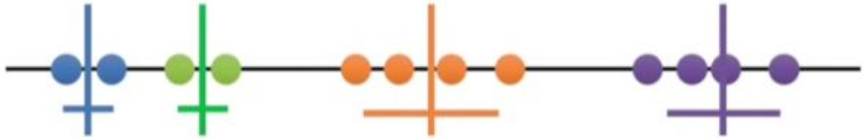
k=2

El objetivo es ir iterando el valor de K de tal manera que se identifique el valor de K que minimice la variación total

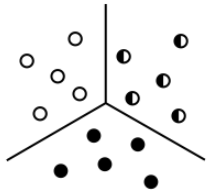
k=3

CODERHOUSE

K means - Selección valor óptimo K

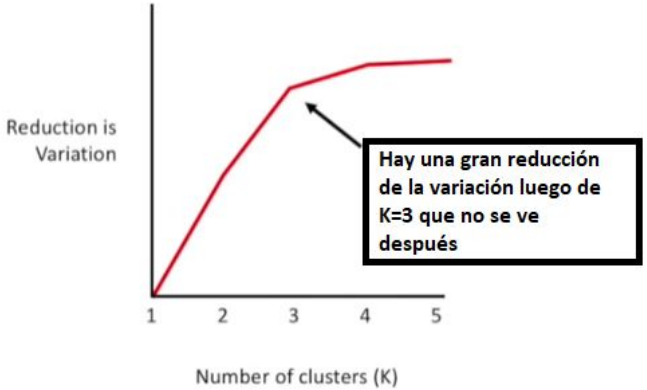






Cada vez que se agrega un cluster la variación total se hace menor hasta el punto que tendremos un grupo para cada individuo y no habrá variation total

Elbow Method (Método del Codo)



CODERHOUSE

DBSCAN

CODERHOUSE



Para pensar

¿Alguna vez han escuchado de algoritmos de agrupación basados en Densidad de puntos? ¿Conocen el algoritmo DBSCAN y HDBSCAN?

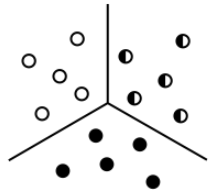
Contesta en el chat de Zoom

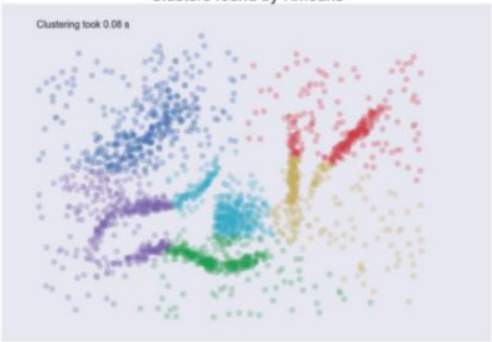
CODERHOUSE

Problemas del K means

CODERHOUSE

¿Para qué sirve?





Puede pasar a veces que **si no se escalan/normalizan** los datos, no anda nada bien porque asume que los datos son “esféricos”.



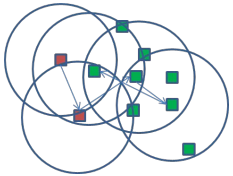
Como solución se suele utilizar algoritmos de clustering basado en densidades, como el HDBSCAN o el DBSCAN

CODERHOUSE

Definición

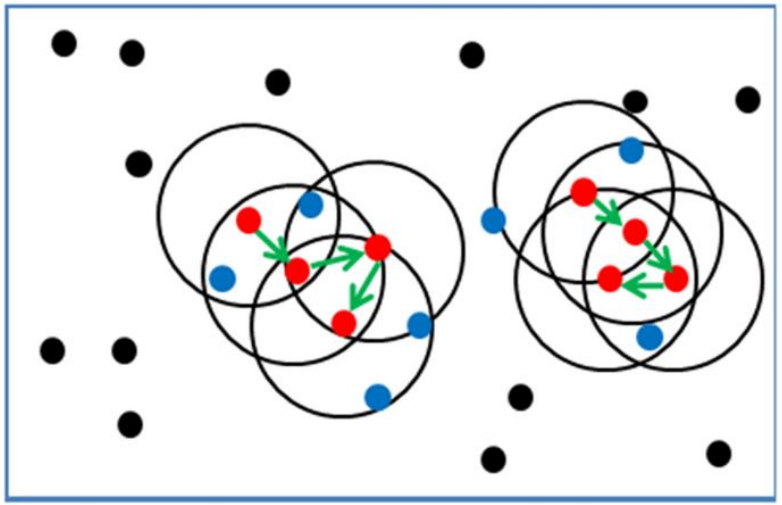
CODERHOUSE

DBSCAN



DBSCAN significa Density Based Spatial Clustering of Application with Noise

Fue propuesta por Martín Ester et al. en 1996. DBSCAN es un algoritmo de agrupamiento basado en la densidad que funciona asumiendo que los agrupamientos son regiones densas en el espacio separadas por regiones de menor densidad.

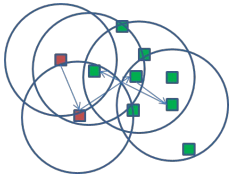


CODERHOUSE

Funcionamiento

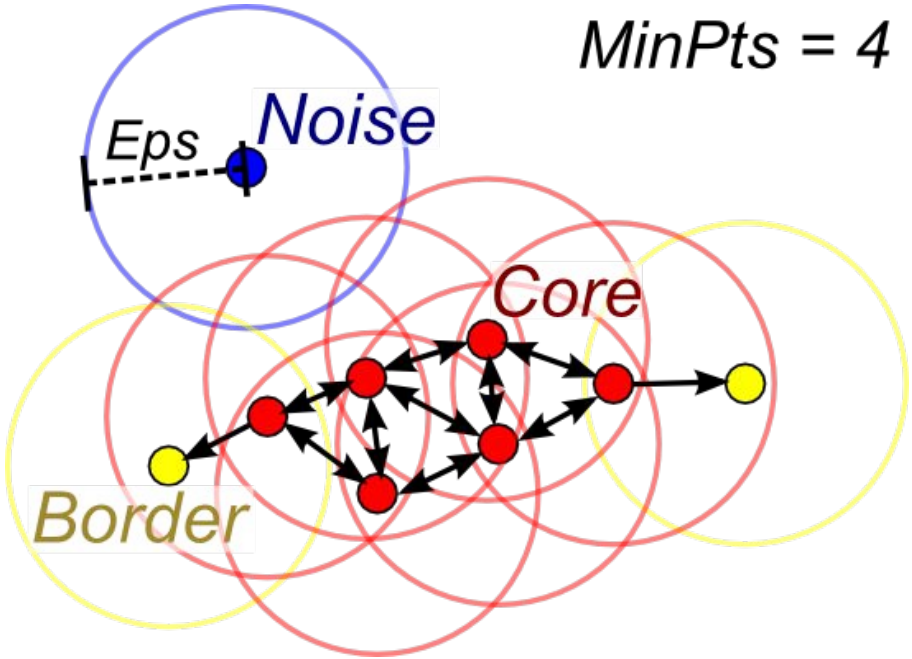
CODERHOUSE

Cómo funciona el DBSCAN



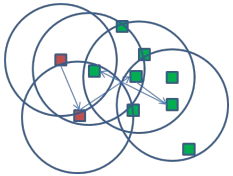
Separa los clusters de alta densidad de los de baja densidad
Input: Puntos, min_pts, eps
Output: Clusters con densidad

Cada punto es:
Core point: tiene al menos min_pts en su vecindario
Border point: no es core pero tiene al menos 1 core point en su vecindario
Noise point: No es core o border



CODERHOUSE

Ventajas/Desventajas DBSCAN



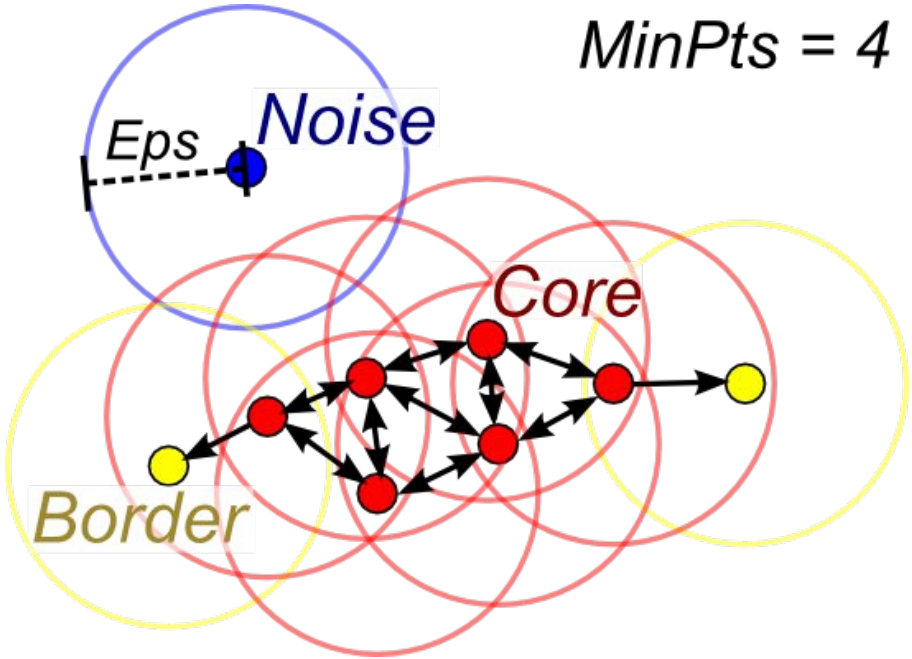
Ventajas

1. No necesita número de clusters
2. Clustering en diferentes formas
3. Elimina puntos de ruido

Desventajas

1. Sensible a los parámetros (si el min_pts es pequeño problemas)
2. Produce malos resultados cuando hay mucho ruido.

eps (valor crítico para considerar dos puntos como vecinos)



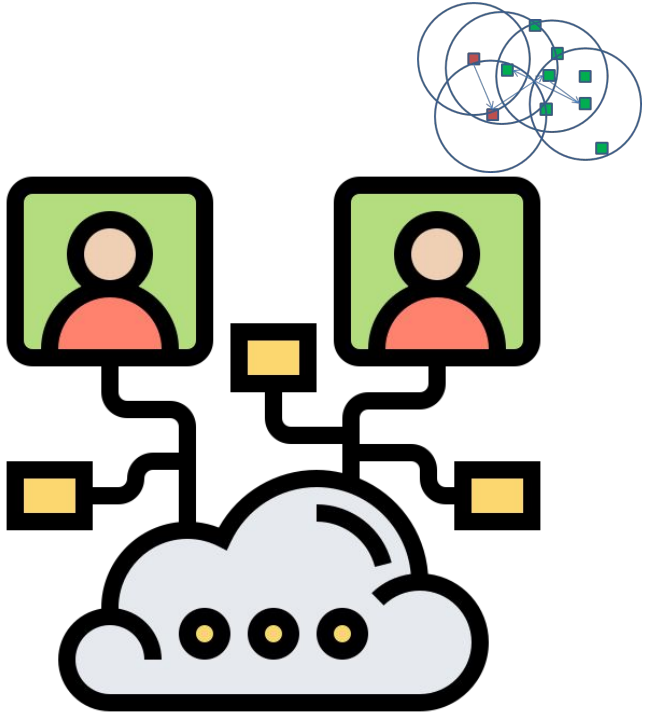
CODERHOUSE

HDBSCAN

CODERHOUSE

HDBSCAN

Es un algoritmo de clustering o agrupamiento **basado en la densidad** que puede ser utilizado para **identificar clústeres de cualquier forma en un conjunto de datos que contiene ruido y valores atípicos.** La idea básica detrás del enfoque de agrupamiento basado en la densidad se deriva de un método intuitivo de agrupamiento humano.

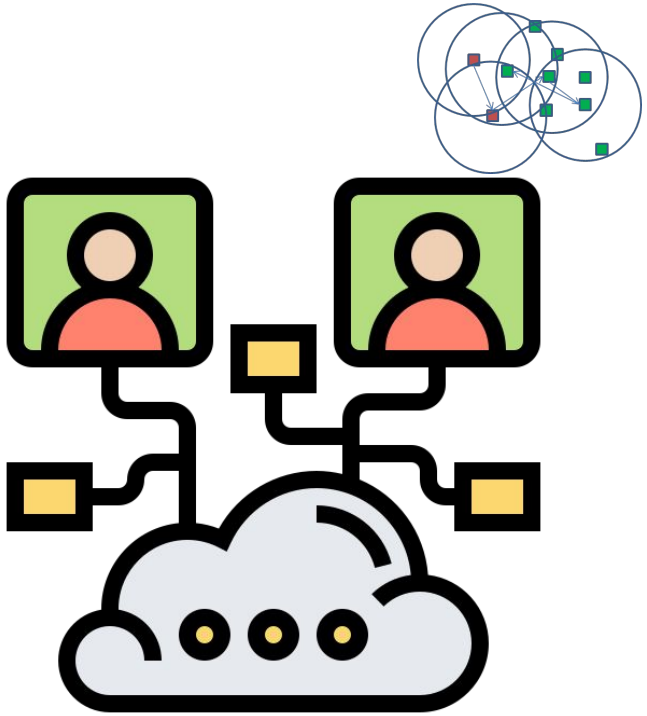


CODERHOUSE

HDBSCAN

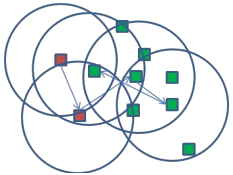
HDBSCAN= High DBSCAN

- Se enfoca mucho más en las altas densidades
- Reduce la velocidad de clustering en comparación con otros métodos
- Tiene un parámetro adicional min_cluster_size que define que tan grande debe ser un cluster para ser formado.

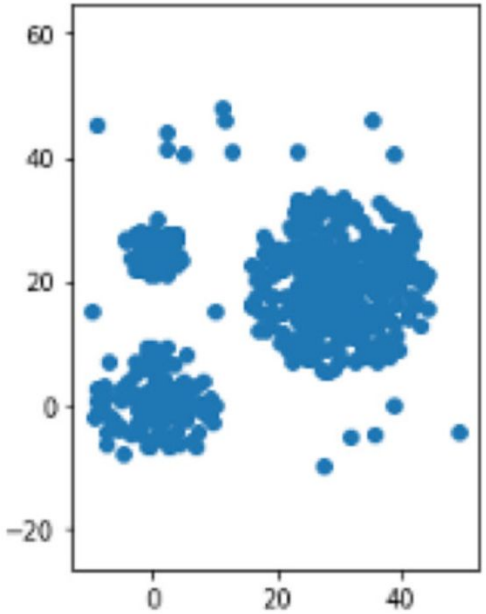


CODERHOUSE

HDBSCAN en acción



Por ejemplo, al mirar la figura de la derecha, uno puede identificar fácilmente tres grupos junto con varios puntos de ruido, debido a las diferencias en la densidad de puntos.



CODERHOUSE

Importante



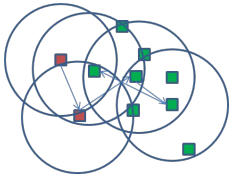
Por lo tanto, los clústeres son regiones densas en el espacio de datos, separadas por regiones de menor densidad de puntos. El algoritmo HDBSCAN se basa en esta **noción intuitiva de clústeres y ruido**.

CODERHOUSE

K Means vs DBSCAN/HDBCAN

CODERHOUSE

K means vs DBSCAN/HDBSCAN



K-Means	DBSCAN/HDBSCAN
La agrupación del K means es sensible a la cantidad de agrupaciones definidas	No es necesario especificar el número de conglomerados
Su agrupación en Clústeres no funciona bien con valores atípicos y conjuntos de datos con ruido	Su agrupación en Clústeres maneja de manera eficiente los outliers y los datos ruidosos
Las densidades variables de los puntos de datos no afectan el algoritmo K means	La agrupación basada en clústeres no funciona muy bien para conjuntos dispersos o para puntos con densidad variable
La agrupación en clústeres de K-means es más eficiente para grandes conjuntos de datps	No puede manejar de manera eficiente conjuntos de datos con alta dimensión

CODERHOUSE

¿Preguntas?

CODERHOUSE

Glosario

K means: algoritmo de aprendizaje no supervisado que se utiliza para resolver problemas de agrupamiento por medio de una serie de grupos, definidos por la letra "k", que se fija de antemano por medio de un proceso iterativo

DBSCAN: algoritmo de agrupamiento basado en la densidad que funciona asumiendo que los agrupamientos son regiones densas en el espacio separadas por regiones de menor densidad.

HDBSCAN: algoritmo de clustering o agrupamiento **basado en la densidad** que puede ser utilizado para **identificar clústeres de cualquier forma en un conjunto de datos que contiene ruido y valores atípicos.** La idea básica detrás del enfoque de agrupamiento basado en la densidad se deriva de un método intuitivo de agrupamiento humano.