DATA SCIENCE

Algoritmos de Agrupación II

CODERHOUSE

Temario

Algoritmos de agrupación I

- ✓ K means
- ✓ DBSCAN

Algoritmos de Agrupación II

- ✓ PCA
- ✓ Reducción de dimensionalidad
- ✓ Detección de outliers

Selección de Algoritmo y Entrenamiento del Modelo I

- ✓ Matriz de confusión
- ✓ Accuracy
- ✓ Precisión
- ✓ Sensibilidad
- ✓ Especificidad
- ✓ F1 score y curva ROC

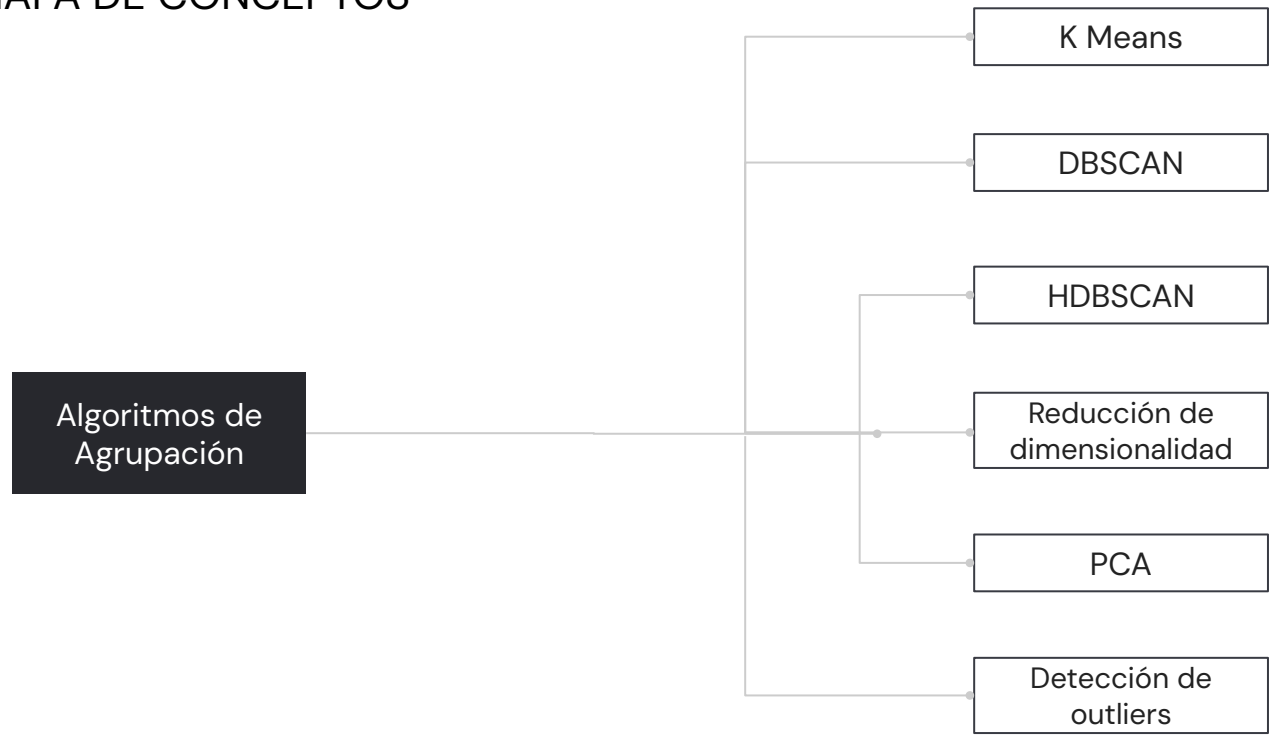
CODERHOUSE

Objetivos de la clase

- **Profundizar** en el aprendizaje supervisado
- **Conocer** el funcionamiento de los modelos de Clustering, PCA y detección de anomalías

CODERHOUSE

MAPA DE CONCEPTOS



CODERHOUSE

PCA

CODERHOUSE



Para pensar

Si tenemos una situación en la cual tenemos variables categóricas solamente respecto a los atributos de diversos automóviles, ¿podríamos aplicar la técnica de PCA?

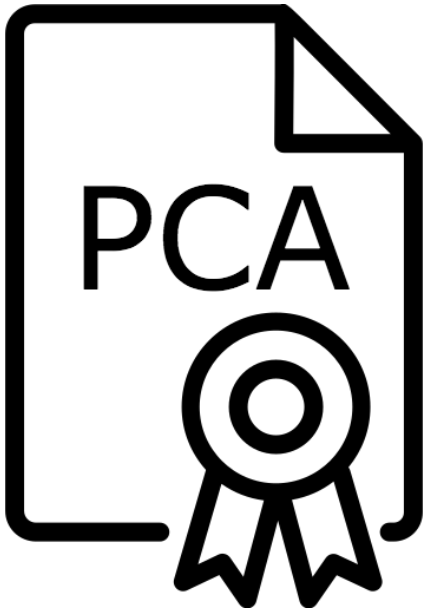
Verdadero o Falso

Contesta en el chat de Zoom

CODERHOUSE

¿Qué hacía el PCA?

- El método gira los datos de forma que, desde un punto de vista estadístico, no exista una correlación entre las características rotadas pero que **conserven la mayor cantidad posible de la varianza de los datos originales**.
- **Reduce la dimensionalidad** de un conjunto de datos proyectándose sobre un subespacio de menor dimensionalidad.



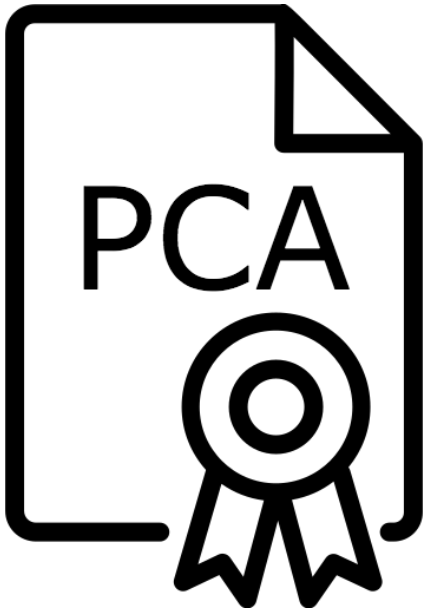
CODERHOUSE

Definición

CODERHOUSE

PCA (Principal Component Analysis)

Es una técnica utilizada para la identificación de un número más pequeño de variables no correlacionadas conocidas como componentes principales de un conjunto más grande de datos. Permite enfatizar la variación y capturar patrones fuertes en un conjunto de datos.



CODERHOUSE

Ejemplo aplicado

CODERHOUSE

PCA (Principal Component Analysis)

Es una técnica utilizada para la identificación de un número más pequeño de variables no correlacionadas conocidas como componentes principales de un conjunto más grande de datos. Permite enfatizar la variación y capturar patrones fuertes en un conjunto de datos.

	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1

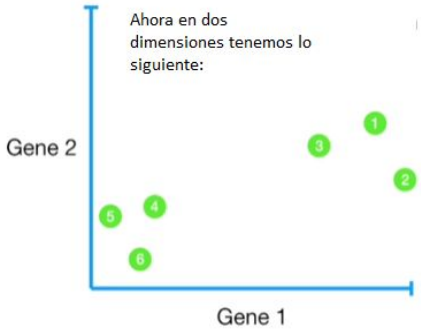


Imaginemos que tenemos el siguiente conjunto de datos que representa dos variables para 6 individuos (ratones). Si queremos representar a los individuos en una dimensión a traves de una variable podemos hacer una grafica com la de la derecha

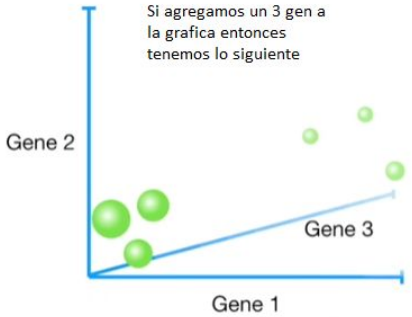
CODERHOUSE

PCA (Principal Component Analysis)

	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1



	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1
Gene 3	12	9	10	2.5	1.3	2

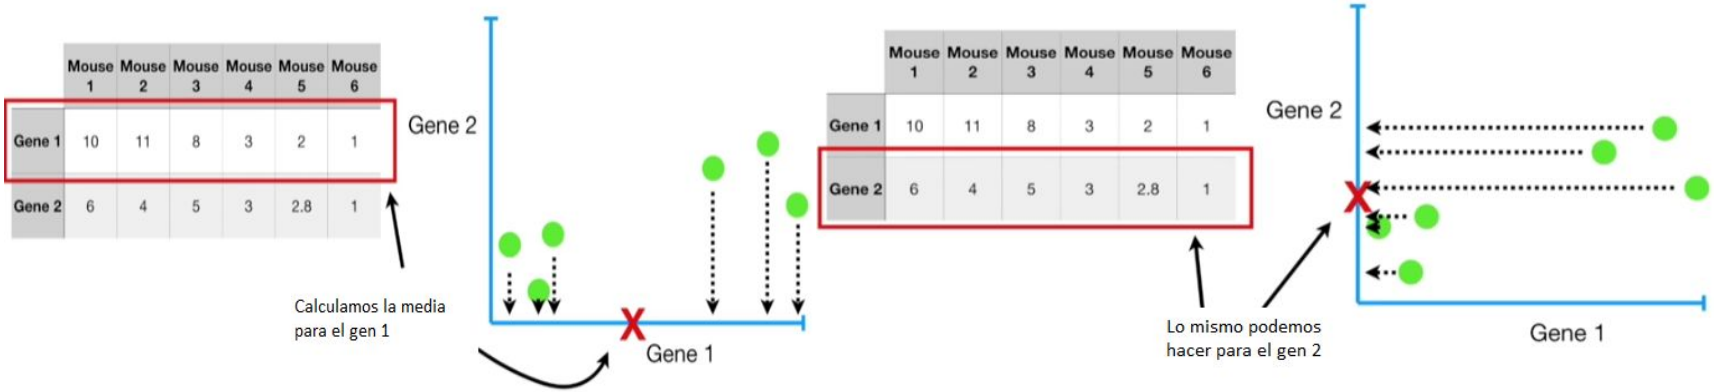


También podemos graficar dos dimensiones como se observa en la figura de arriba generando un diagrama de dispersión

Si agregamos una tercera variable podríamos hacer un gráfico 3D. Aunque si ponemos una cuarta dimensión el análisis ya no es tan sencillo

CODERHOUSE

PCA (Principal Component Analysis)



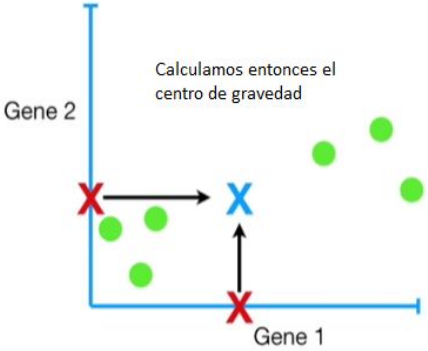
Si calculamos la media de la primera variable tenemos lo siguiente

De igual forma si calculamos la media de la segunda variable tenemos lo siguiente

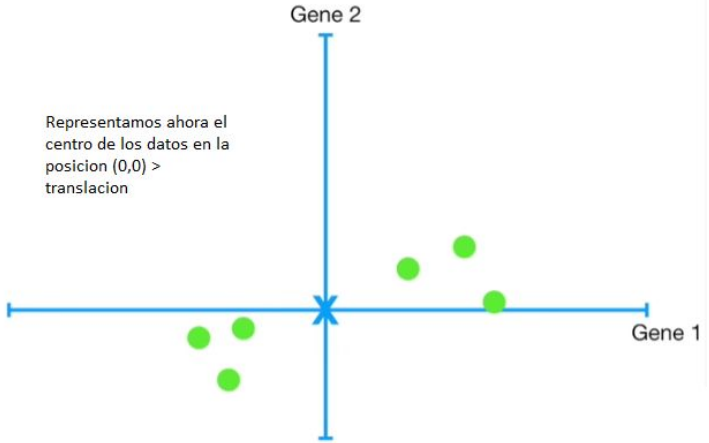
CODERHOUSE

PCA (Principal Component Analysis)

	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1



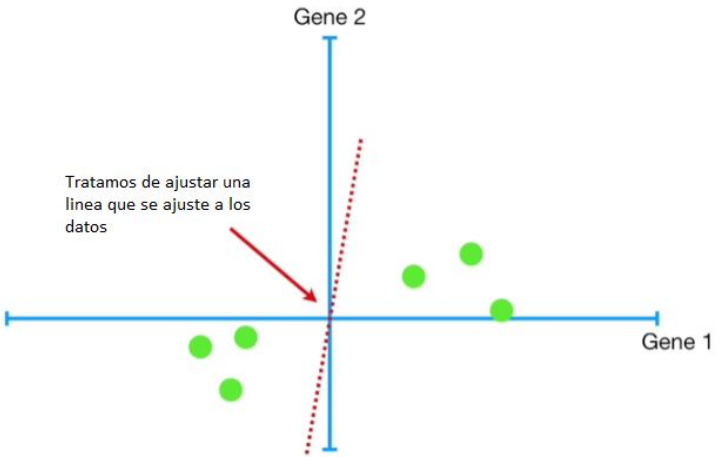
Si juntamos los dos punto tenemos el centro de gravedad o la media global de los individuos



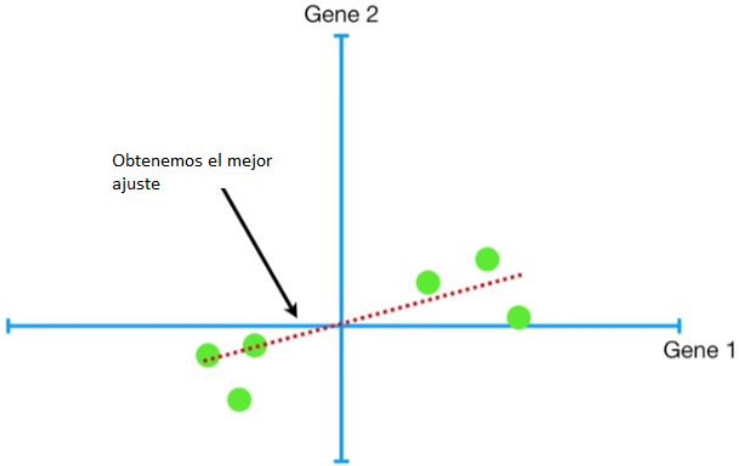
Si hacemos que este punto sea el nuevo centro (0,0) no afecta la posición relativa de los puntos

CODERHOUSE

PCA (Principal Component Analysis)



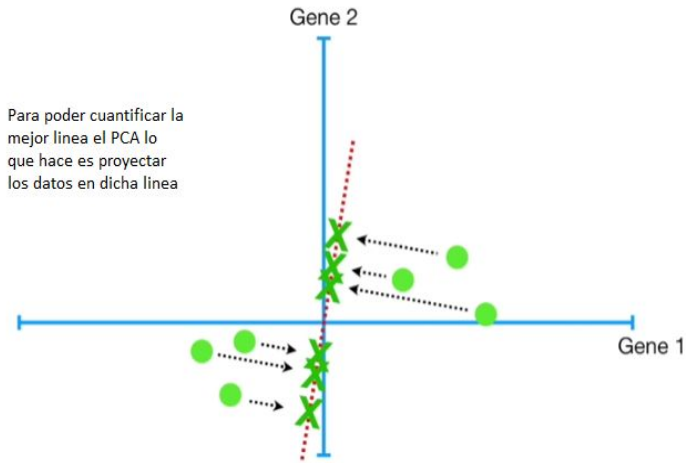
Podemos proceder a ajustar una línea que mejor se ajuste a los datos como en regresión



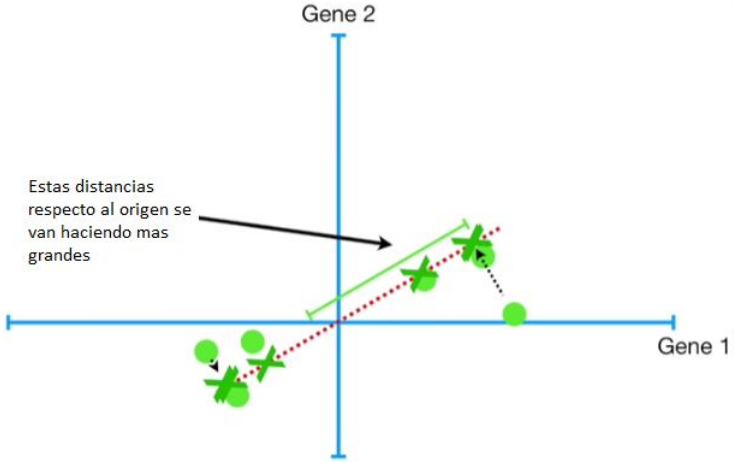
Y el resultado luego del ajuste es el siguiente

CODERHOUSE

PCA (Principal Component Analysis)



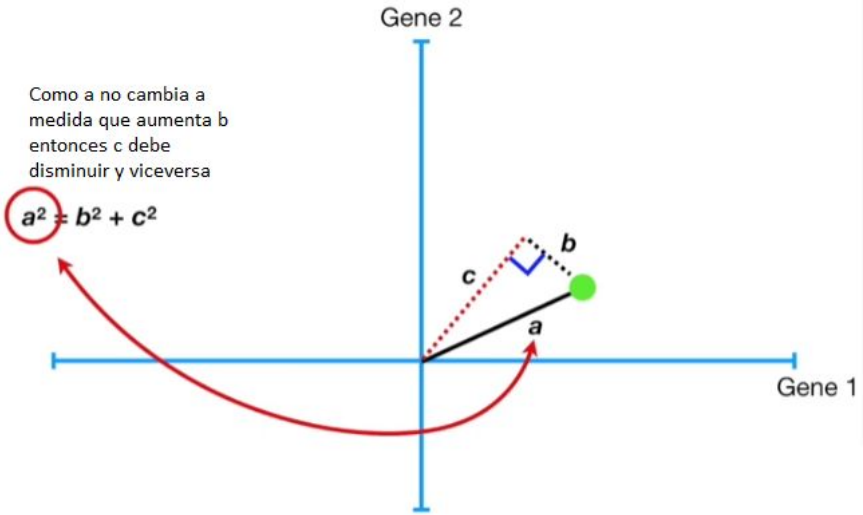
La medida de bondad de ajuste de la línea se hace proyectando cada individuo en la línea



De esta manera las distancia respecto al origen se maximizan

CODERHOUSE

PCA (Principal Component Analysis)

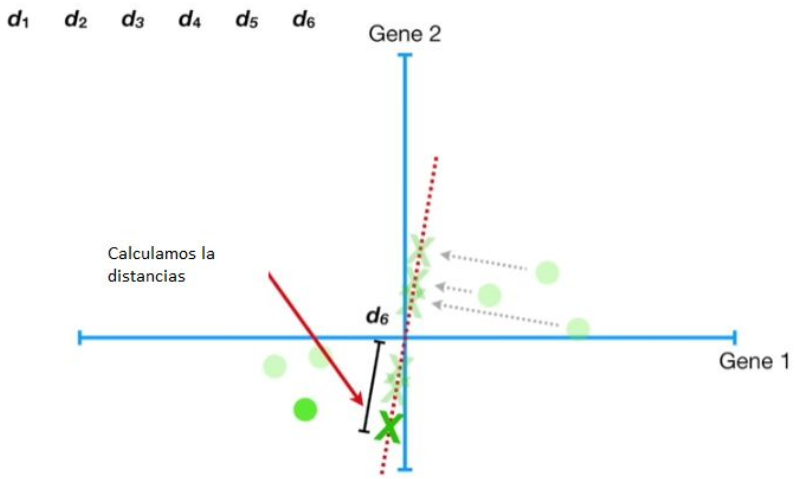


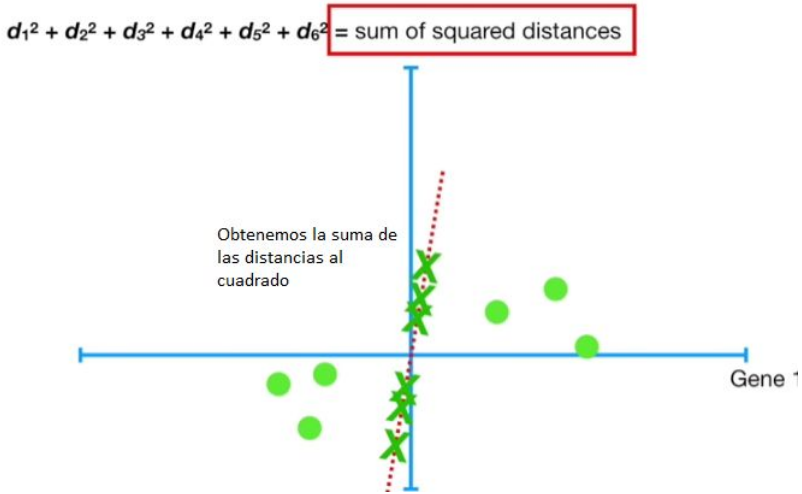
Entonces el PCA minimiza la distancia hasta la linea de proyeccion o maximiza la distancia del punto proyectado al origen

Aunque preferiblemente lo hace maximizando la distancia **c** en el triángulo

CODERHOUSE

PCA (Principal Component Analysis)

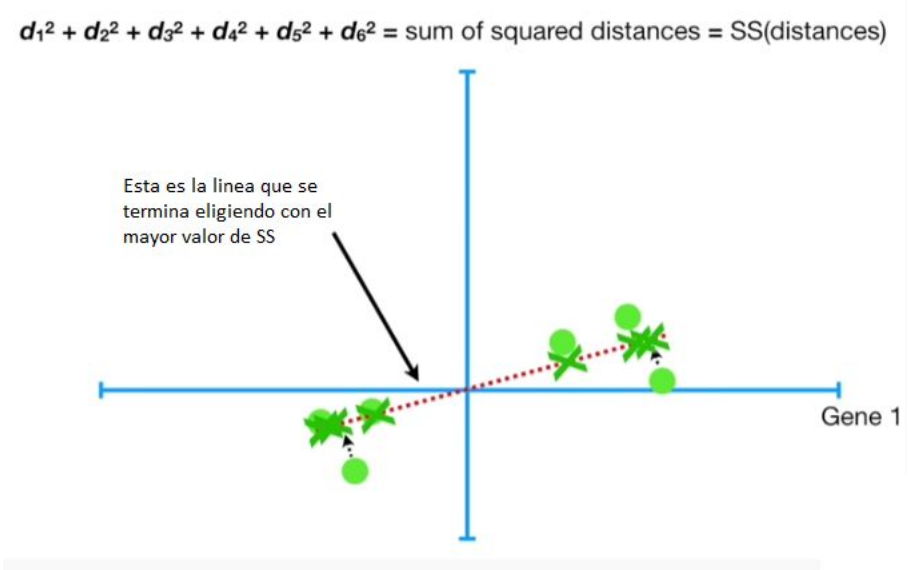




Así que de esta manera tenemos maximizadas las distancias hasta el origen y minimizadas las distancias de los puntos a la línea de proyección

CODERHOUSE

PCA (Principal Component Analysis)

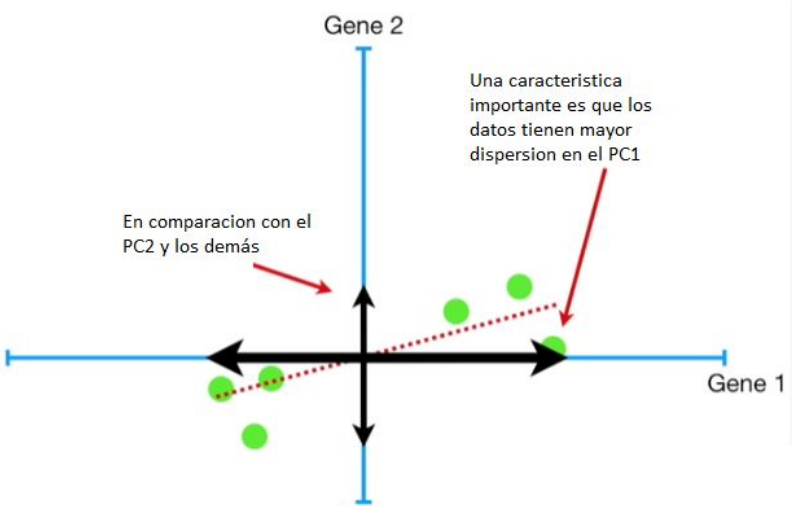


Esta línea se llama PC1 (si tiene una pendiente de 0.25 por ejemplo) por cada 4 unidades que aumente el gen 1 el gen 2 aumenta en 1 unidad

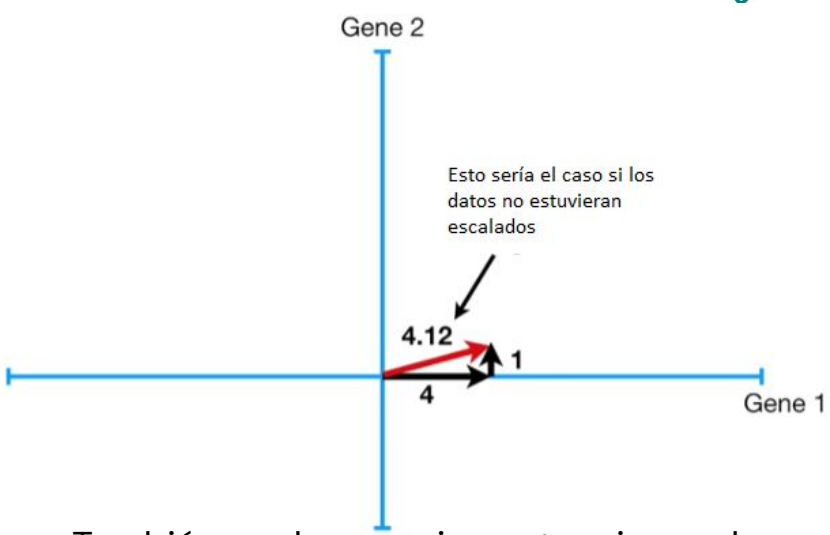
Por eso el PC1 así como los demás componentes principales on una combinación lineal de variables

CODERHOUSE

PCA (Principal Component Analysis)



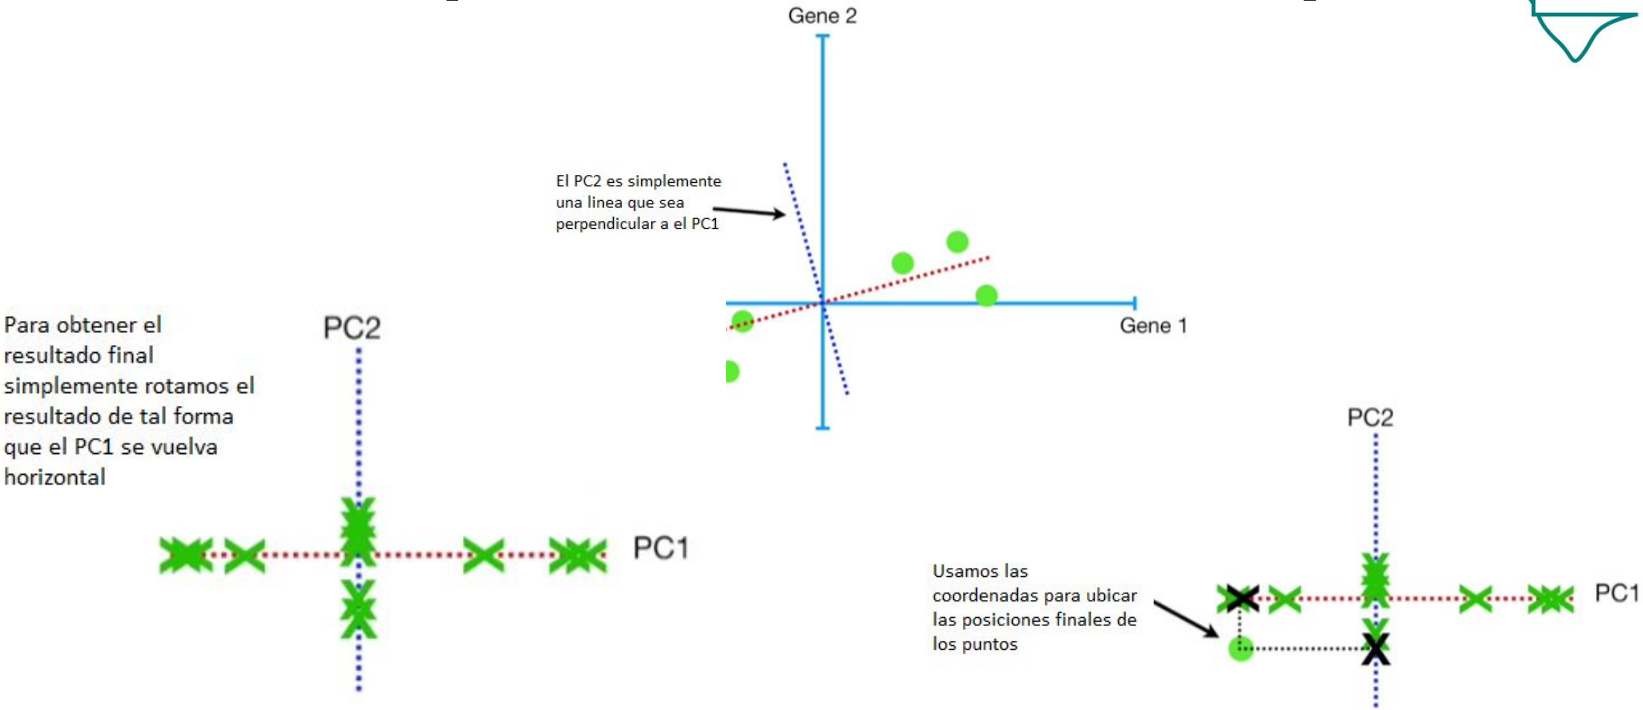
Una propiedad de este método es que el PC1 siempre recoge mayor porcentaje de variabilidad explicada



También es de suma importancia que los datos esten escalados o normalizados

CODERHOUSE

PCA (Principal Component Analysis)



CODERHOUSE

Reducción de dimensionalidad

CODERHOUSE



Para pensar

Si bien hemos visto que la Reducción de dimensionalidad es uno de los problemas que se pueden resolver con el aprendizaje no supervisado, ¿Han escuchado de algún otro método similar al PCA?

Contesta en el chat de Zoom

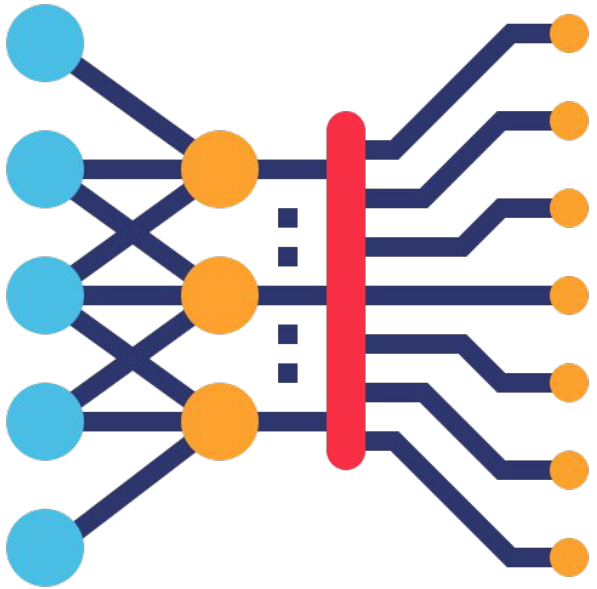
CODERHOUSE

Definición

CODERHOUSE

Reducción de dimensionalidad

Es una técnica de de aprendizaje no supervisado que consiste en la transformación de datos desde un espacio de alta dimensión a uno de baja dimensión para que la representación de baja dimensión retenga algunas propiedades significativas de los datos originales.



CODERHOUSE

Importancia

CODERHOUSE

Importancia

- Menor número de dimensiones implica menor tiempo de entrenamiento y menor recurso computacional y mayor performance
- Permite evitar el problema del overfitting
- Es extremadamente util para la tarea de “Data Visualization”



CODERHOUSE

Importancia

- Puede ser usado para comprimir imágenes con el fin de evitar consumir mucho espacio a la hora de generar algoritmos y entrenarlos
- Puede ser usado para transformar datos no lineales en una forma lineal separable (e.g Kernel PCA es una aplicación de este caso)



CODERHOUSE

Importancia

- Tiene en cuenta el problema de la multicolinealidad
- Es bastante útil para el análisis factorial (encontrar variables latentes que no se pueden medir directamente en una variable)
- Remueve el ruido en los datos quedándose con las variables más importantes



CODERHOUSE

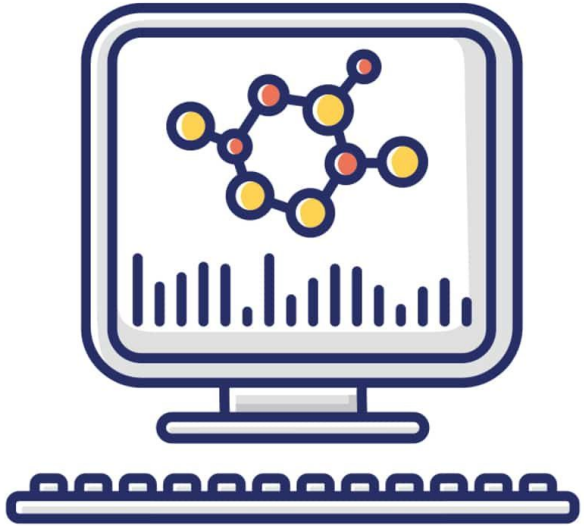
Clasificación

CODERHOUSE

Clasificación

Se tienen dos grandes categorías:

1. **Feature Selection:** tiene como objetivo encontrar un subconjunto de variables (las más importantes) de todas las variables. Tenemos 3 estrategias distintas (Filtro, Wrapper, Embedded)
2. **Feature Extraction:** extrae variables relevantes como combinación lineal de las variables originales con menor número de dimensiones



CODERHOUSE

Clasificación

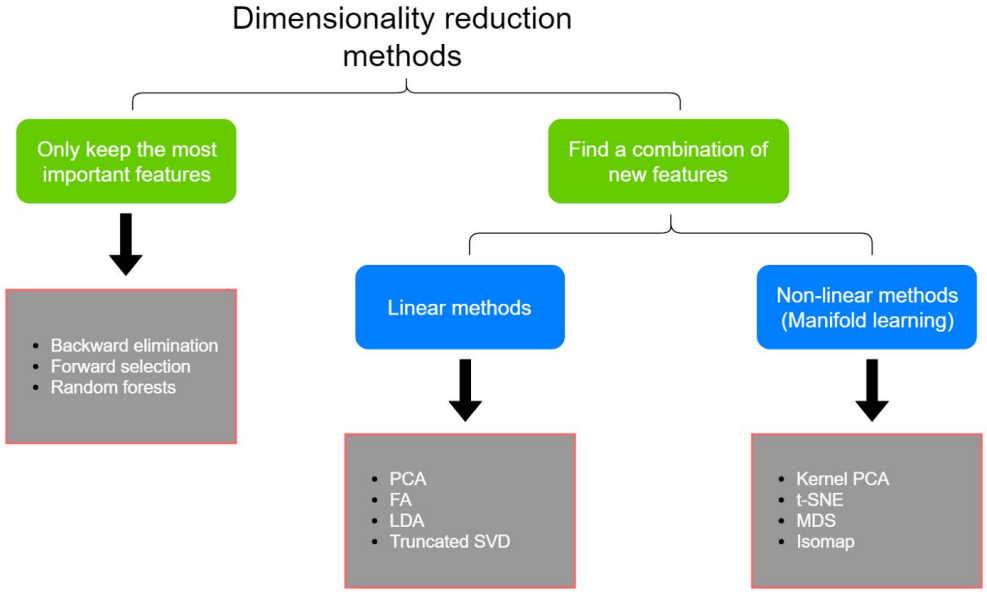


Image copyright: Rukshan Pramoditha

La metodología Feature Extraction también tiene una clasificación adicional ya que se pueden utilizar técnicas lineales o no lineales)Manifold) para encontrar las mejores combinaciones

Fuente: Clasificación Reducción Dimensionalidad

Principales técnicas

CODERHOUSE

Principales técnicas

Algunas de las principales técnicas más aplicadas son:

1. Principal Component Analysis (PCA)
2. Análisis Factorial
3. Análisis Discriminante
4. Kernel PCA
5. t-SNE (t-distributed Stochastic Neighbor Embedding)
6. Escalamiento multidimensional (MDS)
7. Isomap (Isometric mapping)

Exploraremos algunas técnicas distintas del PCA



CODERHOUSE

Análisis factorial

Este método no solo busca reducir la dimensionalidad como el PCA, sino que también permite encontrar variables latentes que no se pueden medir directamente con una sola variable, estas variables latentes se les llama **factores**.

Es una tecnica principalmente estadística que busca explicar las correlaciones entre las variables en términos de un menor número de variables

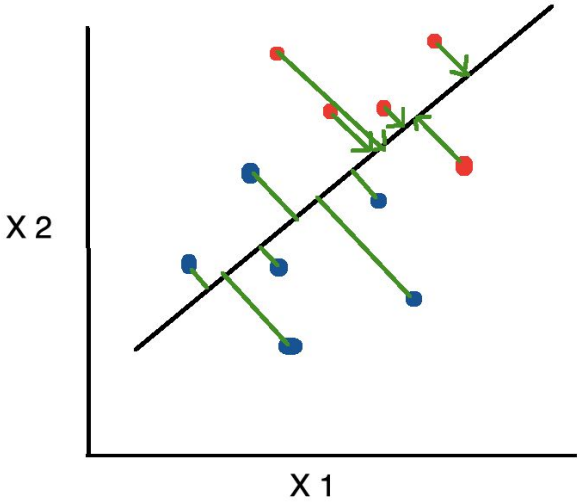


CODERHOUSE

Análisis Discriminante

Conocido como LDA se usa para problemas de clasificación multi clase usualmente. Esta técnica separa o discrimina las instancias por sus clases. A diferencia del PCA el LDA encuentra una combinación lineal de variables que optimice la separación de clases mientras que el PCA trata de encontrar componentes no correlacionados.

Otra diferencia es que el PCA es un algoritmo no supervisado mientras que el LDA es supervisado



CODERHOUSE

Kernel PCA

Es una técnica de reducción de dimensionalidad no lineal que utiliza diferentes **funciones kernel (Radial basis-function kernel)** y es la versión no lineal del PCA. Funciona bastante bien en datasets no lineales donde el PCA normal no funciona eficientemente

Se necesitan especificar 3 hiper parámetros importantes: a) componentes a retener, b) tipo de kernel (linear, poly, rbf, sigmoid, cosine) y c) coeficiente kernel llamado gamma



CODERHOUSE

t-SNE

Es una técnica de reducción de dimensionalidad no lineal que principalmente se usa para “Data Visualization”.

Se basa en técnicas probabilísticas sobre parejas de muestras en el espacio original

Se recomienda utilizar ya sea PCA o descomposicion SVD truncada antes de t-SNE si el numero de variables es mayor a 50.



CODERHOUSE

Escalamiento multidimensional

MDS es una técnica de reducción de dimensionalidad no lineal que trata de preservar las distancias entre las instancias mientras reduce la dimensionalidad de los datos no lineales.

Existen dos tipos de algoritmos de MDS con métrica y sin métrica. Dentro de la clase MDS() de Scikit Learn e puede definir cuál de las dos se desea utilizar

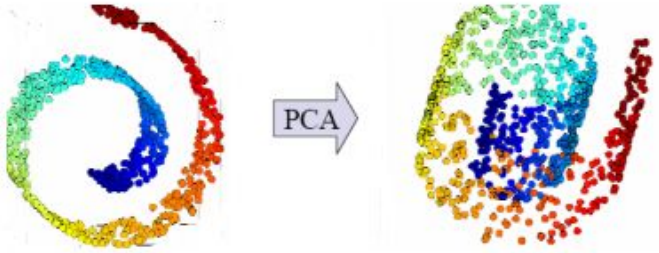


CODERHOUSE

Isomap

Es una técnica de reducción de dimensionalidad no lineal que funciona como una extensión del MDS o del Kernel PCA. Conecta cada instancia calculando una distancia curva o geodésica con base a los vecinos más cercanos.

El número de vecinos a considerar para cada punto se puede específicas con n_neighbors dentro de la clase Isomap



CODERHOUSE

Detección de Outliers

CODERHOUSE



Para pensar

Como hemos visto en clases anteriores los outliers son un problema bastante común en cualquier tipo de datos, ¿Conocen algún método que permita encontrarlos de manera automática? ¿Podríamos utilizar métodos automáticos para detectarlos?

Contesta en el chat de Zoom

CODERHOUSE

Definición

CODERHOUSE

Definición

Se define como el proceso de detectar y excluir outliers de un dataset dado. Recordemos que un outlier es una observación que difiere drásticamente de los demás datos. Existen diversas técnicas estadísticas y de aprendizaje automático para poder detectarlos



CODERHOUSE

Clasificación

CODERHOUSE

Definición

Existen diversas técnicas de las cuales podemos resaltar:

1. Isolation Forest
2. Minimum Covariance Determinant
3. Local Outlier Factor (LOF)
4. One Class SVM

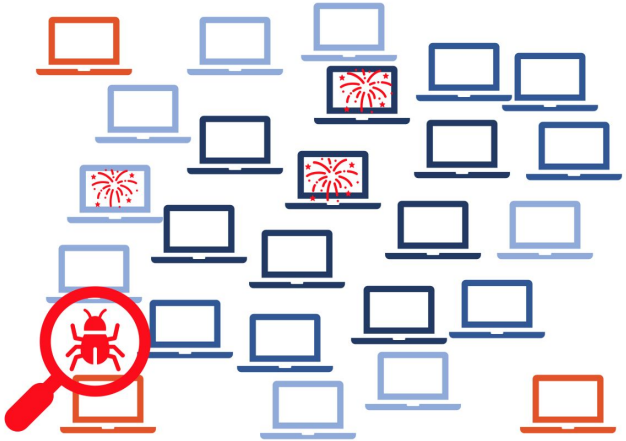


CODERHOUSE

Isolation Forest



Es un algoritmo de detección de anomalías, el proceso de detección lo realiza por medio de aislamiento (isolation). Fue desarrollado por Fei Tony Liu en 2007 en sus estudios de doctorado.



Es un método no supervisado (sin etiquetas). Eta inspirado en algoritmo de clasificación Random Forest, formado por la combinación de múltiples arboles de decision llamados isolation trees

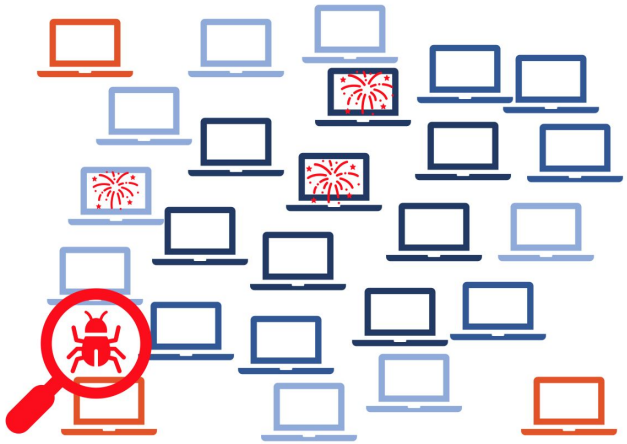
CODERHOUSE

Isolation Forest



El método toma ventaja de dos propiedades cuantitativas de las anomalías:

1) Son una minoría de todas las instancias
2) Tienen atributos bastante diferentes a las instancias normales

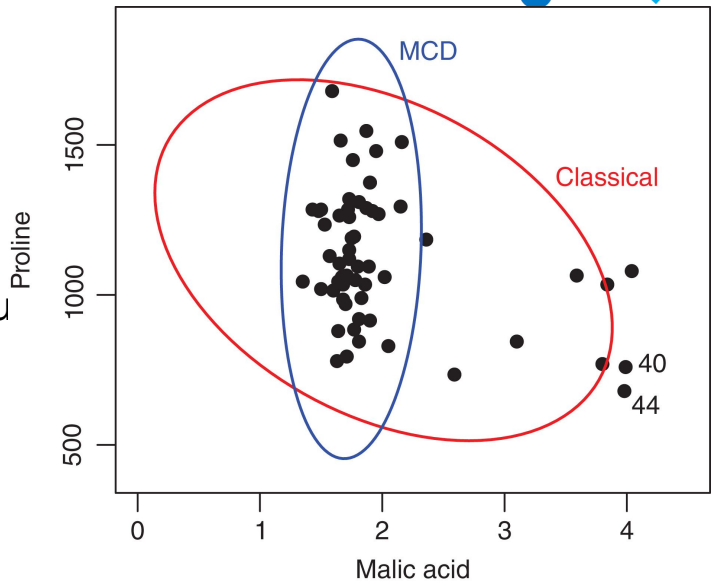


A la hora de implementar el algoritmo es importante tener en cuenta el hiper parámetro llamado contaminación que se encuentra entre 0 0.5 por defecto es 0.1

CODERHOUSE

Minimum Covariance Determinant

Llamado MCD por sus siglas en inglés. Es un algoritmo de detección de anomalías bastante robusto teniendo en cuenta estructuras multivariadas creando estructuras elipsoidales qu siguen la distribución normal multivariada. Todas las observaciones que queden por fuera de la elipsoide se consideran como anomalías/outliers

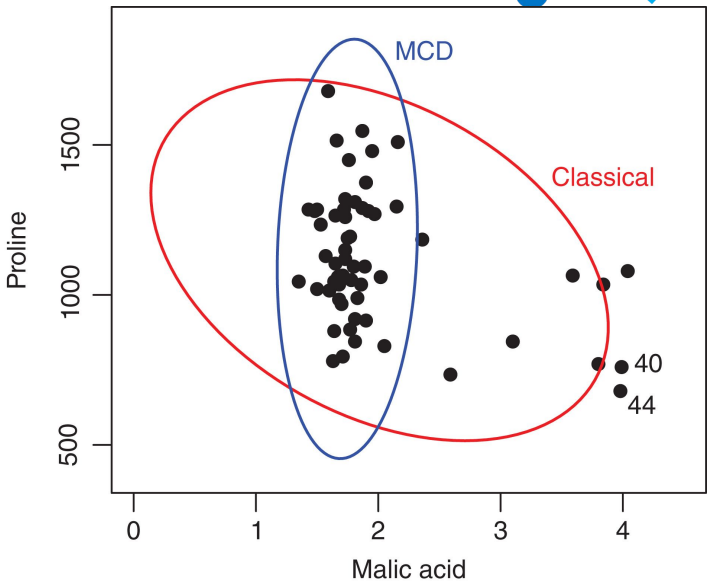


CODERHOUSE

Minimum Covariance Determinant

Su objetivo principal es encontrar observaciones (de un total de n) en las cuales la matriz de covarianza tiene el determinante más bajo.

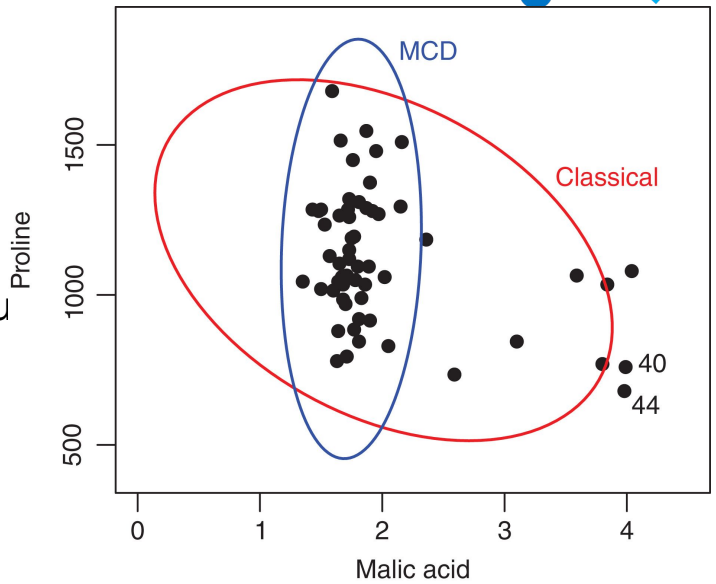
El parámetro “contamination” se define como la proporción de outliers y se puede encontrar el valor óptimo con prueba y error o con algun metodo de busqueda de hiper parámetros



CODERHOUSE

Minimum Covariance Determinant

Llamado MCD por sus siglas en inglés. Es un algoritmo de detección de anomalías bastante robusto teniendo en cuenta estructuras multivariadas creando estructuras elipsoidales qu siguen la distribución normal multivariada. Todas las observaciones que queden por fuera de la elipsoide se consideran como anomalías/outliers

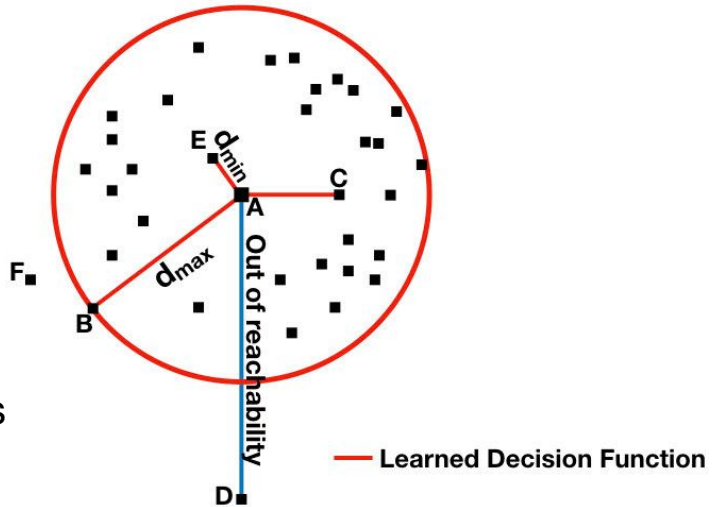


CODERHOUSE

Local Outlier Factor (LOF)



Es una técnica que intenta aprovechar la idea de los vecinos más cercanos para la detección de valores atípicos. A cada instancia se le asigna una puntuación de qué tan aislado (probabilidad de ser atípico) en función del tamaño de su vecindario más cercano. Es más probable que las instancias con la puntuación más alta sean valores atípicos. El parámetro “contamination” representa la proporción de nulos por defecto es 0.1.

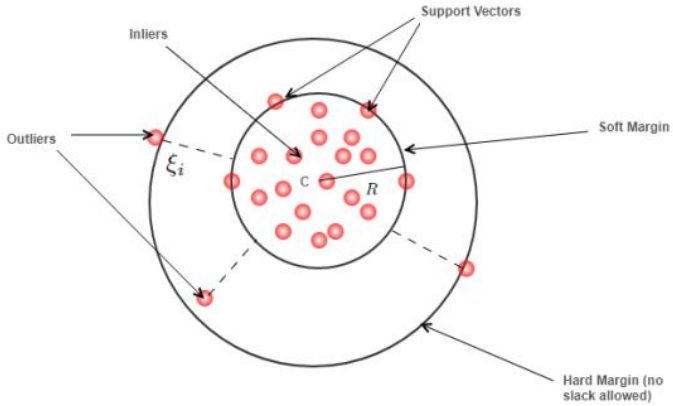


CODERHOUSE

One-Class SVM

Aunque el SVM se desarrolló inicialmente para clasificación binaria se puede usar también para clasificación con una sola clase. Cuando se modela una clase el algoritmo captura la densidad de la clase mayoritaria y clasifica las instancias en los extremos de la función de densidad como outliers.

El One-Class SVM es un algoritmo de clasificación aunque puede ser usado para detectar outliers en datos de entrada para regresión o clasificación



CODERHOUSE



Para pensar

¿El SVM encuentra el hiperplano que maximiza el margen de separación entre clases ?

Verdadero o Falso

Contesta la encuesta de Zoom

CODERHOUSE

Importante...



Si bien existen diversos métodos que funcionan de manera automática para la detección de outliers no siempre todos son eficientes a la hora de encontrarlos, es por ello que se recomienda aplicar diferentes métodos y seleccionar el mejor que se ajuste al contexto de los datos analizados.

CODERHOUSE

¿Preguntas?

CODERHOUSE

Glosario

PCA: técnica utilizada para la identificación de un número más pequeño de variables no correlacionadas conocidas como componentes principales de un conjunto más grande de datos.

Reducción de dimensionalidad: técnica de aprendizaje no supervisado que consiste en la transformación de datos desde un espacio de alta dimensión a uno de baja dimensión para que la representación de baja dimensión retenga algunas propiedades significativas de los datos originales.

Detección de outliers: proceso de detectar y excluir outliers de un dataset dado. Recordemos que un outlier es una observación que difiere drásticamente de los demás datos. Existen diversas técnicas estadísticas y de aprendizaje automático para poder detectarlos. Existen diversas técnicas como: Isolation Forest, Minimum Covariance Determinant, Local Outlier Factor (LOF) y One-Class SVM

CODERHOUSE