DATA SCIENCE

Selección del algoritmo y Entrenamiento del Modelo I

CODERHOUSE

Temario

Algoritmos de Agrupación II

- ✓ PCA
- ✓ Reducción de Dimensionalidad
- ✓ Detección de outliers

Selección de Algoritmo y entrenamiento del Modelo I

- ✓ Matriz de confusión
- ✓ Accuracy
- ✓ Precisión
- ✓ Sensibilidad
- ✓ Especificidad
- ✓ F1 Score y curva ROC

Selección de Algoritmo y Entrenamiento del Modelo II

- ✓ Métricas y evaluación de modelos
- ✓ RMSE
- ✓ MAE
- ✓ R2

CODERHOUSE

Objetivos de la clase

- **Evaluar** métricas de modelos de Clasificación

CODERHOUSE

MAPA DE CONCEPTOS



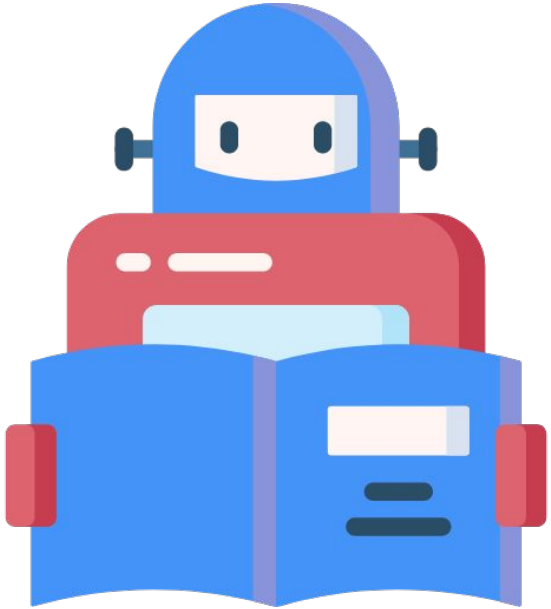
CODERHOUSE

Matriz de confusión y sus métricas

CODERHOUSE

Para qué servía la matriz de confusión

- Es una herramienta que nos permitía visualizar el desempeño de algoritmos de Aprendizaje Supervisado - Clasificación
- Con ella podíamos cuantificar que tantas predicciones correctas/incorrectas resultaban luego de aplicar el algoritmo de Clasificación
- Se puede aplicar para problemas de clasificación Binaria y multiclase



CODERHOUSE

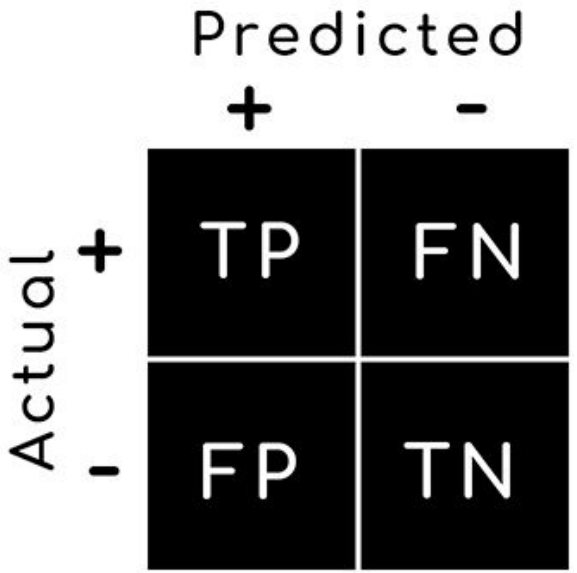
Definición

CODERHOUSE

Matriz de confusión

Es una técnica para resumir el desempeño de un algoritmo de clasificación. El accuracy de la clasificación por sí sola puede ser engañosa si tiene un número desigual de observaciones en cada clase o si tiene más de dos clases

Esta técnica puede dar una mejor idea de qué está haciendo bien el modelo de clasificación y qué tipos de errores está cometiendo.



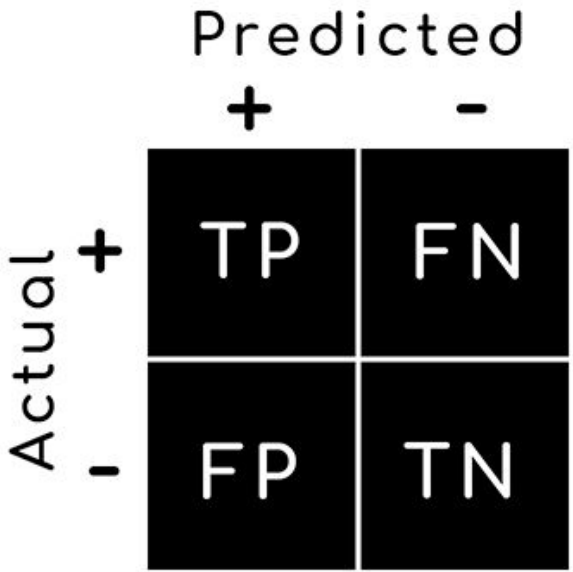
CODERHOUSE

Cómo calcular la matriz de confusión

CODERHOUSE

Cómo calcular la matriz de confusión

1. Se necesita de un dataset de test o validación con los valores esperados
2. Realizar la predicción para cada fila del dataset test
3. Del conteo de valores esperados y predicciones se encuentra:
   a. El número de predicciones correctas
   b. El número de predicciones incorrectas para cada clase



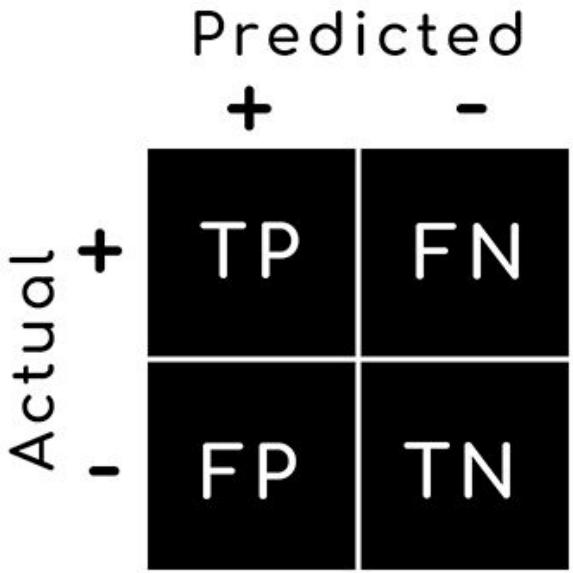
CODERHOUSE

Cómo calcular la matriz de confusión

Estos números se organizan en una tabla o matriz de la siguiente manera:

a. Valores esperados: en cada fila de la matriz.
b. Predicciones: cada columna de la matriz.

En la diagonal principal de la matriz tenemos las predicciones correctas (TP=True Positives y TN=True Negatives) y por fuera quedan las predicciones incorrectas (FP= False Positive y FN= False Negatives)

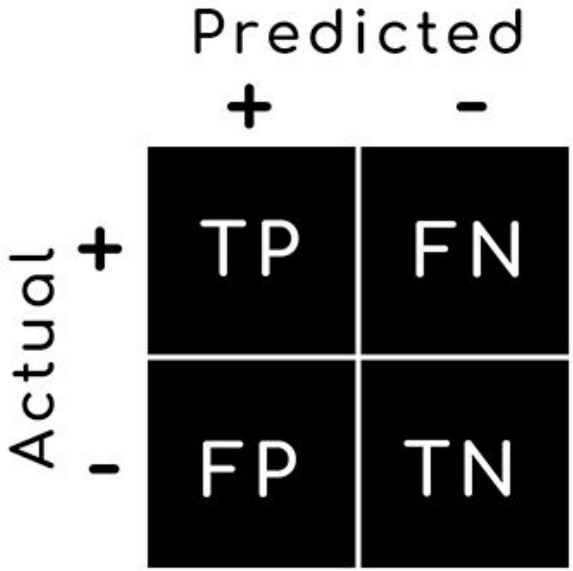


CODERHOUSE

Cómo calcular la matriz de confusión

Dentro de la matriz debemos definir las siguientes cantidades en el caso de un problema binario:

a. **verdadero positivo (TP):** eventos predichos correctamente.
b. **"falso positivo" (FP):** eventos pronosticados incorrectamente **(Error Tipo I)**.
c. **"verdadero negativo" (TN):** sin eventos predichos correctamente.
d. **"falso negativo" (FN):** sin eventos pronosticados incorrectamente **(Error Tipo II)**.

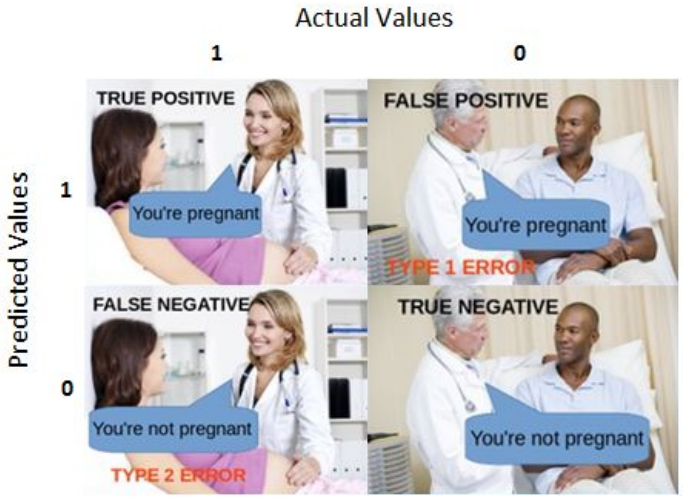


CODERHOUSE

Cómo calcular la matriz de confusión

Los **Falsos Positivos (FP) – Error Tipo I** son predicciones que tienen la característica cuando no es cierto, por ejemplo **predecir que un hombre está embarazado cuando es falso**

Los **Falsos Negativos (FN) - Error Tipo II** son predicciones que NO tienen la característica pero realmente si la tienen, por ejemplo **predecir que una mujer no está embarazada cuando realmente lo está.**



CODERHOUSE



Para pensar

Para las siguientes situaciones pensemos si serían Falso Positivo o Falso Negativo

- ✔ Una prueba de detección de cáncer da positivo, pero usted no tiene la enfermedad.
- ✔ Un algoritmo dice que una persona no cometerá fraude, pero logró cometer fraude la semana pasada

Contesta en el chat de Zoom

CODERHOUSE



Para pensar

Para estos casos las respuestas son

- ✔ Una prueba de detección de cáncer da positivo, pero usted no tiene la enfermedad **(Falso Positivo: predicción +, valor real –)**.
- ✔ Un algoritmo dice que una persona no cometerá fraude, pero logró cometer fraude la semana pasada **(Falso Negativo: predicción –, valor real +)**

Contesta en el chat de Zoom

CODERHOUSE

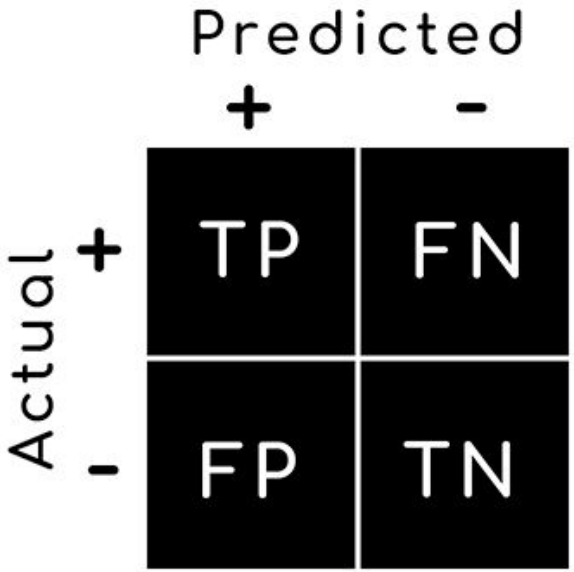
Accuracy

CODERHOUSE

Accuracy

Es una métrica que resume el rendimiento de un modelo de clasificación como el número de predicciones correctas dividido por el número total de predicciones. Se puede dar como porcentaje o fracción.

$$\textit{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$



CODERHOUSE

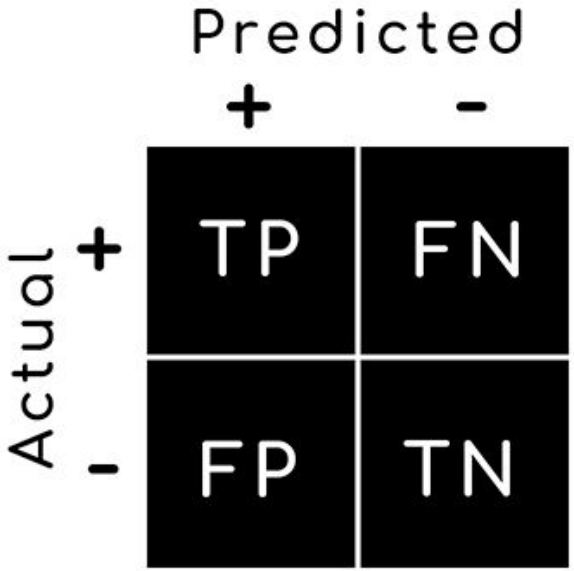
Precisión

CODERHOUSE

Precisión

Es una métrica que resume el rendimiento de un modelo de clasificación cuando se tienen dos clases con tamaño desigual, se calcula como el número de verdaderos positivos dividido por el número total de verdaderos positivos y falsos positivos.

$$\text{Precision} = \frac{True\ Positive}{True\ Positive + False\ Positive}$$



CODERHOUSE

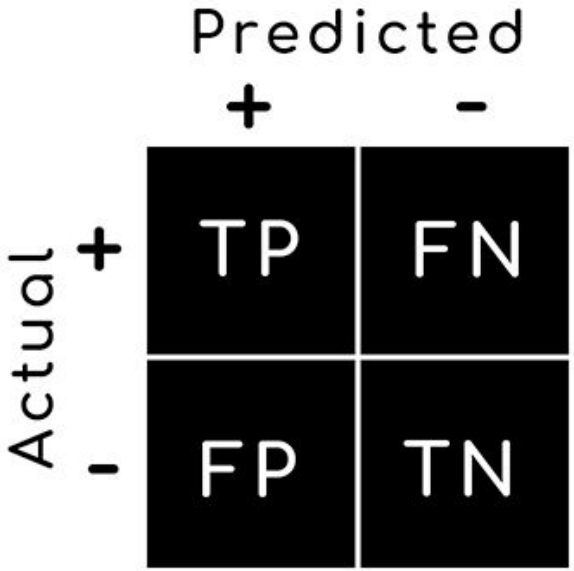
Sensibilidad

CODERHOUSE

Sensibilidad

Es una métrica que resume el rendimiento de un modelo de clasificación cuando se tienen dos clases con tamaño desigual, a diferencia de la Precisión en lugar de observar la cantidad de falsos positivos, analiza la cantidad de falsos negativos

$$\text{Recall} = \frac{True\ Positive}{True\ Positive + False\ Negative}$$



CODERHOUSE

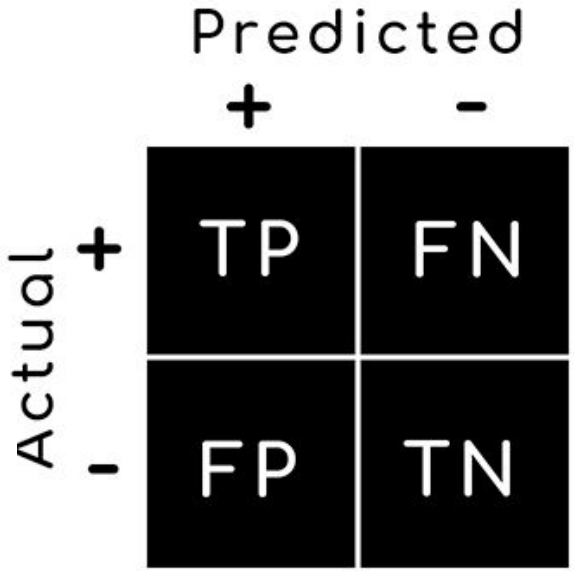
Especificidad

CODERHOUSE

Especificidad

Es una métrica que resume el rendimiento de un modelo de clasificación cuando se tienen dos clases con tamaño desigual, se calcula como el número de predicciones negativas correctas dividido por el número total de negativos. También se llama tasa de verdaderos negativos (TNR)

$$\text{Specificity} = \frac{\text{True Negatives}}{\text{True Negatives} + \text{False Positives}}$$



CODERHOUSE

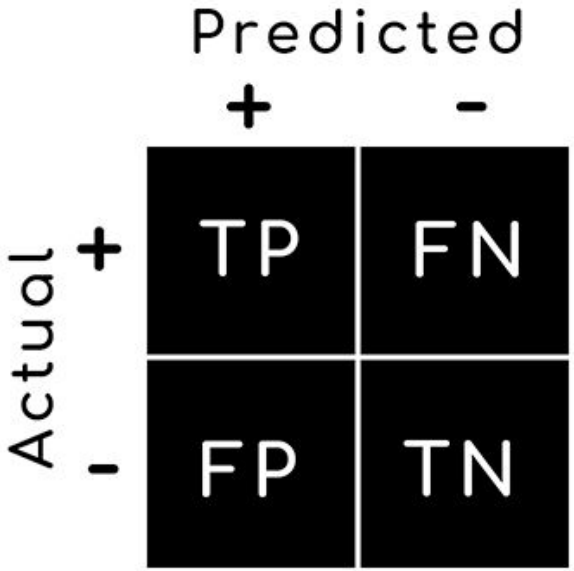
F1 Score

CODERHOUSE

F1 Score

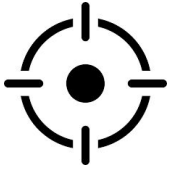
La puntuación F1 es una métrica que tiene en cuenta tanto la precisión y el recall (sensibilidad). Solo es 1 cuando la precisión y la sensibilidad son 1 ambas, también se entiende como la media armónica de la precisión y la sensibilidad. Se define de la siguiente manera

$$F1\ Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$



CODERHOUSE

Resumen



Métricas de evaluación en clasificación

Las métricas nos ayudan a entender qué tan bien (o mal) está funcionando nuestro modelo. Cada una responde una pregunta distinta.

No existe una métrica perfecta para todos los casos. Hay que elegir la que mejor se adapte al objetivo del problema.

Accuracy

¿Qué proporción del total de casos clasifiqué correctamente?

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Caso de uso

Útil cuando las clases están balanceadas (tienen una cantidad similar de ejemplos).

Precisión

De los casos que predecí como positivos, ¿cuántos eran realmente positivos?

$$\text{Precisión} = \frac{TP}{TP + FP}$$

Caso de uso

Útil cuando queremos evitar falsas alarmas, por ejemplo, en la detección de fraudes.

Sensibilidad (Recall)

De los positivos reales, ¿cuántos logré detectar?

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

Caso de uso

Útil cuando no queremos dejar pasar los casos positivos, por ejemplo, en la detección de enfermedades.

Especificidad

De los negativos reales, ¿cuántos reconocí correctamente?

$$\text{Especificidad} = \frac{TN}{TN + FP}$$

Caso de uso

Útil cuando queremos identificar bien los casos negativos, por ejemplo, para evitar falsos positivos en una prueba médica.

F1 Score

¿Cómo se combinan la precisión y la sensibilidad?

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

Caso de uso

Útil cuando buscamos un equilibrio entre evitar falsas alarmas y no perder positivos reales.

AUC - ROC

¿Qué capacidad tiene el modelo para distinguir las clases a través de distintos umbrales?

$$\text{AUC} = \text{Área bajo la curva ROC}$$

Caso de uso

Útil para comparar modelos y entender su desempeño en diferentes umbrales de decisión.

Ejemplo común para todas las métricas

		Predicción: Positivo	Predicción: Negativo
Valor real	Positivo	TP (100)	FN (20)
	Negativo	FP (10)	TN (70)

Caso de uso (aplicable a todas las métricas)

Imaginemos un modelo que predice si un cliente va a comprar un producto (sí/no).

- **TP:** cliente que compra y el modelo predice que compra.
- **FP:** cliente que no compra, pero el modelo predice que sí.
- **TN:** cliente que no compra y el modelo predice que no.
- **FN:** cliente que compra, pero el modelo predice que no.

En resumen...

Estas métricas nos dan diferentes perspectivas del mismo problema. La clave está en entender qué pregunta responde cada una y elegir la más adecuada según el objetivo de nuestro modelo y el contexto del negocio.

CODERHOUSE

Métricas de evaluación en clasificación

Cada métrica nos da una mirada distinta del modelo. No existe una única "mejor" métrica, sino que depende del objetivo y del tipo de problema que estemos resolviendo.

Métrica	¿Qué mide?	Fórmula	¿Cuándo es útil?	Ejemplo (caso de uso común)
Accuracy	Proporción de predicciones correctas sobre el total.	$\frac{TP + TN}{TP + TN + FP + FN}$	Cuando las clases están balanceadas y los errores tienen un costo similar.	Clasificar correos como spam o no spam, cuando hay una cantidad similar de ambos.
Precisión	De los casos que predijo como positivos, ¿cuántos eran realmente positivos?	$\frac{TP}{TP + FP}$	Cuando queremos evitar falsas alarmas.	Detectar transacciones fraudulentas, para no bloquear por error operaciones legítimas.
Sensibilidad (Recall)	De los positivos reales, ¿cuántos logró detectar?	$\frac{TP}{TP + FN}$	Cuando los falsos negativos son especialmente costosos.	Detección de enfermedades, para no dejar pasar casos reales.
Especificidad	De los negativos reales, ¿cuántos reconoció correctamente?	$\frac{TN}{TN + FP}$	Cuando los falsos positivos son problemáticos.	Filtrado de contenido, para no marcar como spam mensajes legítimos.
F1 Score	Equilibrio entre precisión y sensibilidad.	$\frac{2 \cdot (\text{Precisión} \cdot \text{Sensibilidad})}{\text{Precisión} + \text{Sensibilidad}}$	Cuando las clases están desequilibradas o querés considerar ambas métricas.	Detección de fraude o clasificación de clases con baja frecuencia.
AUC - ROC	Capacidad del modelo para distinguir entre las clases a través de distintos umbrales.	Área bajo la curva ROC (0,5 = azar / 1 = perfecto)	Cuando querés comparar modelos y analizar su comportamiento a distintos umbrales.	Diagnóstico médico, donde se necesita evaluar diferentes niveles de decisión.

Ejemplo práctico (mismo caso para todas las métricas)

Supongamos que queremos predecir si un cliente va a comprar un producto (clase positiva = compra). Luego de entrenar y evaluar el modelo, obtenemos la siguiente matriz de confusión:

		Predicción: Positivo	Predicción: Negativo
Valor real	Positivo	TP (100)	FN (20)
	Negativo	FP (10)	TN (70)

Total:

- Positivos reales: 120 (100 + 20)
- Negativos reales: 80 (10 + 70)
- Total de casos: 200

Con estos valores podemos calcular cada una de las métricas y entender cómo se comporta el modelo.

CODERHOUSE

¿Qué nos dice cada métrica?

Ejemplo: predecir si un cliente compra

ACCURACY
Exactitud



$$\frac{TP + TN}{Total}$$

¿Qué proporción de todas las predicciones fue correcta?

8 de 10 predicciones correctas

PRECISIÓN



$$\frac{TP}{TP + FP}$$

De los clientes que el modelo predijo que comprarían, ¿cuántos compraron realmente?

4 de 5 fueron correctos

SENSIBILIDAD (RECALL)



$$\frac{TP}{TP + FN}$$

De los clientes que realmente compraron, ¿a cuántos detectó el modelo?

4 de 5 fueron detectados

ESPECIFICIDAD



$$\frac{TN}{TN + FP}$$

De los clientes que realmente no compraron, ¿a cuántos identificó correctamente?

4 de 5 fueron correctos

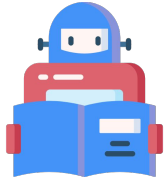
La misma predicción puede evaluarse con distintas métricas: **cada una responde una pregunta diferente.**

CODERHOUSE

Ejemplo aplicado

CODERHOUSE

Ejemplo aplicado

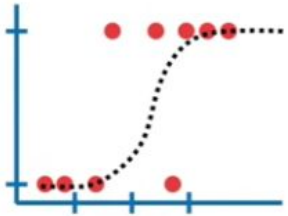


Imaginen que tenemos estos datos

Chest Pain	Good Blood Circ.	Blocked Arteries	Weight	Heart Disease
No	No	No	125	No
Yes	Yes	Yes	180	Yes
Yes	Yes	No	210	No
...	...	...	...	...

En este caso pudiéramos usar cualquiera de estos métodos

Regresion Logistica



KNN



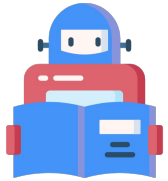
Random Forest



O tambien pudieramos usar el SVM o un arbol de decision

CODERHOUSE

Ejemplo aplicado

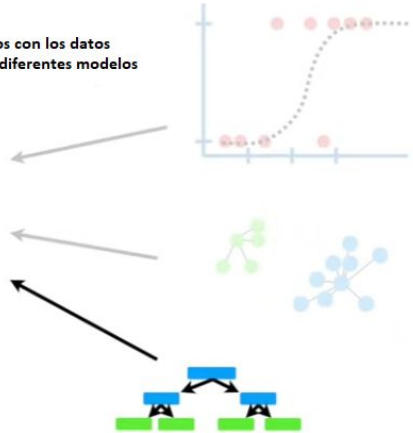


Separamos train/test

Chest Pain	Good Blood Circ.	Blocked Arteries	Weight	Heart Disease
No	No	No	125	No
...	Training Data			...

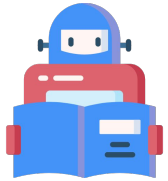
Chest Pain	Good Blood Circ.	Blocked Arteries	Weight	Heart Disease
Yes	Yes	No	210	No
...	Testing Data			...

Entrenamos con los datos train bajo diferentes modelos



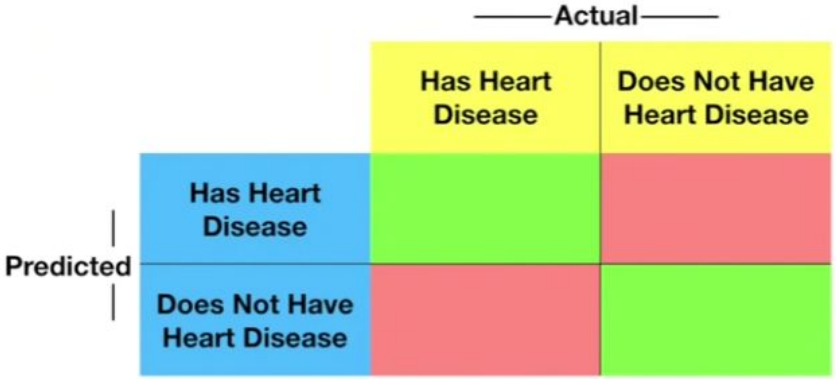
CODERHOUSE

Ejemplo aplicado



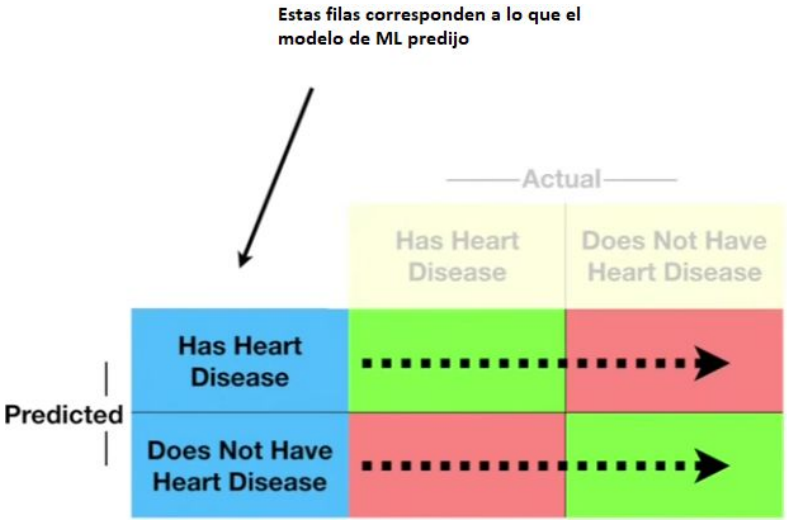


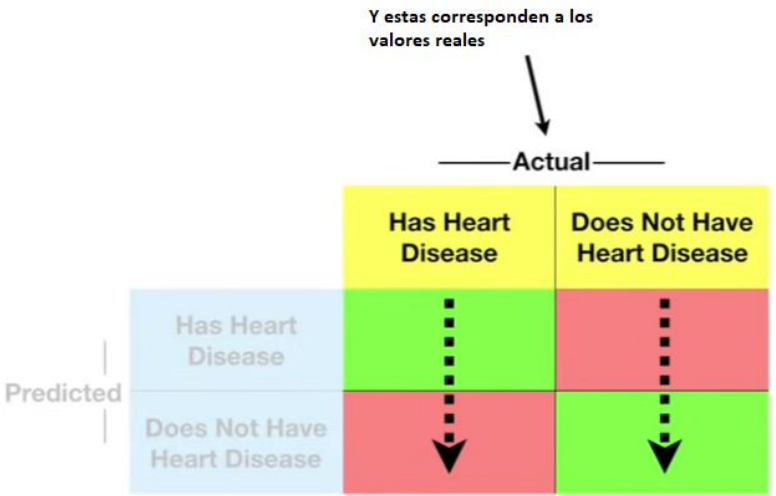
Una forma de hacer esto es con la matriz de confusión



CODERHOUSE

Ejemplo aplicado

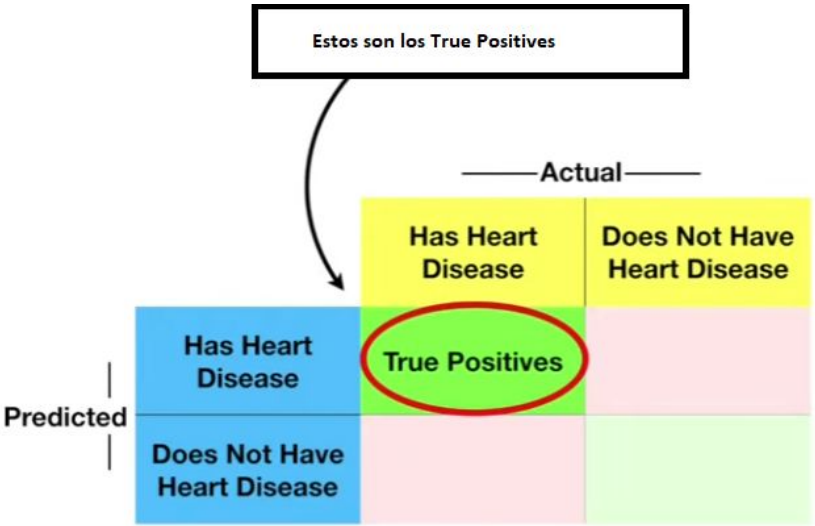


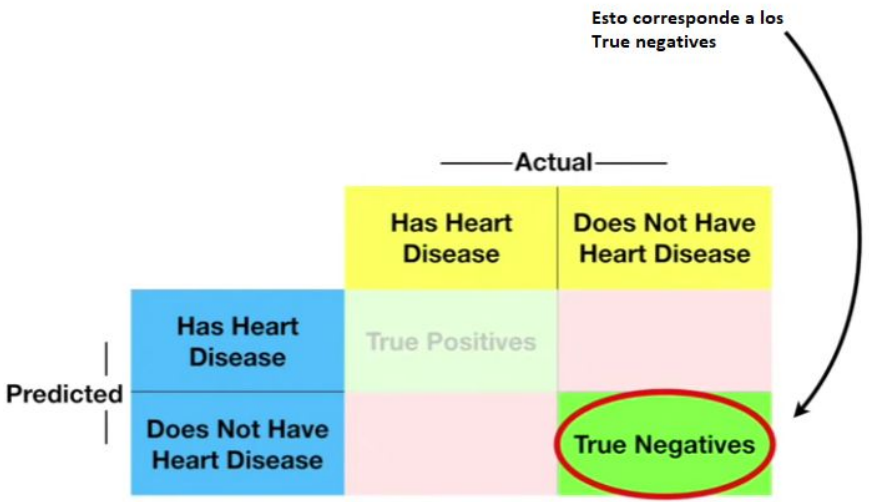


En cada fila tenemos los valores predichos por el algoritmo y en las columnas los valores reales

CODERHOUSE

Ejemplo aplicado

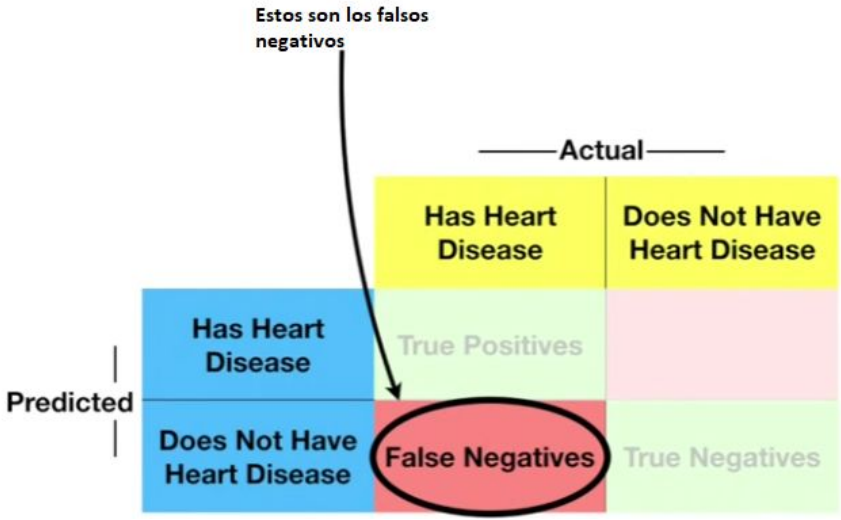


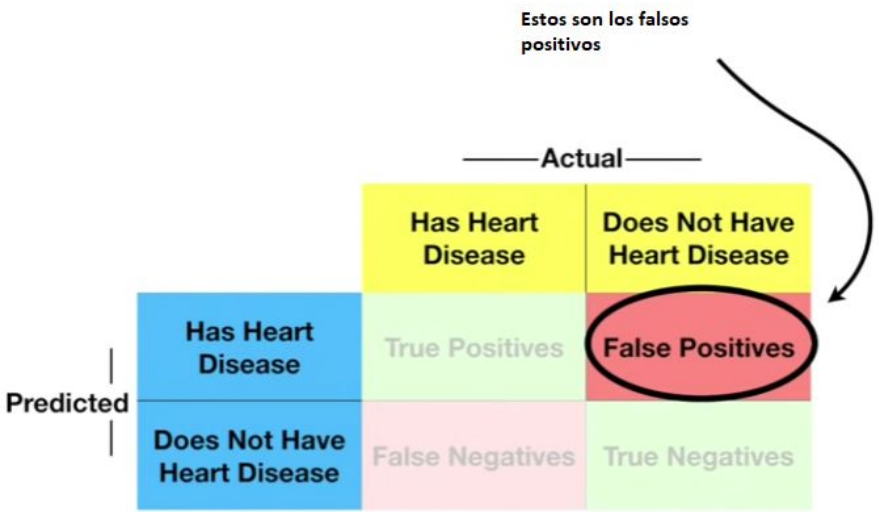


En la diagonal principal de la matriz de confusión tendremos en verde a los Verdaderos Positivos (TP) y Verdaderos Negativos (TN) que son predicciones correctas

CODERHOUSE

Ejemplo aplicado

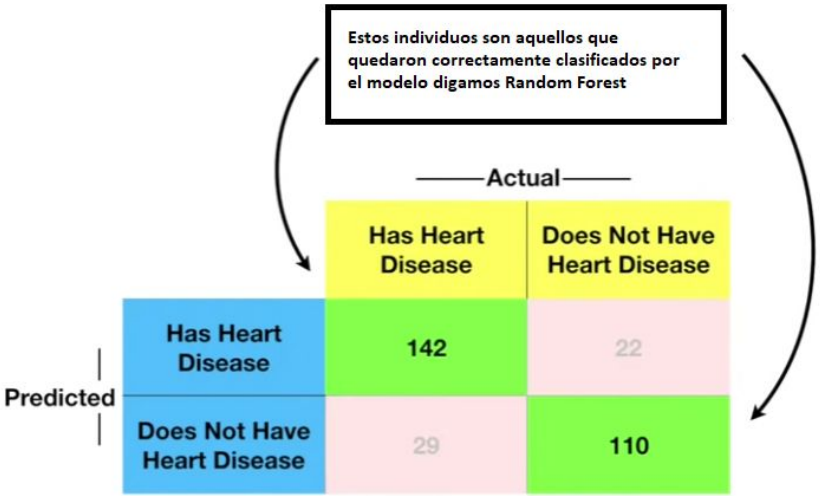


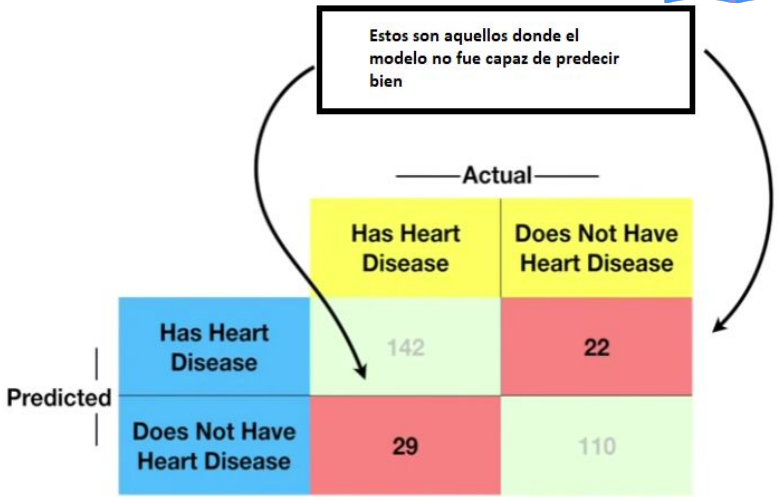


Fuera de la diagonal tenemos a los Falsos Negativos (FN) y a los Falsos Positivos (FP) que representan a los errores Tipo I y Tipo II

CODERHOUSE

Ejemplo aplicado





Para el ejemplo que estamos analizando podemos ver que 142+110 individuos quedaron bien clasificados, mientras que 22+29 quedaron mal clasificados

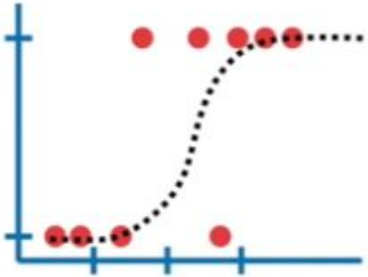
CODERHOUSE

Ejemplo aplicado



	Has Heart Disease	Does Not Have Heart Disease
Has Heart Disease	142	22
Does Not Have Heart Disease	29	110

Cuando los modelos tienen una matriz de confusion similar no es tan facil la cuestion. Para eso se puede usar metricas como sensibilidad, especificidad, ROC y AUC



	Has Heart Disease	Does Not Have Heart Disease
Has Heart Disease	139	20
Does Not Have Heart Disease	32	112

CODERHOUSE



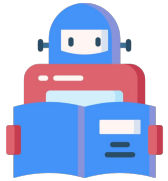
Para pensar

¿Se puede realizar una matriz de confusión cuando tenemos más de dos categorías?
Justifiquen su respuesta.

Contesta en el chat de Zoom

CODERHOUSE

Ejemplo aplicado



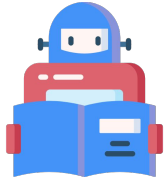
		Actual		
		Troll 2	Gore Police	Cool as Ice
Predicted	Troll 2	12	102	93
	Gore Police	112	23	77
	Cool as Ice	83	92	17

		Actual		
		Troll 2	Gore Police	Cool as Ice
Predicted	Troll 2	12	102	93
	Gore Police	112	23	77
	Cool as Ice	83	92	17

La respuesta es sí si miramos para el caso de 3 categorías como se observa en las figuras de arriba tenemos un ejemplo donde en verde están las buenas clasificaciones y en rojo las malas

CODERHOUSE

Ejemplo aplicado

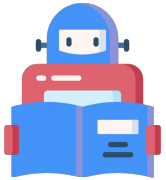


	Thing 1	Thing 2	Thing 3	Thing 4
Thing 1				
Thing 2				
Thing 3				
Thing 4				

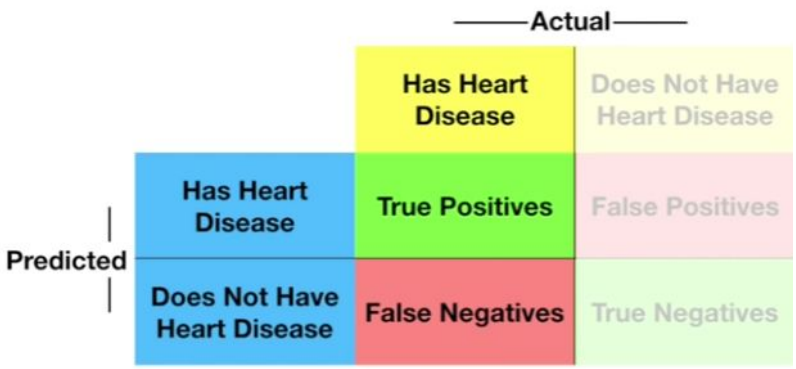
Incluso para el caso de más de 3 categorías podríamos construir una matriz de confusión aunque sería más complejo la interpretación de los resultados y la cuantificación de los errores

CODERHOUSE

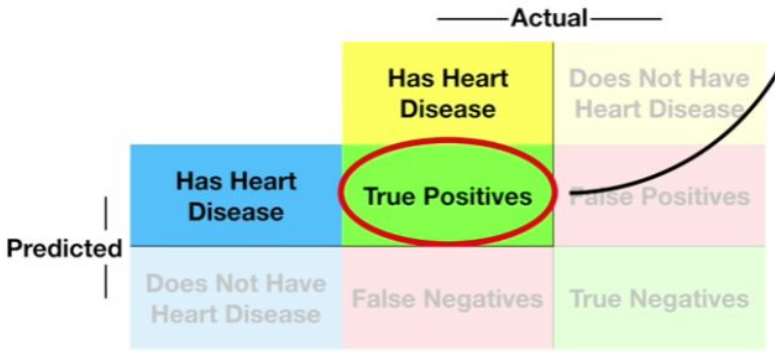
Ejemplo aplicado



La sensibilidad dice el porcentaje de pcientes con heart disease que fueron identificados bien



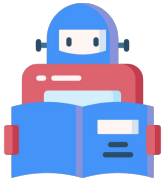
$$\text{Sensitivity} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$



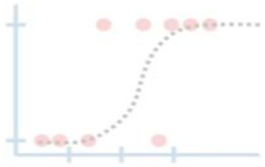
La sensibilidad para este caso se enfoca principalmente en el número de pacientes que fueron identificado correctamente

CODERHOUSE

Ejemplo aplicado



$$\text{Sensitivity} = \frac{139}{139 + 32} = 0.81$$



	Has Heart Disease	Does Not Have Heart Disease
Has Heart Disease	139	20
Does Not Have Heart Disease	32	112

81 % de las personas **con** ataque cardíaco fueron identificadas con el modelo de regresión logística

$$\text{Sensitivity} = \frac{142}{142 + 29} = 0.83$$

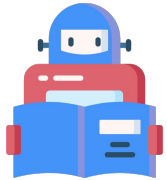


		Actual: Has Heart Disease	Actual: Does Not Have Heart Disease
Predicted	Has Heart Disease	142	22
Predicted	Does Not Have Heart Disease	29	110

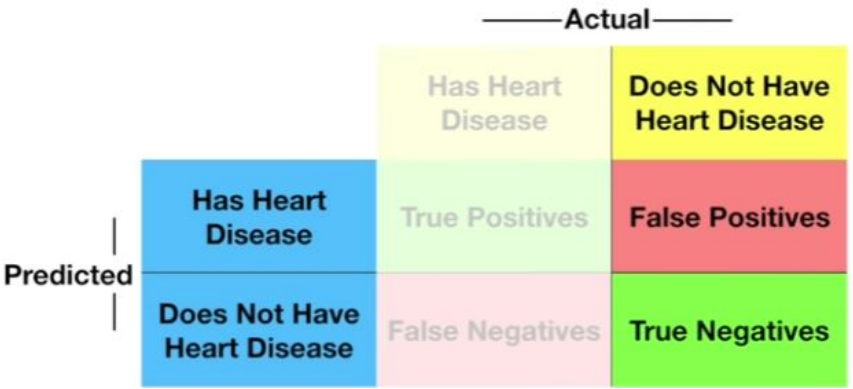
83 % de las personas **con** ataque cardíaco fueron identificadas con el modelo de Random Forest

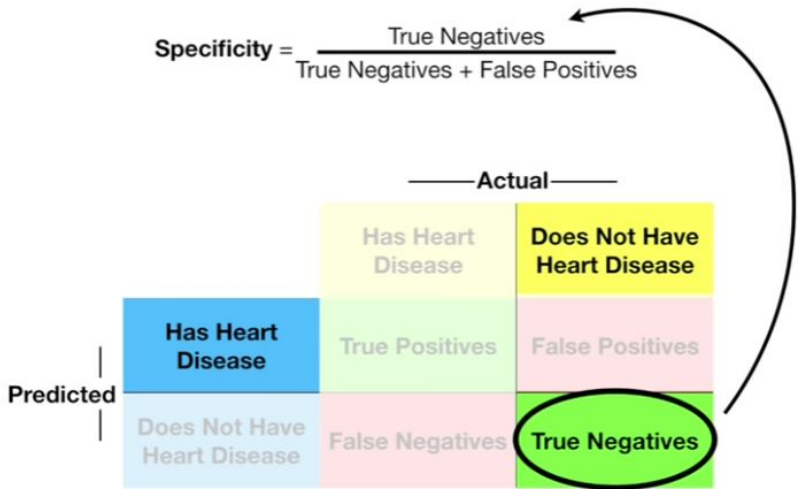
CODERHOUSE

Ejemplo aplicado



La especificidad dice el porcentaje de pacientes sin heart disease que fueron correctamente identificados

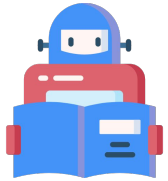




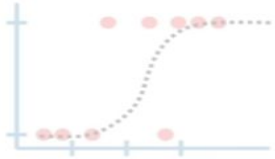
La especificidad por el contrario se enfoca en el número de pacientes que no tienen la característica y que fueron correctamente identificados

CODERHOUSE

Ejemplo aplicado



$$\text{Specificity} = \frac{112}{112 + 20} = 0.85$$



	Has Heart Disease	Does Not Have Heart Disease
Has Heart Disease	139	20
Does Not Have Heart Disease	32	112

85 % de las personas **sin** ataque cardíaco fueron identificadas con el modelo de regresión logística

$$\text{Sensitivity} = \frac{142}{142 + 29} = 0.83$$

$$\text{Specificity} = \frac{110}{110 + 22} = 0.83$$

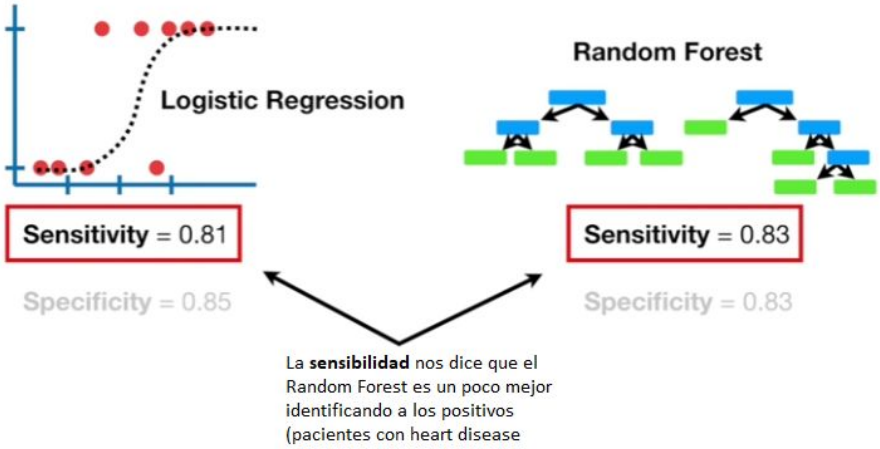


		Actual: Has Heart Disease	Actual: Does Not Have Heart Disease
Predicted	Has Heart Disease	142	22
Predicted	Does Not Have Heart Disease	29	110

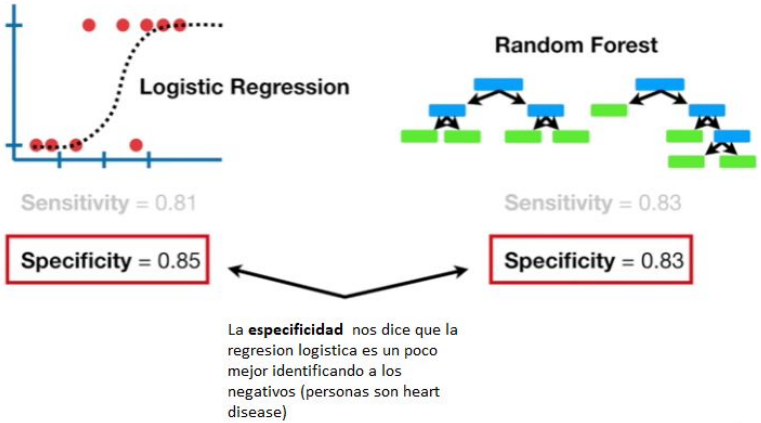
83 % de las personas **sin** ataque cardíaco fueron identificadas con el modelo de Random Forest

CODERHOUSE

Ejemplo aplicado



Usamos el modelo de **Regresión Logística** si identificar pacientes **sin** heart disease es más importante que identificar pacientes **con** heart disease



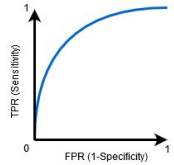
Usamos el modelo de **Random Forest** si identificar pacientes **con** heart disease es más importante que identificar pacientes **sin** heart disease

CODERHOUSE

Curva ROC

CODERHOUSE

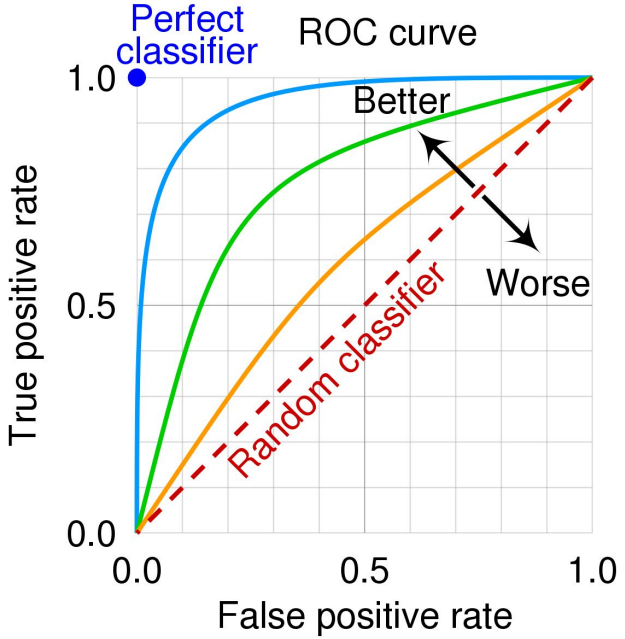
Curva ROC



La curva AUC-ROC es una métrica de rendimiento que se utiliza para **medir el rendimiento del modelo de clasificación en diferentes valores de umbral**.

Cuanto mayor sea el valor de AUC (Área bajo la curva), mejor será nuestro clasificador para predecir las clases.

AUC-ROC se utiliza principalmente en problemas de clasificación binaria.



CODERHOUSE

Interpretaciones

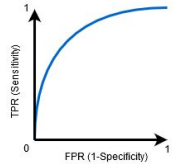
CODERHOUSE

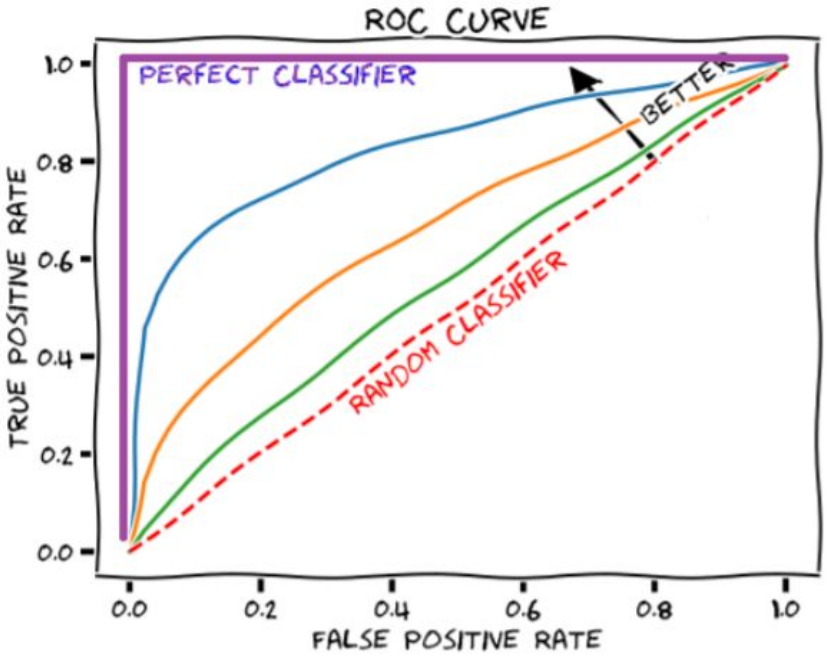
Curva ROC

<u>Interpretaciones:</u>

- AUC cercano a 1: performance casi perfecta AUC
- AUC cercano a 0.5: performance a nivel chance (funciona igual que lanzar una moneda)

Siempre se debe tener presente que alcanzar un valor de 1 para el AUC es bastante complejo pero un umbral entre 0.8-0.9 es un valor apropiado para un modelo que generaliza y no memoriza



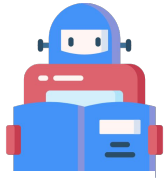


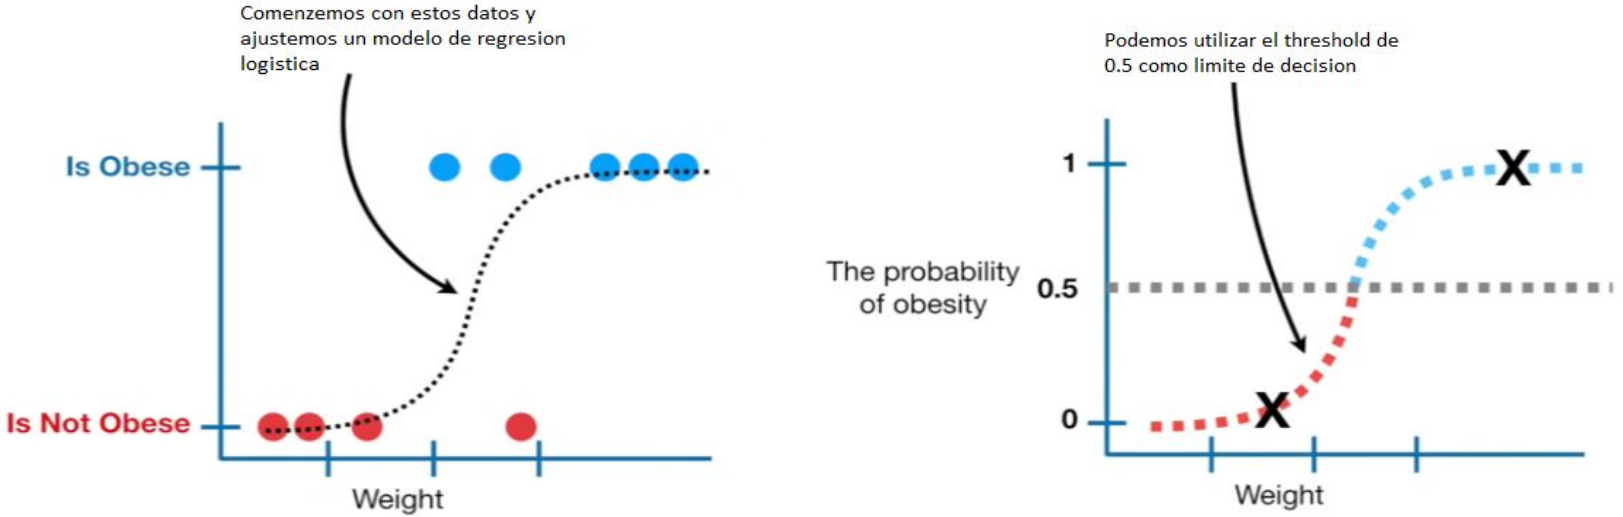
CODERHOUSE

Ejemplo aplicado

CODERHOUSE

Ejemplo aplicado

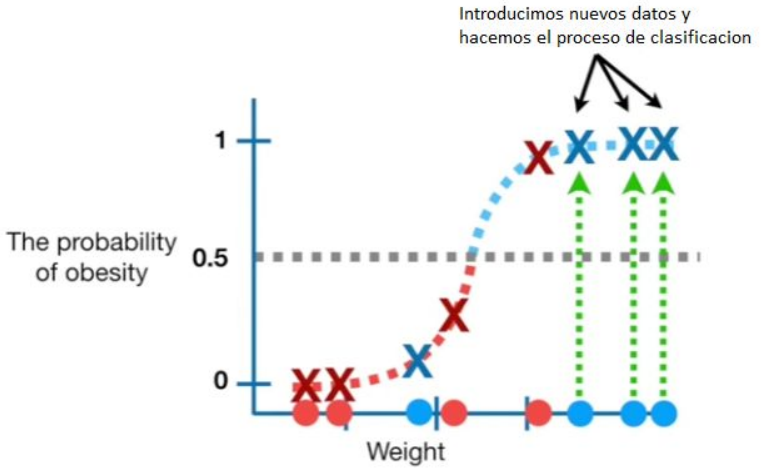


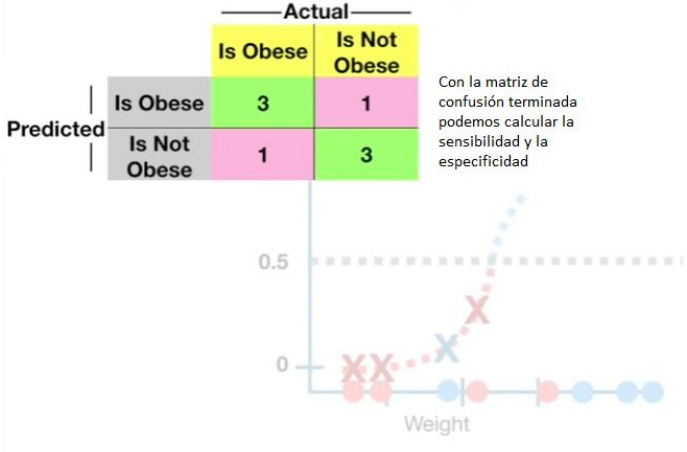


Para este caso enfoquemonos en un modelo de regresión Logística para resolver el problema de clasificación binaria para detectar si un individuo es obeso o no con base en el peso.

CODERHOUSE

Ejemplo aplicado

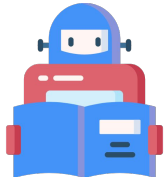


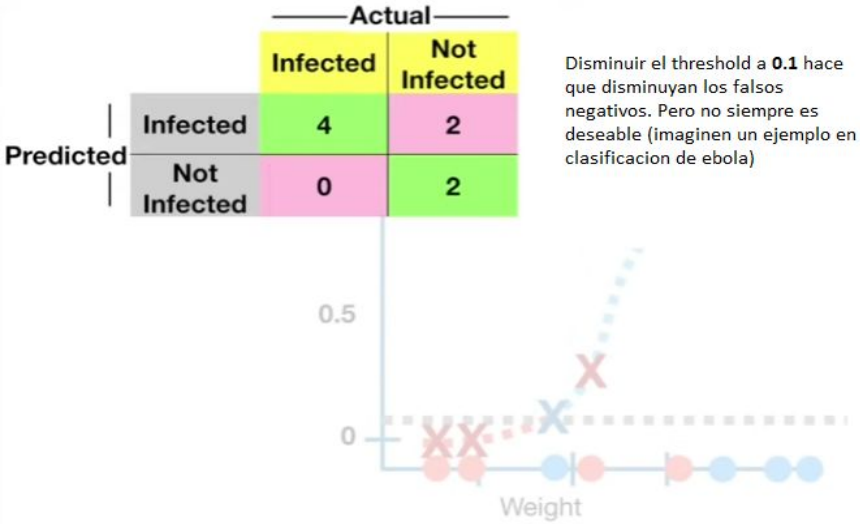


Al hacer el proceso de ajuste de los datos al algoritmo podemos cuantificar que tan bien o mal se desempeña en los datos de test y construimos una matriz de confusión

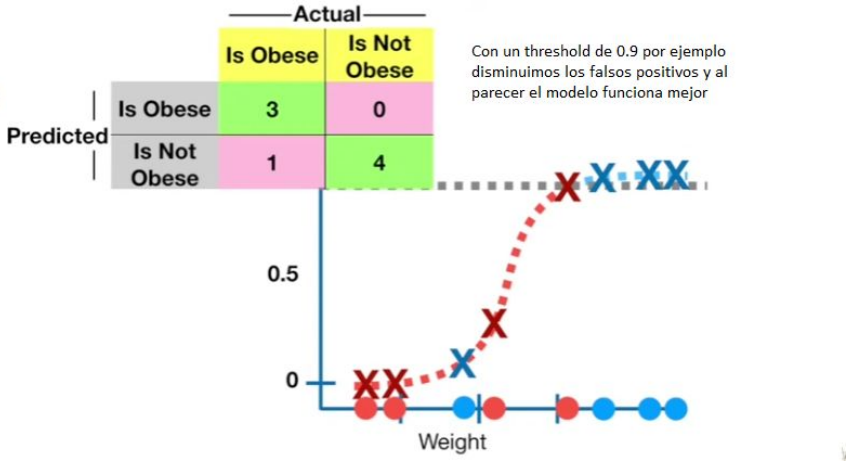
CODERHOUSE

Ejemplo aplicado





Disminuir el threshold a **0.1** hace que disminuyan los falsos negativos. Pero no siempre es deseable (imaginen un ejemplo en clasificacion de ebola)

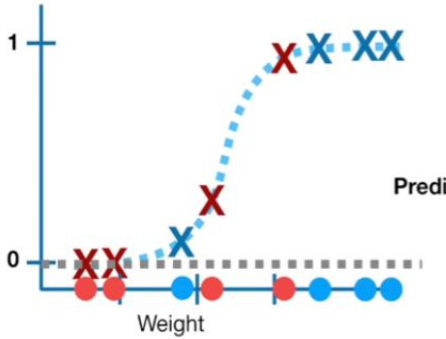


Con un threshold de 0.9 por ejemplo disminuimos los falsos positivos y al parecer el modelo funciona mejor

Si modificamos el valor del threshold o límite de clasificación nuestra matriz de confusión variará por cada nuevo valor que establezcamos como límite.

CODERHOUSE

Ejemplo aplicado



		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	4	4
	Is Not Obese	0	0

True Positive Rate = Sensitivity = $\frac{4}{4+0} = 1$

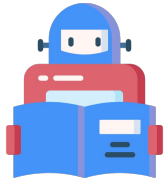
False Positive Rate = 1 - Specificity = $\frac{4}{4+0} = 1$

		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	4	4
	Is Not Obese	0	0

Podemos comenzar con un threshold bajo como 0 o 0.1 y podemos calcular la matriz de confusión y todas sus métricas que ya conocemos

CODERHOUSE

Ejemplo aplicado

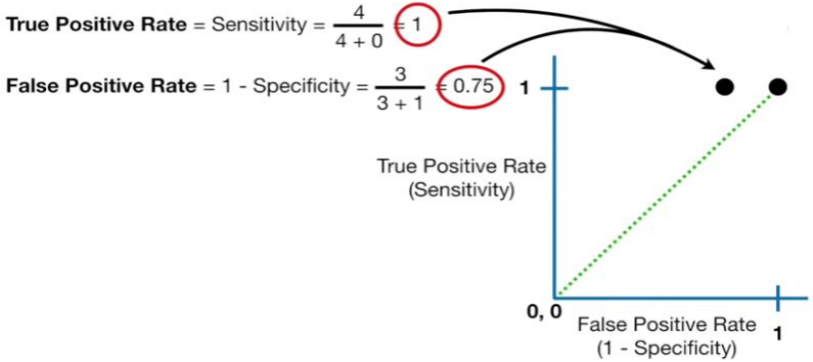


Podemos ir cambiando the threshold de manera iterativa

True Positive Rate = Sensitivity = $\frac{4}{4+0} = 1$ ...and the **False Positive Rate**...

False Positive Rate = 1 - Specificity = $\frac{3}{3+1} = 0.75$

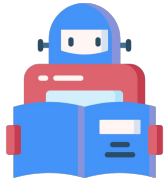
Predicted	Actual: Is Obese	Actual: Is Not Obese
Is Obese	4	3
Is Not Obese	0	1



Como resultado vamos observando que podemos ir creando diferentes puntos cruzando la False Positive Rate vs True Positive Rate

CODERHOUSE

Ejemplo aplicado

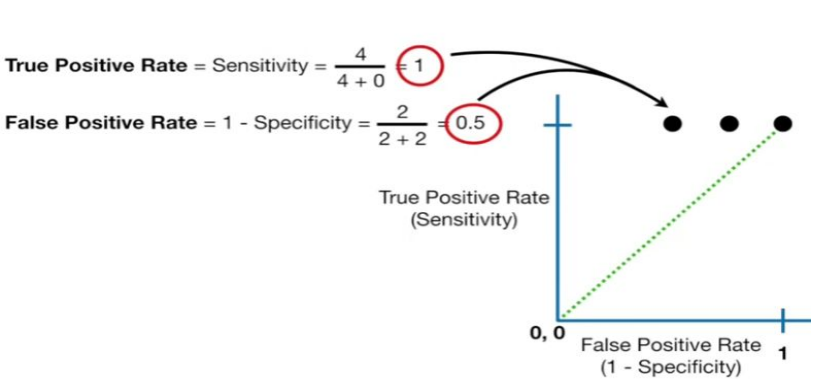


Podemos ir cambiando the threshold de manera iterativa

True Positive Rate = Sensitivity = $\frac{4}{4+0} = 1$

False Positive Rate = 1 - Specificity = $\frac{2}{2+2} = 0.5$

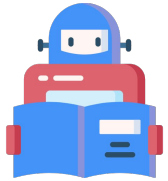
		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	4	2
	Is Not Obese	0	2



Como resultado vamos observando que podemos ir creando diferentes puntos cruzando la False Positive Rate vs True Positive Rate

CODERHOUSE

Ejemplo aplicado

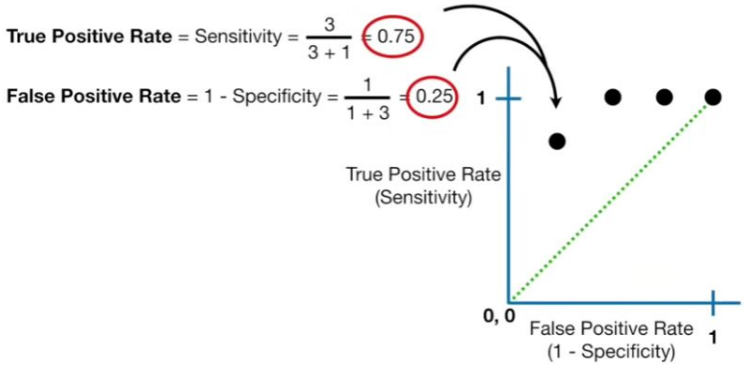


Podemos ir cambiando the threshold de manera iterativa

True Positive Rate = Sensitivity = $\frac{3}{3+1}$ = 0.75

False Positive Rate = 1 - Specificity = $\frac{1}{1+3}$ = 0.25

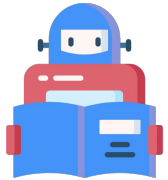
		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	3	1
	Is Not Obese	1	3



Como resultado vamos observando que podemos ir creando diferentes puntos cruzando la False Positive Rate vs True Positive Rate

CODERHOUSE

Ejemplo aplicado

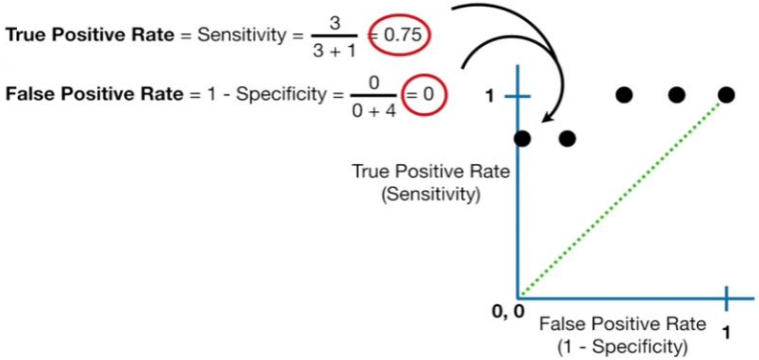


Podemos ir cambiando the threshold de manera iterativa

True Positive Rate = Sensitivity = $\frac{3}{3+1}$ = 0.75

False Positive Rate = 1 - Specificity = $\frac{0}{0+4}$ = 0

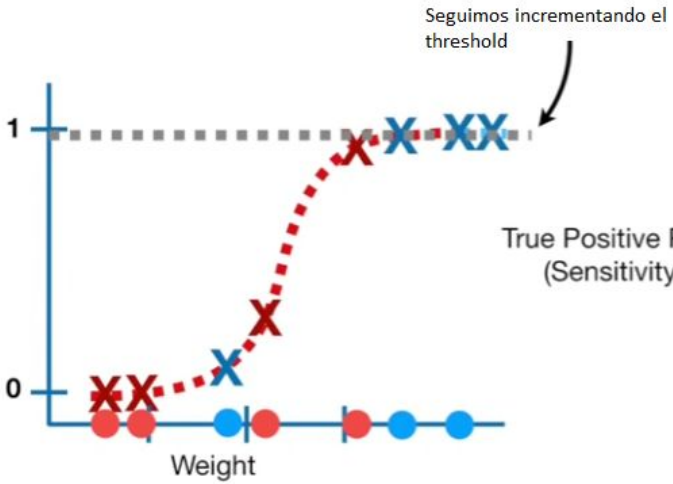
		Actual: Is Obese	Actual: Is Not Obese
Predicted	Is Obese	3	0
	Is Not Obese	1	4

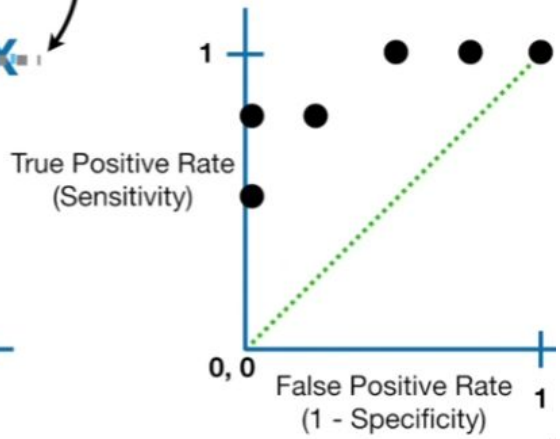


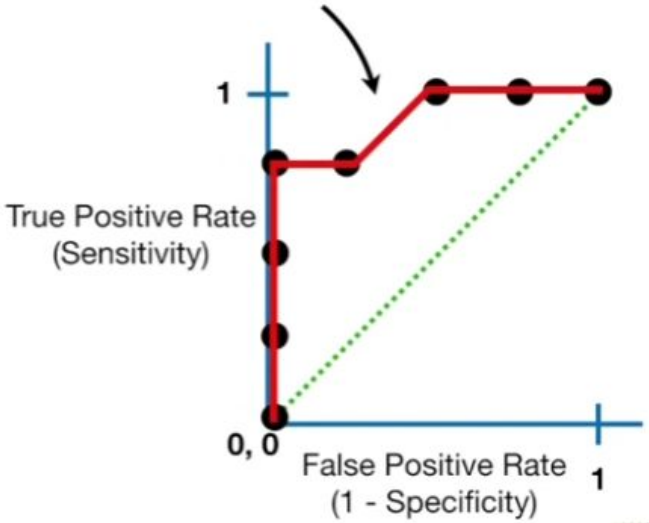
Como resultado vamos observando que podemos ir creando diferentes puntos cruzando la False Positive Rate vs True Positive Rate

CODERHOUSE

Ejemplo aplicado



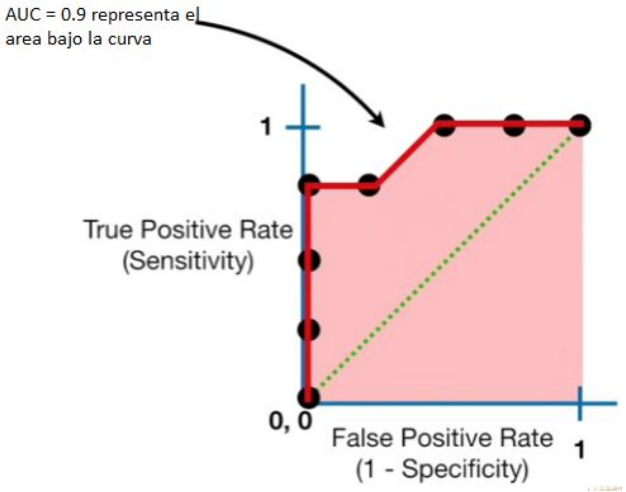


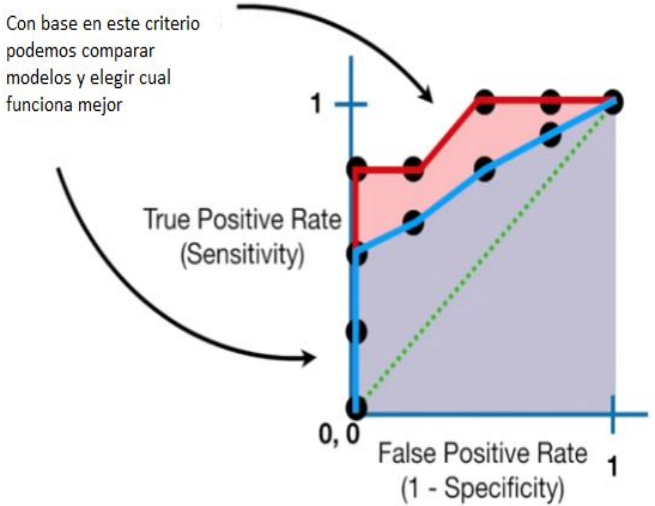


Como resultado si unimos todos los puntos que generamos tenemos la curva que se observa a la derecha

CODERHOUSE

Ejemplo aplicado

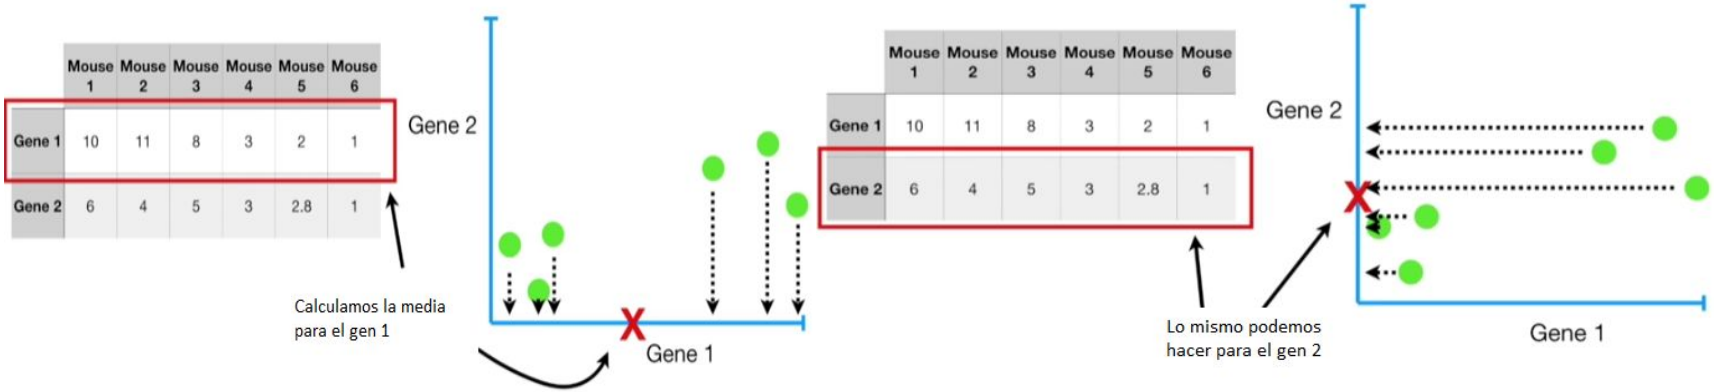




Podemos calcular para el mismo problema la curva ROC para otros modelos y con base en esto comparar cual tiene mejor desempeño

CODERHOUSE

PCA (Principal Component Analysis)



Si calculamos la media de la primera variable tenemos lo siguiente

De igual forma si calculamos la media de la segunda variable tenemos lo siguiente

CODERHOUSE



Break

¡10 minutos y volvemos!

CODERHOUSE



Ejemplo en vivo

Dentro de la carpeta de clase analizaremos cómo evaluar modelos de clasificación (SVM, Random Forest, Regresión Logística y árboles de decisión) haciendo uso de la matriz de confusión y sus métricas

CODERHOUSE

¿Preguntas?

CODERHOUSE

Glosario

Matriz de confusión: técnica para resumir el desempeño de un algoritmo de clasificación, puede dar una mejor idea de qué está haciendo bien el modelo de clasificación y qué tipos de errores está cometiendo.

Accuracy: número de predicciones correctas dividido por el número total de predicciones

Precisión: número de verdaderos positivos dividido por el número total de verdaderos positivos y falsos positivos.

Sensibilidad: número de Verdaderos positivos divididos por verdaderos positivos más Falsos negativos

Especificidad: número de predicciones negativas correctas dividido por el número total de negativos

F1 Score: métrica que cuantifica la precisión y recall de un algoritmo de clasificación

Curva ROC: métrica de rendimiento que se utiliza para medir el rendimiento del modelo de clasificación en diferentes valores de umbral.

CODERHOUSE

Muchas gracias.

CODERHOUSE

Resumen
de la clase hoy

- ✓ Matriz de confusión
- ✓ Accuracy
- ✓ Precisión
- ✓ Sensibilidad
- ✓ Especificidad
- ✓ F1 Score
- ✓ Curva ROC

CODERHOUSE

Opina y valora esta clase

CODERHOUSE

#DemocratizandoLaEducación

CODERHOUSE