Esta clase va a ser

- grabada

CODERHOUSE

DATA SCIENCE

Modelos de Ensamble y Boosting Models

CODERHOUSE

Objetivos de la clase

- **Identificar** algoritmos de Ensamble y Boosting

CODERHOUSE

MAPA DE CONCEPTOS



CODERHOUSE

Métodos de Ensamble

CODERHOUSE



Métodos de Ensamble



También llamados **“métodos combinados”**, intentan **ayudar a mejorar el rendimiento de los modelos de Machine Learning al mejorar su precisión**.

Este es un proceso mediante el cual se construyen estratégicamente varios modelos de Machine Learning para resolver un problema particular.

CODERHOUSE

Ejemplo aplicado

CODERHOUSE



Métodos de Ensamble

Supongamos que queremos invertir en una empresa, pero no estamos seguros de su posible rendimiento, por lo tanto buscamos varios expertos financieros para que nos aconsejen si el precio de la acción aumentará en más de un 5% anual.



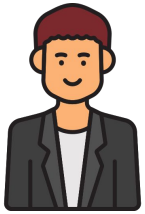
CODERHOUSE

Métodos de Ensamble



Empleada	Asesor Financiero	Operadora Mercado de Valores	Empleado Competidor
Conoce la funcionalidad interna de la empresa. Ha tenido razón 70% de las veces.	Conoce cómo la estrategia de empresas será desarrollada. Ha tenido razón 75 % de las veces.	Conoce el precio de las acciones de la empresa en los últimos años. Ha tenido razón 65 % de las veces.	Conoce la funcionalidad interna de las firmas competidoras. Ha tenido razón 60% de las veces.









CODERHOUSE

Métodos de Ensamble



Empleada de la empresa: Esta persona **conoce la funcionalidad interna de la empresa y tiene información sobre la misma**, pero ***carece de una perspectiva más amplia sobre cómo están innovando los competidores y cómo está evolucionando la tecnología***. En el pasado, ha tenido razón 70% de veces

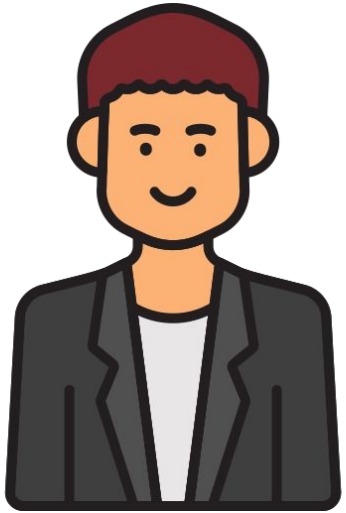


CODERHOUSE

Métodos de Ensamble



Asesor financiero de la empresa: Esta persona tiene una **perspectiva más amplia sobre cómo la estrategia de las empresas será ajustada en este entorno competitivo**, sin embargo, ***carece de una visión sobre cómo las políticas internas de la empresa impactan en su funcionalidad***. En el paso ha tenido razón un 75% de las veces.



CODERHOUSE

Métodos de Ensamble



Operadora del mercado de valores: Esta persona ha observado el precio de las acciones de la empresa en los últimos años y **conoce las tendencias de estacionalidad y el rendimiento del mercado en general, pero también conoce que las acciones pueden variar con el tiempo**. En el pasado ha tenido razón 65% de veces.



CODERHOUSE

Métodos de Ensamble

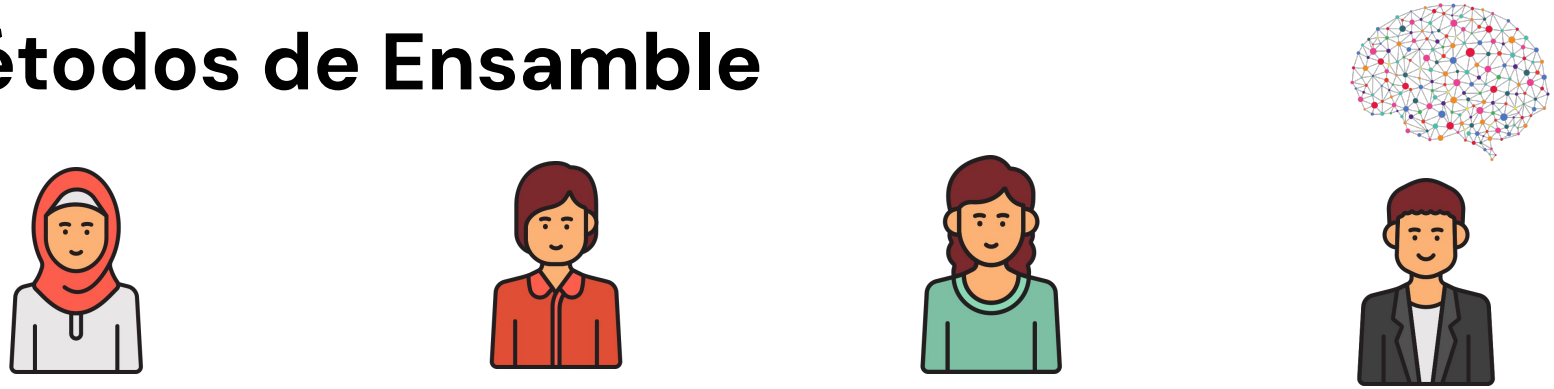


Empleado de un competidor: Esta persona **conoce la funcionalidad interna de las firmas competidoras y está consciente de ciertos cambios que aún no se han implementado**, pero por otra parte ***carece de conocimiento sobre la empresa enfocada y de los factores externos que pueden relacionar el crecimiento del competidor.*** En el pasado, ha tenido razón el 60% de las veces.



CODERHOUSE

Métodos de Ensamble



Como podemos observar del ejemplo anterior, cada experto tiene su propia opinión respecto del tema y nos ofrece una respuesta a la pregunta solicitada. La idea justamente es encontrar la decisión más adecuada en base a las diversas miradas de los expertos.

CODERHOUSE



Para pensar

Ahora bien, ¿Cuál es la relación entre el ejemplo propuesto y los modelos de Ensamble? ¿Han escuchado de alguno de estos modelos anteriormente?

Contesta en el chat de Zoom

CODERHOUSE



Para pensar

Cuando hablamos de “Model Ensamble” se entiende como el proceso de combinar diversos modelos para improvisar la estabilidad y poder predictivo del modelo, es decir tener en cuenta la diferentes opiniones para crear predicciones más robustas

CODERHOUSE

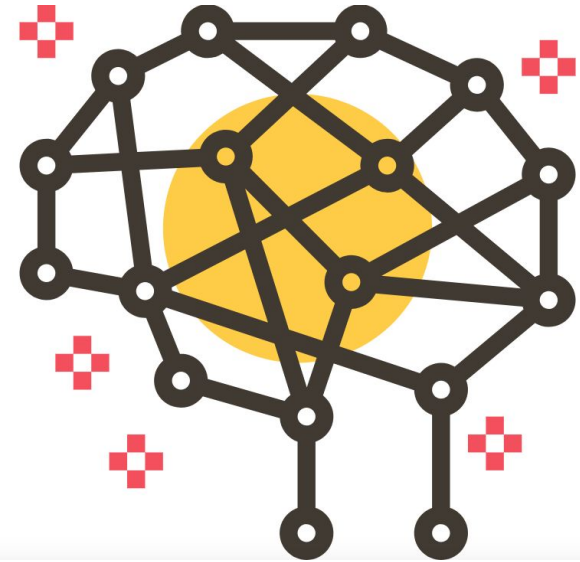
Características de modelos de Ensamble

CODERHOUSE

Características



1. Permiten reducir el error de generalización en las predicciones
2. Las predicciones de diferentes modelos son diversas e independientes.
3. Busca la sabiduría de las multitudes al hacer una predicción.
4. Aunque el modelo de conjunto tiene múltiples modelos base dentro del modelo, actúa y funciona como un solo modelo.

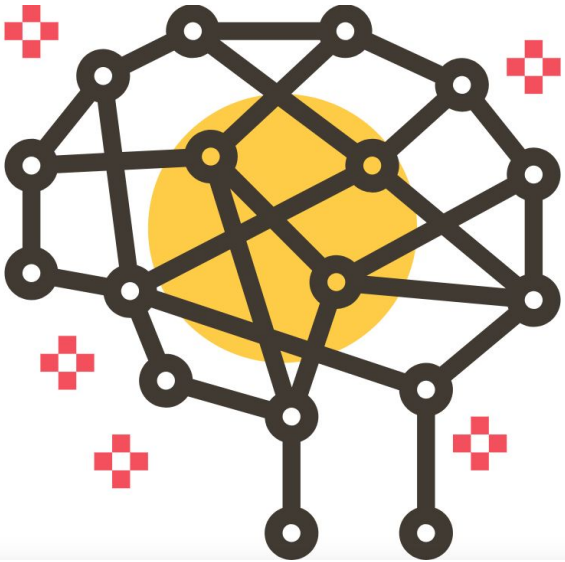


CODERHOUSE

Características



De manera sencilla podría decirse que **son algoritmos formados por algoritmos más simples**. Estos algoritmos simples, **se unen para formar un algoritmo más potente**, siguiendo la premisa: “La unión hace la fuerza”.



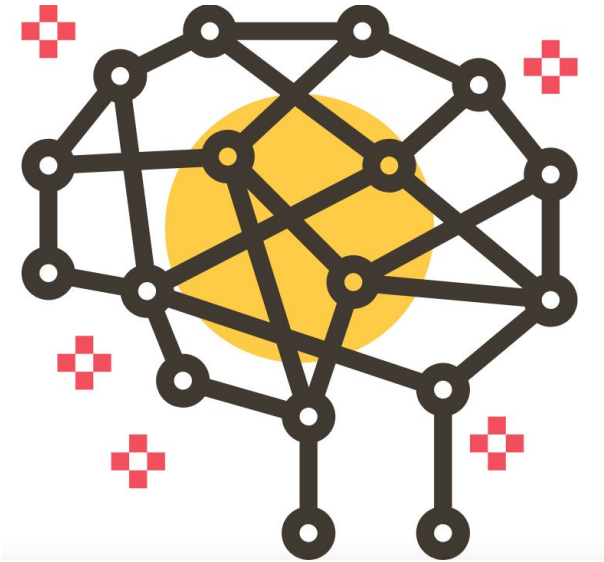
CODERHOUSE

Características



No son todos iguales por diversas razones:

1. Puede haber diferencia en la población de datos
2. Puede haber una técnica de modelado diferente utilizada
3. Puede haber una hipótesis diferente



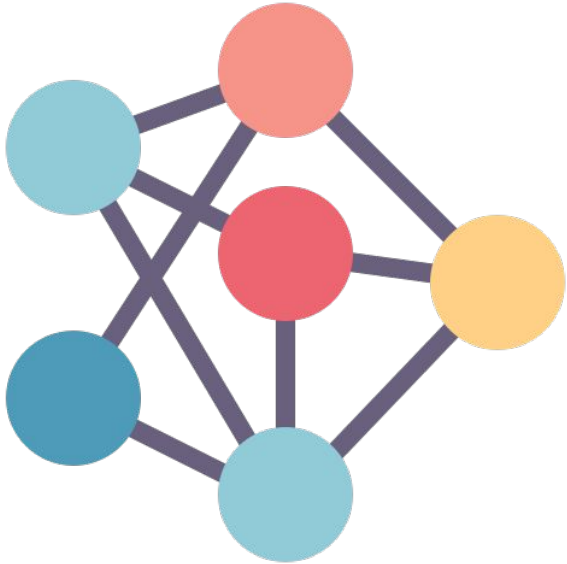
En nuestro ejemplo **“las diferentes opiniones de nuestros expertos financieros”**

CODERHOUSE

Características



Aunque hay diversas formas de ensamblar o unir algoritmos débiles para formar otros, las más usadas y populares son el **bagging y el boosting**.



Cada tipo de algoritmo tiene unas ventajas y desventajas, pudiendo ser usados convenientemente según sea nuestra problemática a resolver.

CODERHOUSE



Para pensar

Al ajustar un modelo de regresión observan que a medida que aumenta la cantidad de datos de entrenamiento, el error de prueba disminuye y el error de entrenamiento aumenta. El error de train es bastante bajo, mientras que el error de prueba es mucho mayor. ¿Cuál crees que es la razón principal detrás de este comportamiento?

A. Alta varianza
B. Alto sesgo en el modelo
C. Alta estimación de sesgo
D. Ninguna de las anteriores

Contesta en el chat de Zoom

CODERHOUSE



Break

¡10 minutos y volvemos!

CODERHOUSE

Metodologías de Ensamble

CODERHOUSE

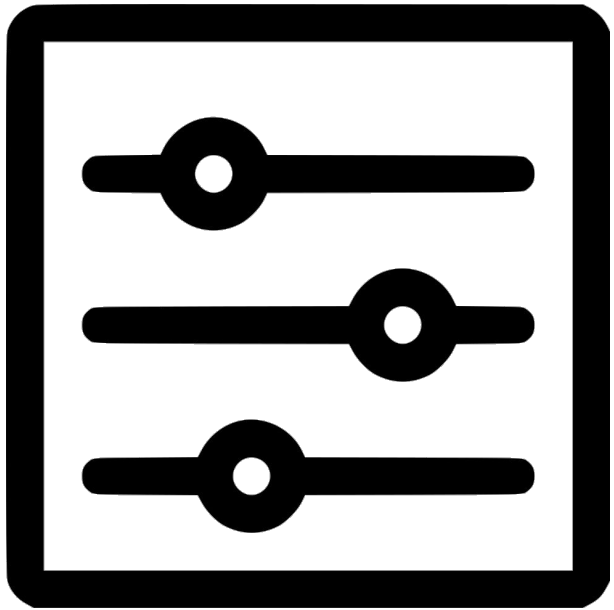
Métodos de Ensamble



Existen diferentes técnicas para poder aplicar estos métodos:

1. Bagging
2. Boosting
3. Stacking (No lo veremos en clase)

A continuación explicaremos cada una de estas técnicas junto con sus algoritmos más importantes



CODERHOUSE

Bagging

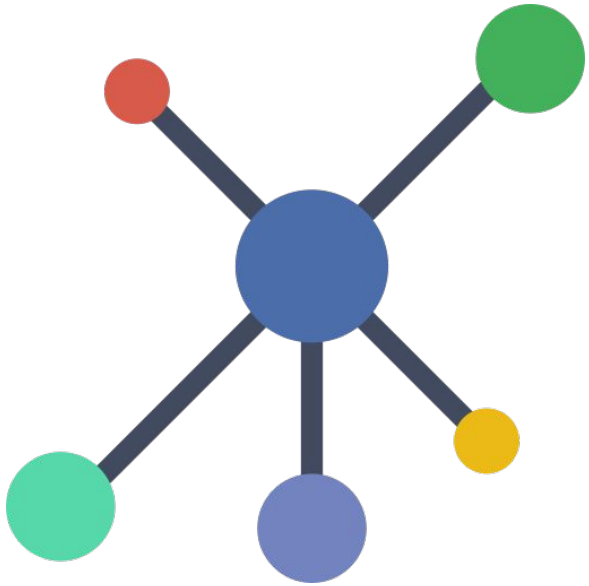
CODERHOUSE

¿De dónde proviene la idea?



Bagging proviene del concepto de **agregación de bootstrap**. *Un forma de reducir la varianza de las estimaciones es promediando estimaciones de distintos modelos o algoritmos*.

Para obtener la agregación de las salidas de cada modelo simple e independiente, **bagging puede usar la votación para los métodos de clasificación y el promedio para los métodos de regresión**.



CODERHOUSE

¿De qué trata?

Los métodos de bagging son métodos donde **los algoritmos simples son usados en paralelo.**

El principal objetivo de los métodos en paralelo es el de **aprovecharse de la independencia que hay entre los algoritmos simples, ya que el error se puede reducir bastante al promediar las salidas** de los modelos simples.





CODERHOUSE

¿De qué trata?



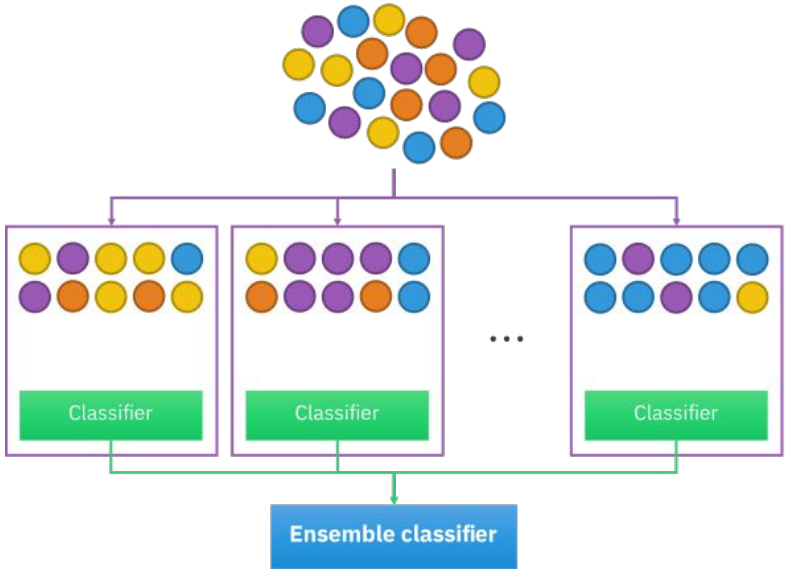
Podríamos pensarlo como como si quisiéramos resolver un problema entre varias personas independientes unas de otras, y finalmente **damos por bueno lo que eligiese la mayoría de las personas**.

Importante: El principal objetivo intrínseco de los algoritmos de bagging es el de la reducción de la varianza.



CODERHOUSE

¿De qué trata?



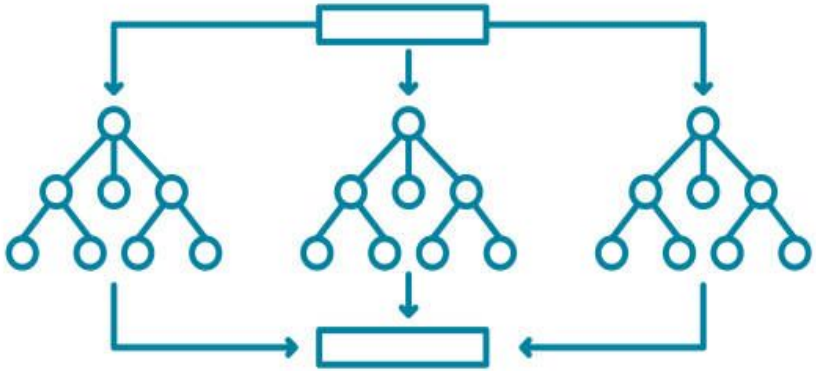
A la izquierda se ilustra el funcionamiento del Bagging

CODERHOUSE

Algoritmos



Estos algoritmos aplican tres procesos fundamentales que son: Bootstrapping, Entrenamiento en paralelo y Agregación



Existen diversos algoritmos pero el modelo más usado es el **Random Forest**

CODERHOUSE

¿De dónde proviene la idea?



Boosting es un método de aprendizaje conjunto que combina un conjunto de modelos simples para minimizar los errores de entrenamiento. Se selecciona una muestra aleatoria de datos y se ajusta con un modelo y luego se entrena secuencialmente. Con cada iteración, las reglas débiles de cada clasificador individual se combinan para formar una regla de predicción fuerte.



CODERHOUSE

¿De qué trata?



En los algoritmos de boosting, los modelos simples son utilizados secuencialmente, es decir, **cada modelo simple va delante o detrás de otro modelo simple**.

El principal objetivo de los métodos secuenciales es el de **aprovecharse de la dependencia entre los modelos simples**.



CODERHOUSE

¿De qué trata?



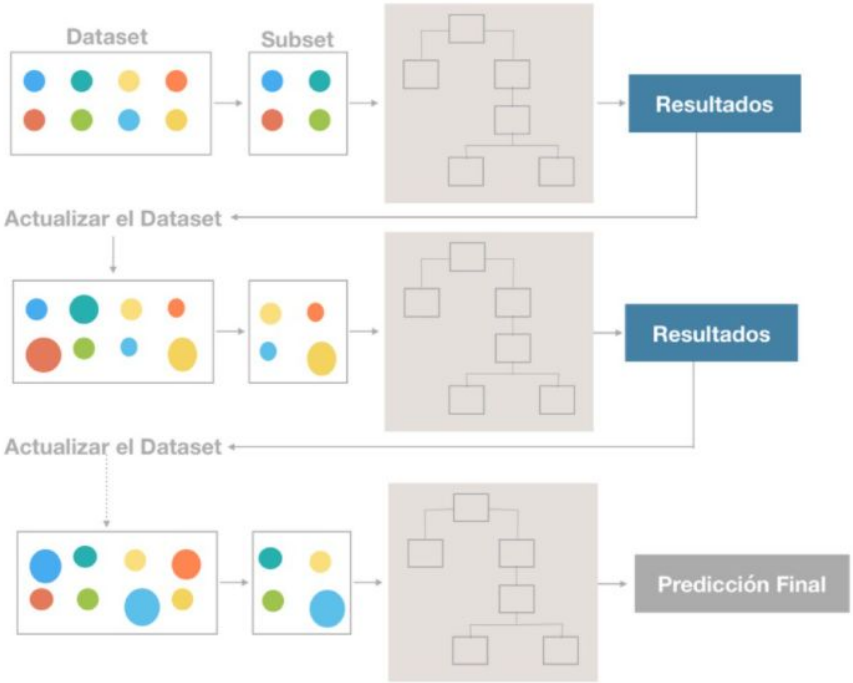
El rendimiento general puede ser mejorado haciendo que un modelo simple posterior, le dé más importancia a los errores cometidos por un modelo simple previo.



Sería como si nosotros al resolver un problema, aprovechásemos nuestro conocimiento de los errores de otros para mejorar en algo intentando no cometerlos nosotros.

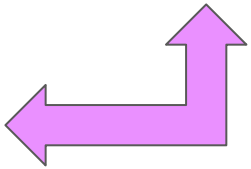
CODERHOUSE

¿De qué trata?





A la izquierda se ilustra el funcionamiento del Boosting



CODERHOUSE



Para pensar

¿Qué diferencias pueden encontrar respecto a la metodología Bagging? ¿Se podrán aplicar los mismos algoritmos para ambas técnicas?

Contesta en el chat de Zoom

CODERHOUSE



Para pensar

La diferencia con el Bagging es que en **el Boosting los algoritmos no se entrenan independientemente,** sino que se ponderan según los errores de los anteriores

Contesta en el chat de Zoom

CODERHOUSE

Boosting

CODERHOUSE

Algoritmos



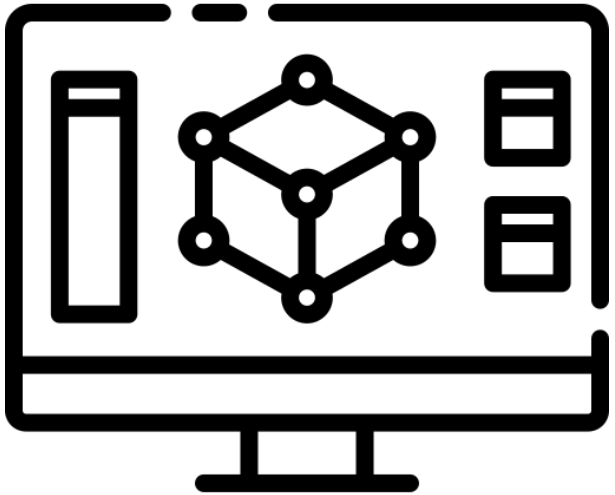
1. ADABOOST
2. GRADIENT BOOSTING
3. XG BOOST
4. LIGHT GBM

CODERHOUSE

AdaBoost



Este algoritmo **entrena de forma secuencial un conjunto de aprendices débiles a partir de un algoritmo base común**. Todos los aprendices son entrenados con el mismo conjunto de datos pero éstos van recibiendo pesos que dependen de los errores cometidos por cada aprendiz.



CODERHOUSE

AdaBoost



Así, inicialmente todos las muestras reciben un peso inicial **wi de 1/n** (suponiendo que haya n muestras). **El primer aprendiz es entrenado y se estima su tasa de error.**

Si trabajamos en un problema de clasificación, la tasa de error está dada por:

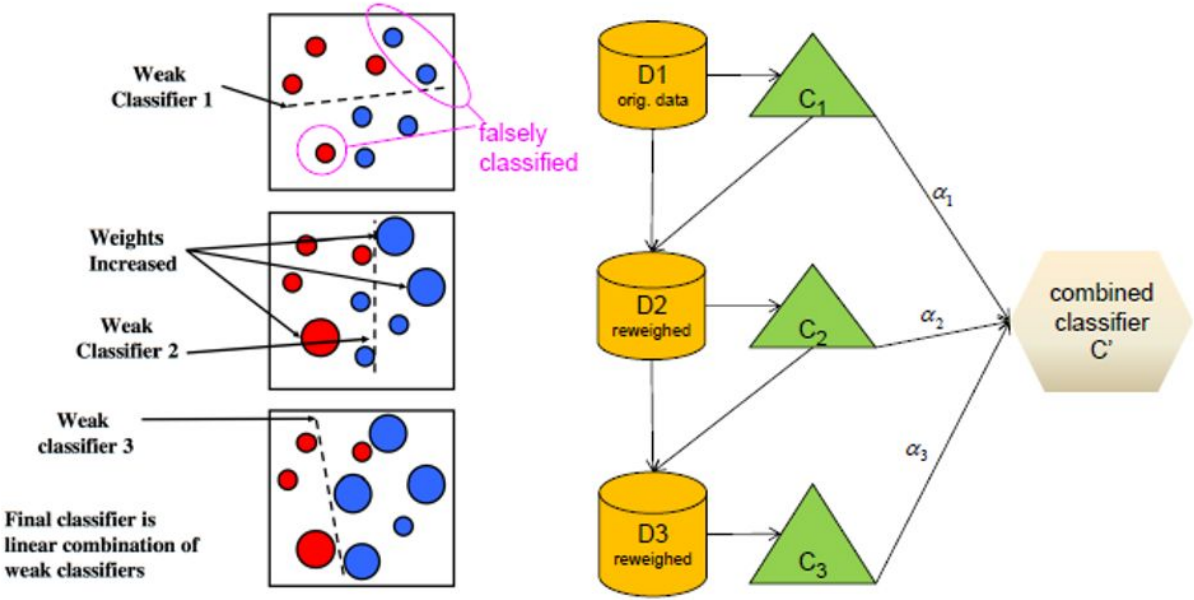
$$r_j = \frac{Suma\ de\ los\ pesos\ de\ las\ muestras\ mal\ clasificadas}{Suma\ de\ todos\ los\ pesos}$$

CODERHOUSE

AdaBoost



A la derecha se ilustra el funcionamiento del modelo AdaBoost

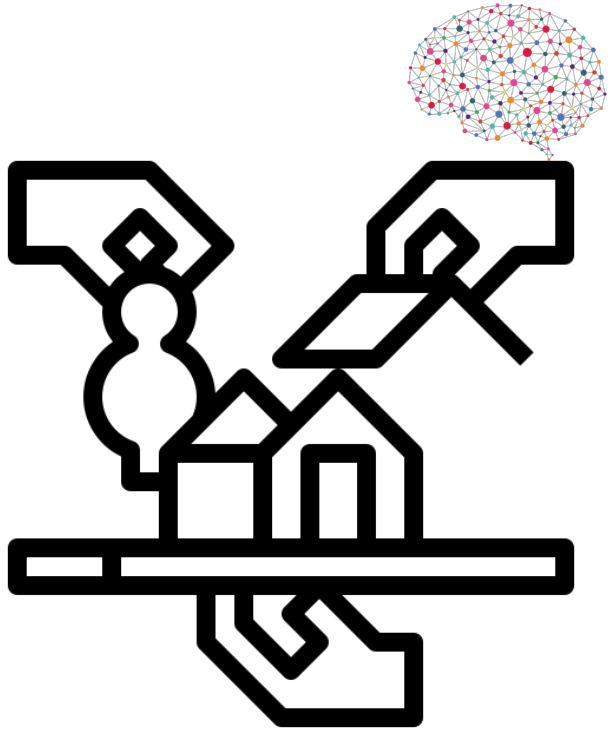


CODERHOUSE

Gradient Boosting

Es un tipo de algoritmo de aumento. **Se basa en la intuición de que el mejor modelo siguiente posible, cuando se combina con modelos anteriores, minimiza el error de predicción general.**

Miremos a detalle cómo funciona!

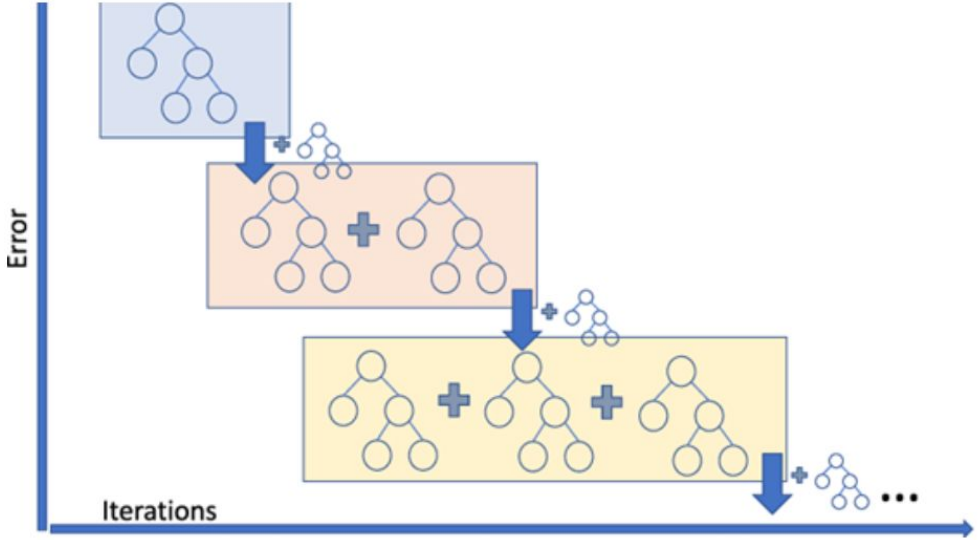


CODERHOUSE

Gradient Boosting



La idea clave es establecer los resultados objetivo para este próximo modelo con el fin de minimizar el error. El aumento de gradiente **se puede utilizar tanto para clasificación como para regresión**.



CODERHOUSE

XGBoosting



Extreme Gradient Boosting, es uno de los **algoritmos de machine learning de tipo supervisado** más usados en la actualidad.

Este algoritmo se caracteriza por obtener **buenos resultados de predicción con relativamente poco esfuerzo**, en muchos casos equiparables o mejores que los devueltos por modelos más complejos computacionalmente, en particular para problemas con datos heterogéneos.



CODERHOUSE

XGBoosting



Se basa en el principio de **“boosting”**, que como bien sabemos, consiste en **generar múltiples modelos de predicción “débiles” secuencialmente y que cada uno de estos tomé los resultados del modelo anterior, para generar un modelo más “fuerte”**, con mejor poder predictivo y mayor estabilidad en sus resultados.

CODERHOUSE

XGBoosting



Para conseguir un modelo más fuerte, se emplea un **algoritmo de optimización**, este caso **Gradient Descent (descenso de gradiente)**. Durante el entrenamiento, **los parámetros de cada modelo débil son ajustados iterativamente tratando de encontrar el mínimo de una función objetivo**, que puede ser la proporción de error en la clasificación, el área bajo la curva (AUC), la raíz del error cuadrático medio (RMSE), etc.



CODERHOUSE

XGBoosting



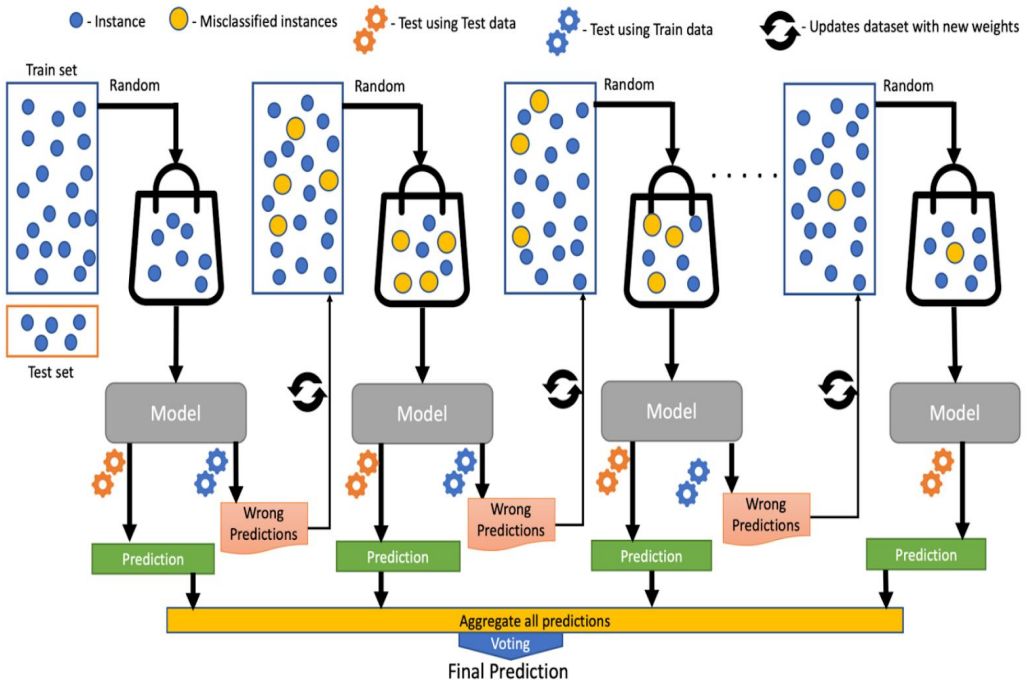
Cada modelo es comparado con el anterior. Si un nuevo modelo tiene mejores resultados, entonces se toma este como base para realizar nuevas modificaciones. **Si, por el contrario, tiene peores resultados, se regresa al mejor modelo anterior y se modifica ese de una manera diferente**.

CODERHOUSE

XGBoosting



A derecha se ilustra el funcionamiento del XGBoosting

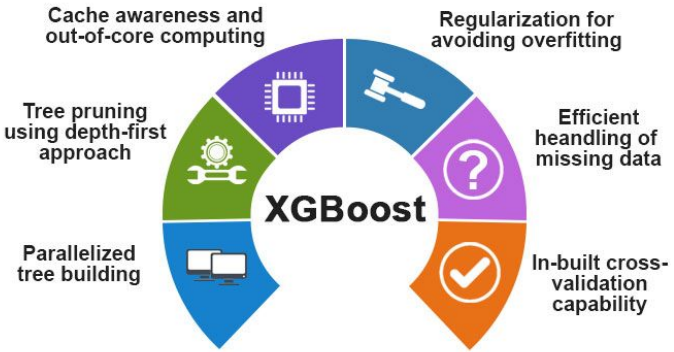


CODERHOUSE

XGBoosting



Este proceso se repite hasta llegar a un punto en el que la diferencia entre modelos consecutivos es insignificante, lo cual nos indica que hemos encontrado el mejor modelo posible, o cuando se llega al número de iteraciones máximas definido por el usuario.



CODERHOUSE

LightGBM



Utiliza la técnica Gradient Boosting. Con este método los árboles se construyen de manera secuencial y cada uno que se agrega aporta su granito de arena para refinar la predicción anterior. Es decir, **se comienza con un valor constante y cada árbol nuevo se entrena para predecir el error en la suma de todas las predicciones de los árboles anteriores.**



CODERHOUSE

LightGBM



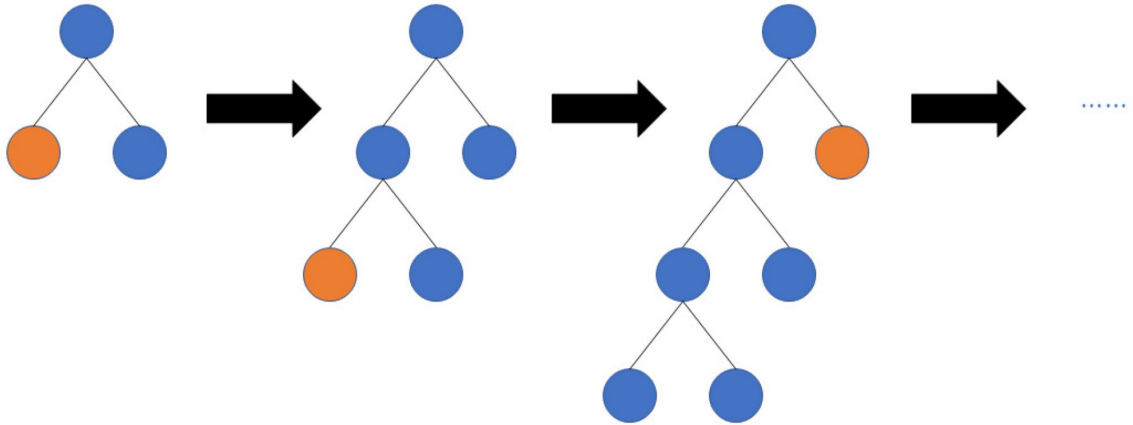
Una vez terminado el proceso, **las predicciones se calculan sumando los resultados de todos los árboles que se construyeron**. El efecto que tiene esto es que **cada vez que se agrega un árbol nuevo se le presta atención a las muestras en las que el modelo está funcionando peor** y se trabaja para mejorar ese aspecto.

CODERHOUSE

LightGBM



A derecha se ilustra el funcionamiento del LightGBM



CODERHOUSE

Ventajas y desventajas

CODERHOUSE

Ventajas y desventajas



Método	Ventajas	Desventajas
Bagging	- Fácil implementación con librerías y buena documentación - Reducción de la varianza especialmente en datasets de alta dimensionalidad	- Pérdida de interpretabilidad debido al proceso de promediado - Consume bastantes recursos computacionales a medida que la cantidad de datos incrementa - Menos flexible y puede llegar a ser menos estable
Boosting	- Fácil implementación con muchos hiper parámetros para configurar el performance - Reducción del sesgo con base el aprendizaje de los weak learners - Eficiencia computacional y menor tiempo de ejecución	- Sensible al overfitting aunque depende de los parámetros - Computación intensiva por ende no es tan fácil de escalar, ya que cada estimador se crea con base en sus predecesores - Son mucho más lentos que los algoritmos de Bagging

CODERHOUSE

¿Preguntas?

CODERHOUSE

CLASE N°50

Glosario

Métodos de Ensamble: También llamados “métodos combinados”, intentan ayudar a mejorar el rendimiento de los modelos de Machine Learning al mejorar su precisión. Existen tres metodologías: Bagging, Boosting y Stacking

Bagging: son métodos donde los algoritmos simples son usados en paralelo con el fin de aprender con base en una estructura en paralelo de cada modelo individual. El algoritmo más importante es el Random Forest

Boosting: es un método de aprendizaje conjunto que combina un conjunto de modelos simples para minimizar los errores de entrenamiento. Se selecciona una muestra aleatoria de datos y se ajusta con un modelo y luego se entrena secuencialmente. Con cada iteración, las reglas débiles de cada clasificador individual se combinan para formar una regla de predicción fuerte.

Sus algoritmos más importantes son: AdaBoost, GradientBoosting, XGBoost y LightGBM

Opina y valora esta clase

CODERHOUSE

Resumen
de la clase hoy

- ✓ Modelos de Ensamble
- ✓ Características
- ✓ Bagging
- ✓ Boosting

CODERHOUSE

Muchas gracias.

CODERHOUSE

#DemocratizandoLaEducación

CODERHOUSE